CASO 2 · CONTEOS Y TASAS · UNIDAD 2.1

Regresión de Poisson: conteos y tasas

Del recuento a la tasa con *offset* · razones de tasas (IRR) · predicción con su margen · inferencia por razón de verosimilitudes · diagnóstico de la Poisson

Modelos Lineales Generalizados · Grado en Ciencia de Datos e IA · UMH

PUNTO DE PARTIDA

Del «¿ocurre?» al «¿cuántas veces?»

CASO 1 · BINARIA

Respuesta 0/1

Bernoulli · enlace logit
Efectos como **odds ratio**



CASO 2 · CONTEOS

Respuesta 0, 1, 2, …

Poisson · enlace log
Efectos como **razón de tasas (IRR)**

La maquinaria es la misma (familia exponencial, IWLS, deviance, LRT); cambian la familia y la lectura:

```
glm(n_asistencia ~ edad_conductor + potencia_cv + ... + offset(log(exposicion)),
family = poisson, data = cartera)
```


Agresti (2015, cap. 7) · Dobson y Barnett (2018, cap. 9)

LO QUE LA DIRECCIÓN QUIERE SABER

El ritmo de siniestros y qué lo explica

1. ¿A qué **ritmo** tienen siniestros nuestras pólizas, y qué factores lo suben o lo bajan —y **cuánto**?

2. ¿Podríais estimar el ritmo esperado, **con su margen**, de una **póliza nueva** de un perfil concreto?

3. Las **asistencias en carretera**, ¿siguen el mismo patrón de riesgo que los siniestros, o responden a otras cosas?

La cartera: 3071 pólizas y un conteo

0.44
asistencias por póliza (media)

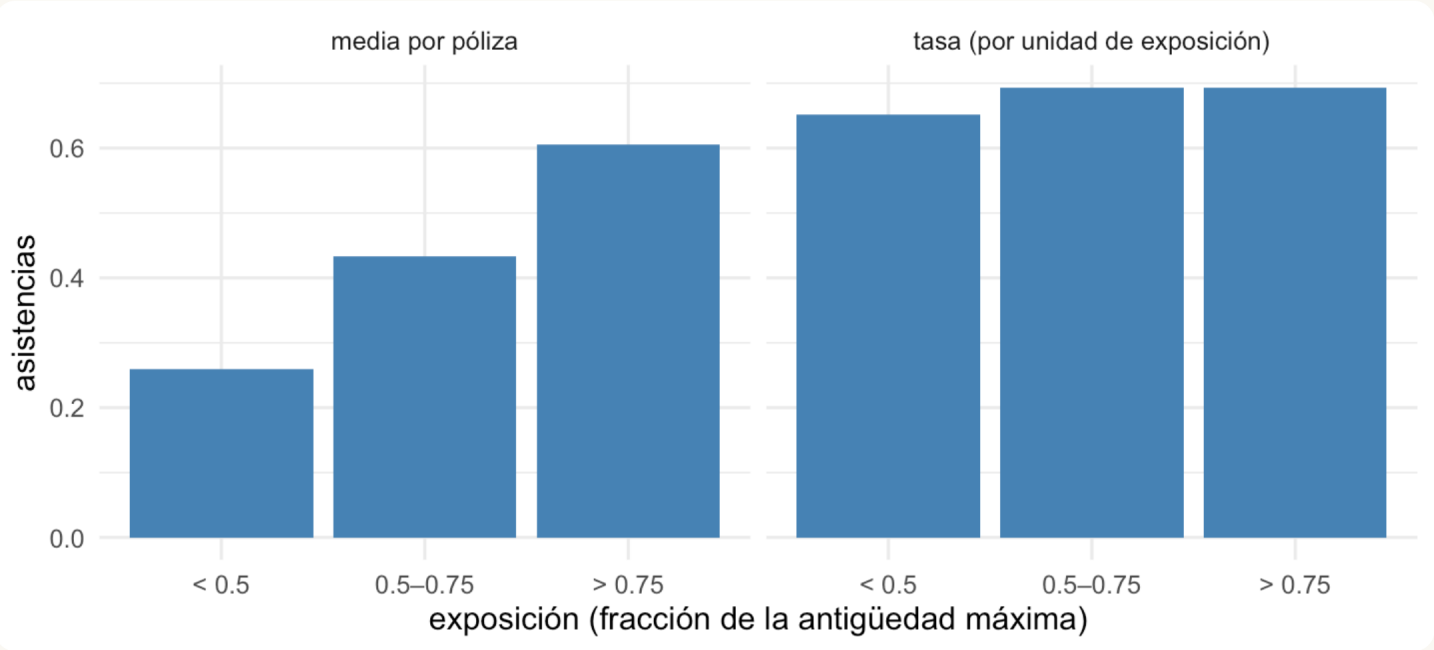
65.7 %
pólizas sin ninguna asistencia

1.11
varianza / media (máximo: 5)

Variable	Papel	Contenido
n_asistencia	respuesta	asistencias en carretera (conteo)
exposicion	offset	antigüedad relativa al cliente más veterano (= 1)
edad_conductor	predictor	años
potencia_cv	predictor	caballos de vapor
zona_circulacion	predictor	urbana · mixta · rural
uso	predictor	particular · comercial
tipo_vehiculo	predictor	turismo · moto · furgoneta

1.1 · CONTEXTO

El recuento confunde riesgo con tiempo observado



Izquierda: media por póliza. Derecha: tasa por unidad de exposición.

Lo que se ve

A más exposición, más asistencias por póliza; la **tasa**, en cambio, apenas se mueve.

Por tanto

Modelamos la **tasa** —asistencias por unidad de exposición— con la exposición como *offset*.

Poisson para la tasa: tres ingredientes

ALEATORIA

$$Y_i \sim \text{Poisson}(\mu_i),\ \mu_i = \lambda_i\, t_i$$

Media = varianza = μ_i (lo pondremos a prueba en 1.5)

ENLACE LOG

$$\log \lambda_i = \eta_i \Rightarrow \lambda_i = e^{\eta_i} > 0$$

Tasa siempre positiva; efectos **multiplicativos**

PREDICTOR LINEAL

$$\eta_i = \beta_0 + x_i'\beta$$

Los mismos predictores que en cualquier GLM

$$\log \mu_i = \log t_i + \beta_0 + x_i'\beta$$

$\log t_i$ es el *offset*: un término con **coeficiente fijado a 1**, que no se estima

Dobson y Barnett (2018, cap. 9) · Agresti (2015, cap. 7)

Máxima verosimilitud, resuelta por IWLS

LOG-VEROSIMILITUD

$$\ell(\beta) = \Sigma_i \left[y_i \left(\log t_i + x_i'\beta\right) - t_i \exp(x_i'\beta) - \log y_i! \right]$$

ECUACIONES DE VEROSIMILITUD

$$\partial \ell / \partial \beta = \Sigma_i \left(y_i - \mu_i\right) x_i = X'(y - \mu) = 0, \; \mu_i = t_i \, \lambda_i$$

Sin solución cerrada

No lineales en β: se itera con el método de Fisher (IWLS)

Respuesta de trabajo

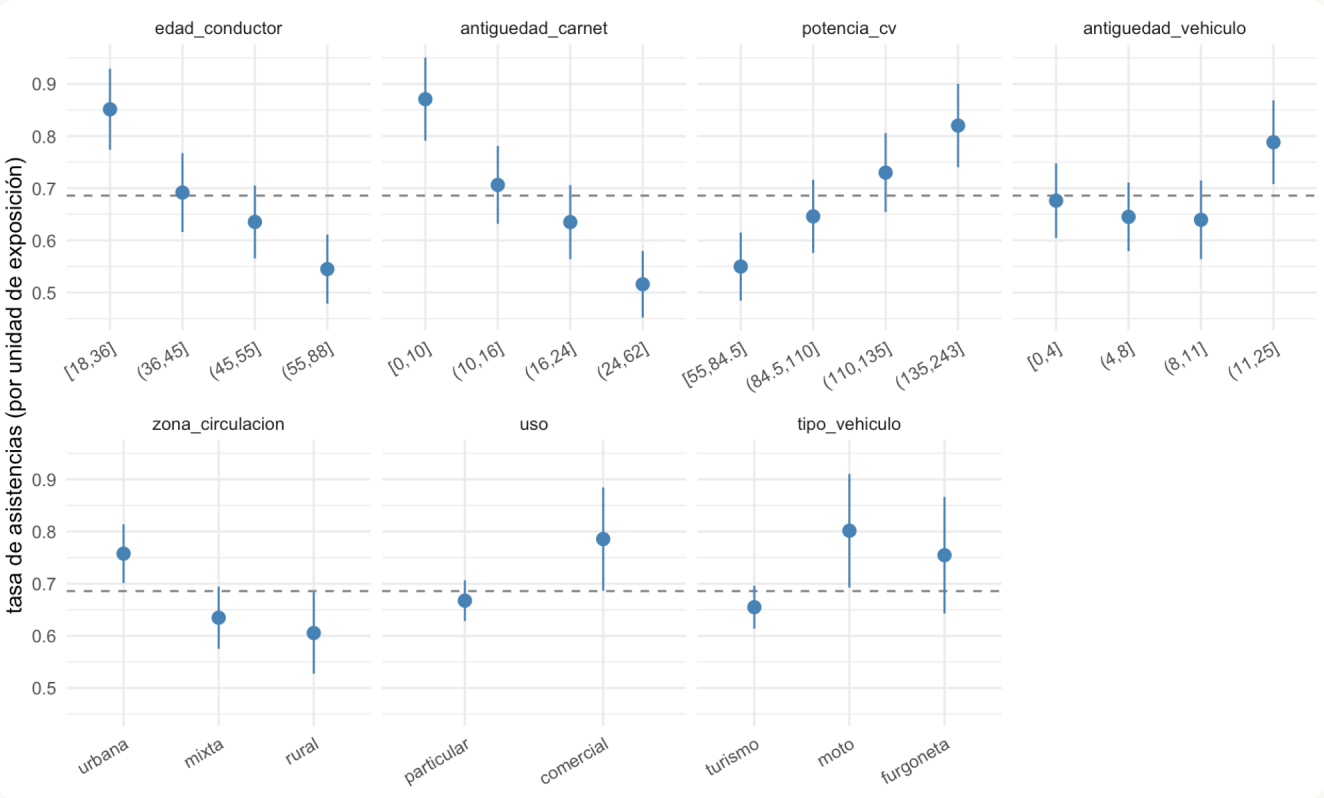
$z_i = \eta_i + (y_i - \mu_i)/\mu_i$

Pesos $w_i = \mu_i$

La media, no la tasa: pesa más quien más tiempo se ha observado

McCullagh y Nelder (1989, cap. 6)

Exploración: la tasa por cuartil y por nivel



Sube con la **potencia**; baja con la **edad**

Mayor en zona **urbana**, uso **comercial** y **moto**

r = 0.82

entre edad y años de carnet: la vista marginal no separa efectos solapados

El modelo usa 5 predictores (edad, potencia, zona, uso, tipo) y estima cada efecto **ajustado por los demás**.

fig-u21-eda-modelo · u21-cor-edad-carnet

El ajuste: efectos sobre el log de la tasa

```
m_tasa ← glm(n_asistencia ~ edad_conductor + potencia_cv + zona_circulacion + uso +
tipo_vehiculo + offset(log(exposicion)), family = poisson, data = cartera)
```

Término	$\hat{\beta}$	EE	p
(Intercept)	−0.289	0.130	0.027
edad_conductor	−0.0134	0.0020	< 0.001
potencia_cv	0.0046	0.0007	< 0.001
zona: mixta	−0.164	0.061	0.007
zona: rural	−0.224	0.076	0.003
uso: comercial	0.167	0.071	0.018
tipo: moto	0.221	0.076	0.004
tipo: furgoneta	0.139	0.082	0.090

8

parámetros; el *offset* no suma ninguno

3063

gl residuales (3071 − 8)

Referencias: zona urbana, uso particular, turismo.

Exponenciar: razones de tasas (IRR)

Término	IRR	IC 95 %
edad_conductor (1 año)	0.987	[0.983, 0.991]
potencia_cv (1 CV)	1.0046	[1.0031, 1.0061]
zona: mixta	0.849	[0.752, 0.956]
zona: rural	0.799	[0.687, 0.926]
uso: comercial	1.182	[1.027, 1.356]
tipo: moto	1.248	[1.072, 1.446]
tipo: furgoneta	1.149	[0.975, 1.346]

$$\mathrm{IRR}_k = \lambda(x_k + 1, x_{-k}) \,/\, \lambda(x_k, x_{-k}) = e^{\beta k}$$

No depende del valor de partida, ni del resto de predictores, ni de la exposición.

> 1 eleva la tasa · **< 1** la reduce · **= 1** sin efecto

broom::tidy(m_tasa, exponentiate = TRUE, conf.int = TRUE)

Dos cautelas al leer las IRR

+1 CV

× 1.0046

parece nada

+10 CV

× 1.047

tasa un 4.7 % mayor

+10 años de edad

× 0.875

tasa un 12.5 % menor

1 · Continuas: un incremento con sentido

$$+c \text{ unidades} \Rightarrow \text{tasa} \times e^{(c\beta_k)} = IRR_k^c$$

2 · No todo nivel se distingue de su referencia

Furgoneta: IC [0.975, 1.346] contiene el 1 → no distinguible de un turismo con estos datos

La interpretación completa de una IRR

> «A igualdad de edad del conductor, potencia, zona y uso, la tasa esperada de asistencias de una póliza de moto es **1.25 veces** la de un turismo; es decir, un **25 % mayor** (IC 95 %: del 7 % al 45 %).»

«A igualdad»
mismo perfil en el resto: no es la vista marginal

«Tasa»
por unidad de exposición, gracias al *offset*

«Esperada»
asociación, no efecto causal

«Veces» y «%»
la misma cifra: IRR − 1

El intervalo
no contiene el 1: distinguible del ruido

tipo_vehiculomoto: IRR 1.248 [1.072, 1.446]

Predicción: el nivel de un perfil, con su margen

PERFIL

45 años · 110 CV
zona urbana · uso particular
turismo
exposicion = 1

TASA ESPERADA

0.678

asistencias en la ventana completa · IC 95 % [0.622, 0.740]

El intervalo se construye en la escala de η y se exponencia

$$\exp(\,\hat{\eta} \pm 1.96 \cdot \mathrm{EE}(\hat{\eta})\,) \rightarrow \text{nunca negativo}$$

Es el margen de la **tasa media** del perfil; **una** póliza concreta varía, además, según la propia Poisson.

predict(type = "link", se.fit = TRUE) · marginaleffects::predictions()

Mismo efecto relativo, distinto efecto absoluto

El mismo cambio, de turismo a moto, sobre dos perfiles de partida muy distintos (exposicion = 1):

Perfil	Turismo	Moto	Cociente	Diferencia
Bajo riesgo · 65 años, 80 CV, rural, particular	0.362	0.451	1.248	0.090
Alto riesgo · 25 años, 160 CV, urbana, comercial	1.317	1.643	1.248	0.326

Cociente = IRR, constante

Dice **cuánto más arriesgado** es un perfil, en proporción.

Diferencia: crece con la tasa base

Dice **cuántas asistencias más** hay que cubrir.

¿Y si ajustamos lm(log((y + c) / t))?

Término	IRR Poisson	e^b, c = 1	e^b, c = 0.5
edad_conductor	0.987	0.997	0.995
potencia_cv	1.005	1.001	1.002
zona: mixta	0.849	0.967	0.944
zona: rural	0.799	0.943	0.917
uso: comercial	1.182	1.053	1.076
tipo: moto	1.248	1.060	1.094
tipo: furgoneta	1.149	1.024	1.041

Con un 65.7 % de ceros, log(y + c) aplasta los efectos hacia 1, y cambian con c.

MEDIA PREDICHA

Modelo	Media
Observada	0.443
Poisson	0.443
log, c = 1	0.394
log, c = 0.5	0.311

Jensen: E[log Y] ≤ log E[Y]. Exponenciar no devuelve la media.

¿Aporta cada predictor? Razón de verosimilitudes

Término retirado	gl	LRT	p
edad_conductor	1	45.25	< 0.001
potencia_cv	1	36.80	< 0.001
zona_circulacion	2	12.22	0.002
uso	1	5.37	0.020
tipo_vehiculo	2	9.59	0.008

El factor completo

La furgoneta sola no se distinguía de 1; el **tipo de vehículo** en conjunto sí aporta.

Poisson: $\varphi = 1$ conocida → contrastes con χ^2, no con F

drop1(m_tasa, test = "LRT")

¿Sobra tipo_vehiculo? AIC y LRT coinciden

```
m_red ← update(m_tasa, . ~ . - tipo_vehiculo)
AIC(m_tasa, m_red); anova(m_red, m_tasa, test = "LRT")
```

INFORMACIÓN

AIC completo **5163.7** · sin tipo 5169.3

ΔAIC = 5.6

a favor del modelo completo (menor es mejor)

MODELOS ANIDADOS

Diferencia de deviance **9.59** con 2 gl

p = 0.008

el mismo contraste que la fila de drop1

1.5 · BONDAD DE AJUSTE Y DIAGNÓSTICO

Deviance y χ^2 de Pearson: resumen, no veredicto

$$D = 2\,\Sigma_i\,[\,y_i \log(y_i/\hat{\mu}_i) - (y_i - \hat{\mu}_i)\,]$$

frente al modelo saturado

$$X^2 = \Sigma_i\,(y_i - \hat{\mu}_i)^2 / \hat{\mu}_i$$

discrepancias escaladas por $\mathrm{Var}(Y_i) = \mu_i$

2868.7	3102.2	3063	0.41
deviance D	Pearson X^2	gl = n − p	mediana de $\hat{\mu}_i$

La aproximación χ^2_{n-p} exige **medias esperadas altas**. Con medias bajas y muchos ceros falla: los p-valores (0.994 para D, 0.306 para X^2) **no son fiables**.

El índice de dispersión

$$\hat{\varphi} = X^2 / (n - p)$$

Si $\mathrm{Var}(Y_i) = \varphi\, \mu_i$, la Poisson es $\varphi = 1$. El índice compara la variabilidad observada con la que la Poisson admite.

N_ASISTENCIA

1.01

La Poisson basta

N_DANOS · MISMO MODELO

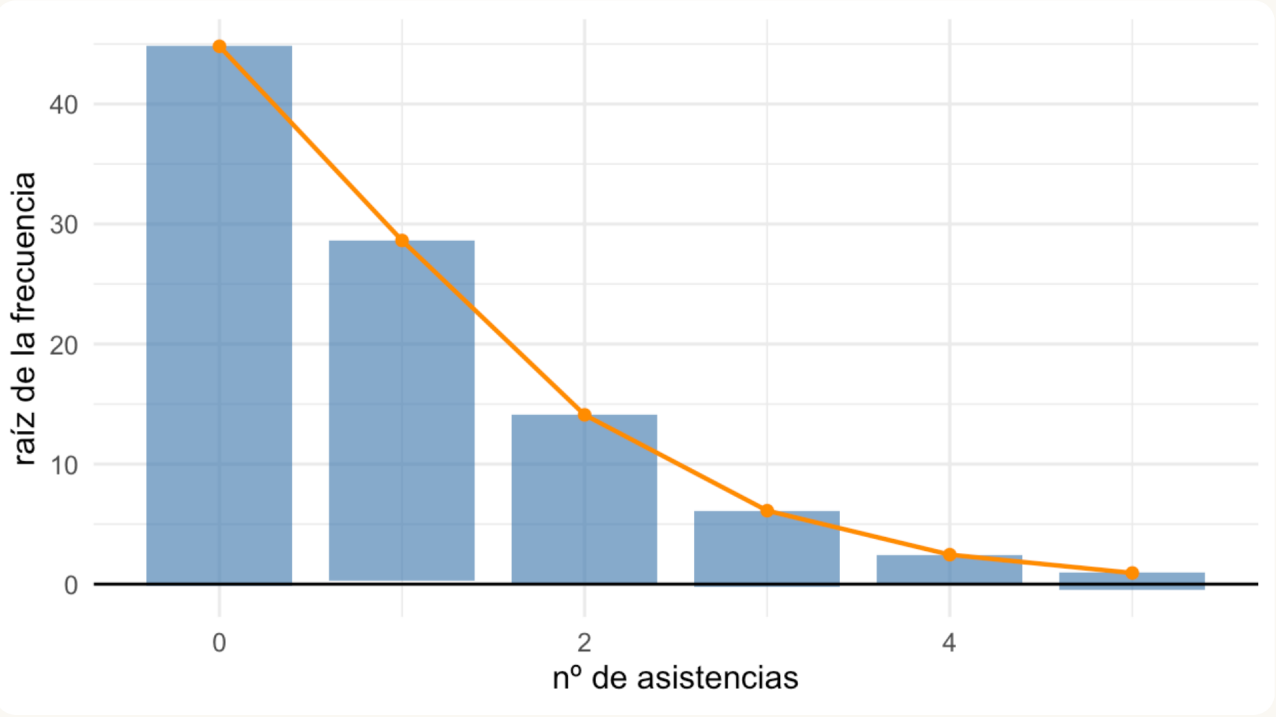
2.39

Sobredispersión → Unidad 2.3

Con $\hat{\varphi} > 1$ los errores estándar de la Poisson quedan subestimados en un factor $\approx \sqrt{\hat{\varphi}}$: intervalos demasiado estrechos.


```
sum(residuals(m, "pearson")^2) / df.residual(m)
```

El rootograma: conteo a conteo

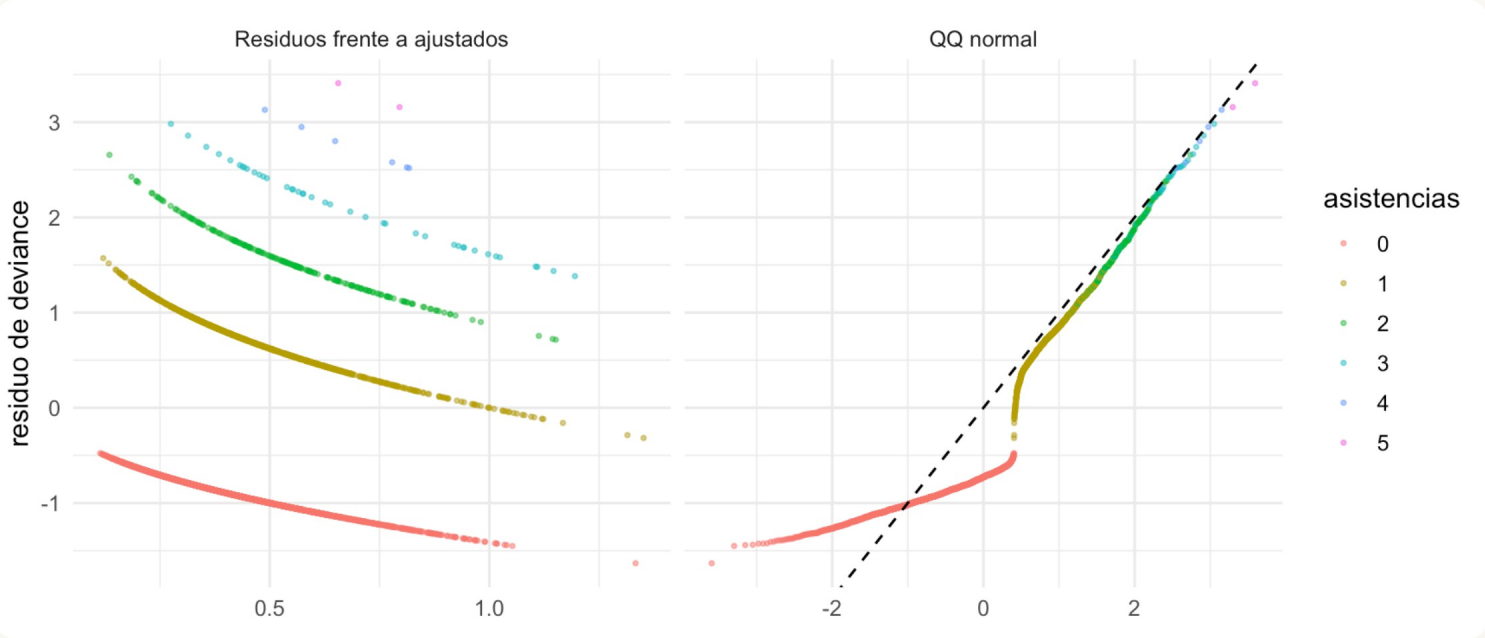


Barras: √observado, colgando de la curva √esperado. Pie en el cero = acierto.

$$E_k = \Sigma_i \, e^{(-\hat{\mu}_i)} \, \hat{\mu}_i^{\,k} / k!$$

k	Observado	Esperado
0	2018	2008
1	805	820
2	200	199
3	40	37
4	6	6
5	2	0.9

Residuos clásicos: bandas que no son un fallo



Residuos de deviance de un modelo que sabemos correcto, coloreados por y.

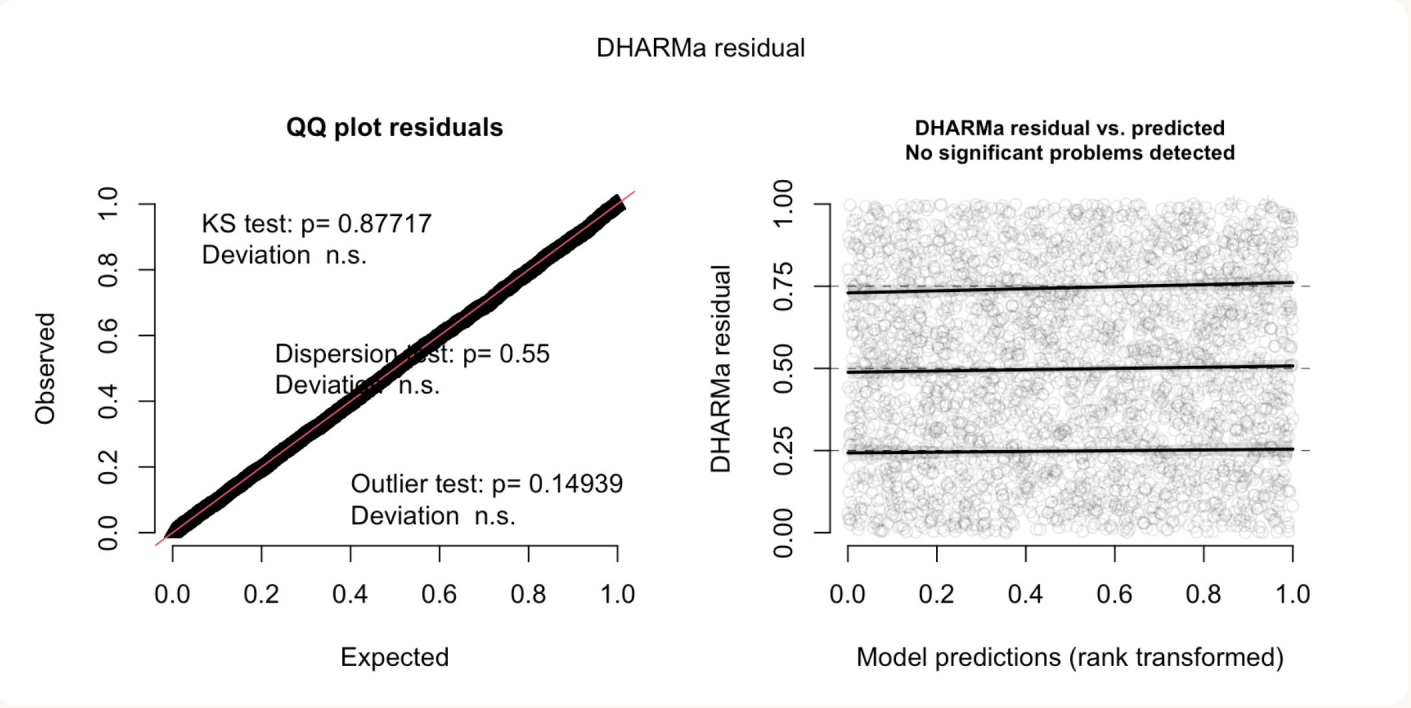
65.7 %
pólizas con y = 0

66.3 %
residuos negativos

Si $y_i = 0$: $r^P_i = -\sqrt{\hat{\mu}_i}$, $r^D_i = -\sqrt{(2\hat{\mu}_i)}$.
Siempre negativos.

fig-u21-residuos-crudos · u21-residuos-ceros

Residuos simulados: uniformes si el modelo acierta



Izquierda: QQ uniforme. Derecha: residuo frente a predicho (rangos).

CONTRASTES (P)

Uniformidad (KS)	**0.88**
Dispersión	**0.55**
Exceso de ceros	**0.76**

Índice, rootograma y DHARMa coinciden: la Poisson con *offset* es adecuada.

VALIDACIÓN CONTRA EL DGP

¿Recupera m_tasa la verdad que generó los datos?

Término	Estimado	Verdadero	Distancia (EE)
edad (por DT)	−0.184	−0.15	−1.23
potencia (por DT)	0.163	0.15	0.48
zona: mixta	−0.164	−0.18	0.26
zona: rural	−0.224	−0.30	1.00
uso: comercial	0.167	0.25	−1.16
tipo: moto	0.221	0.20	0.28
tipo: furgoneta	0.139	0.10	0.48

Todos los **signos** coinciden. Máxima distancia: **1.23 EE** < 1.96 → toda verdad cae dentro del IC 95 %.

Misma escala antes de comparar: continuas por desviación típica; zona recodificada (el DGP usa rural como referencia, R usa urbana).

El DGP incluye dos efectos pequeños que el modelo no lleva (antigüedades) → sección 1.6

Ajustar bien no es predecir bien

Modelo	Parám.	Deviance / n (entren.)	AIC	BIC
nulo	1	0.9699	5259.5	5265.6
m_tasa (5 predictores)	8	0.9341	5163.7	5211.9
riesgo (7 predictores)	10	0.9309	5157.6	5217.9
todos (17 candidatos)	24	0.9251	5167.9	5312.6

Entrenamiento: baja siempre al añadir parámetros. Es el **optimismo**: premia al más grande.

$$\text{AIC} = -2\ell + 2k$$

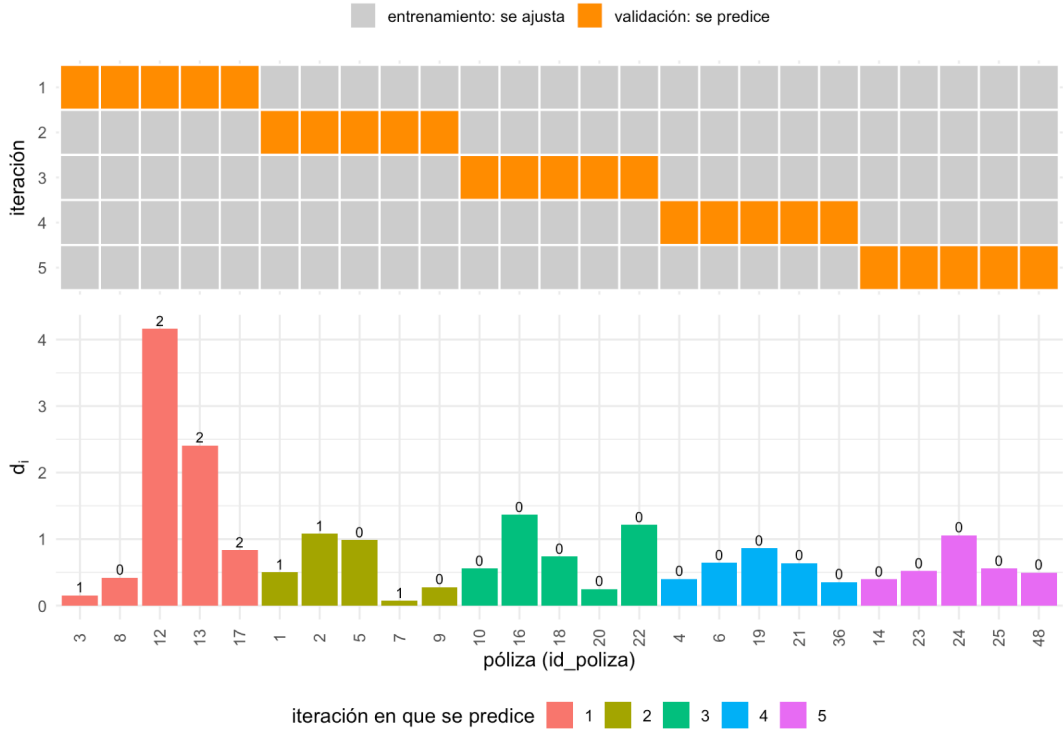
un parámetro más debe rebajar la deviance en **> 2**

$$\text{BIC} = -2\ell + k \log n$$

en **> log n = 8.03**

De m_tasa a riesgo: deviance **−10.1** con 2 parámetros. Supera 4 → el AIC elige **riesgo**; no llega a 16.1 → el BIC se queda con **m_tasa**.

Cada póliza, predicha una vez por un modelo que no la vio



Contribución de la póliza i (bloque b)

$$d_i = 2\,[\, y_i \log(y_i / \hat{\mu}_i^{(-b)}) - (y_i - \hat{\mu}_i^{(-b)}) \,]$$

$$= (r_i^{D(-b)})^2$$

Deviance de validación

$$DV = (1/n)\ \Sigma_i\ d_i$$

Si $y_i = 0$: $d_i = 2\hat{\mu}_i^{(-b)}$. Las barras altas: más asistencias de las predichas.

k = 5, m_tasa: las 3071 pólizas, una vez cada una → **DV = 0.9413**

1.6 · VALIDACIÓN CRUZADA, K = 10

Fuera de la muestra, el orden cambia

Modelo	Entrenamiento	Validación
nulo	0.9699	0.9704
m_tasa	0.9341	0.9403
riesgo	0.9309	0.9389
todos	0.9251	0.9423

Gana **riesgo**: el mismo orden que el **AIC**.

todos, el mejor en entrenamiento, **empeora** al predecir.

Del nulo al mejor, la deviance de validación baja solo **0.031 por póliza**: con dos de cada tres pólizas sin asistencias, la señal es **débil**. Eso marca todo lo que sigue.

1.6 · REGULARIZACIÓN

Un solo modelo con todos, y un precio por el tamaño de β

$$\max \ell(\beta) - \lambda P(\beta)$$

$\lambda = 0$: el glm() de siempre. Al subir λ, los coeficientes se **encogen**: más sesgo, menos varianza. El intercepto no se penaliza.

Norma L1: suma de valores absolutos

$$\|\beta\|_1 = \Sigma_j \, |\beta_j|$$

Norma L2: longitud euclídea

$$\|\beta\|_2 = (\Sigma_j \, \beta_j^{\,2})^{\wedge}\tfrac{1}{2}$$

Ridge · $P = \|\beta\|_2^2$

Encoge todos; **ninguno** llega a cero. Reparte, no selecciona.

Lasso · $P = \|\beta\|_1$

Algunos llegan a **cero exacto**: selecciona mientras ajusta.

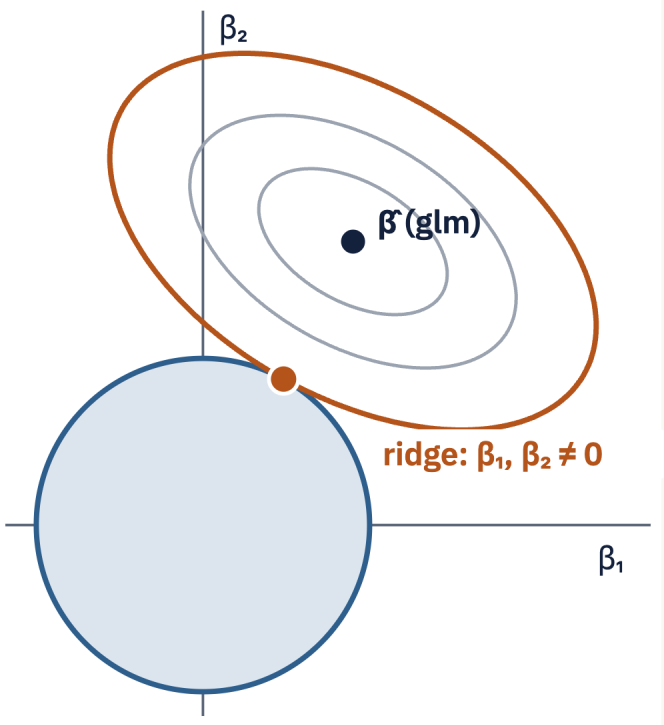
Elastic-net

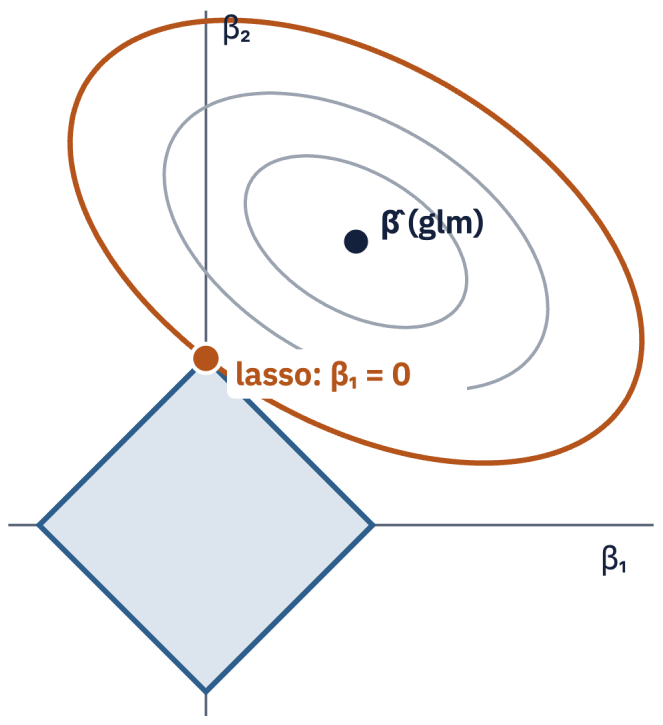
$P = \alpha\|\beta\|_1 + (1 - \alpha)/2 \, \|\beta\|_2^2$

$\alpha = 1$ lasso; $\alpha = 0$ ridge. Conserva **juntos** los correlacionados.

Hoerl y Kennard (1970) · Tibshirani (1996) · Zou y Hastie (2005)

La bola L2 es redonda; la bola L1 tiene esquinas





Penalizar con λ equivale a

$$\max \ell(\beta) \text{ con } \|\beta\| \leq t$$

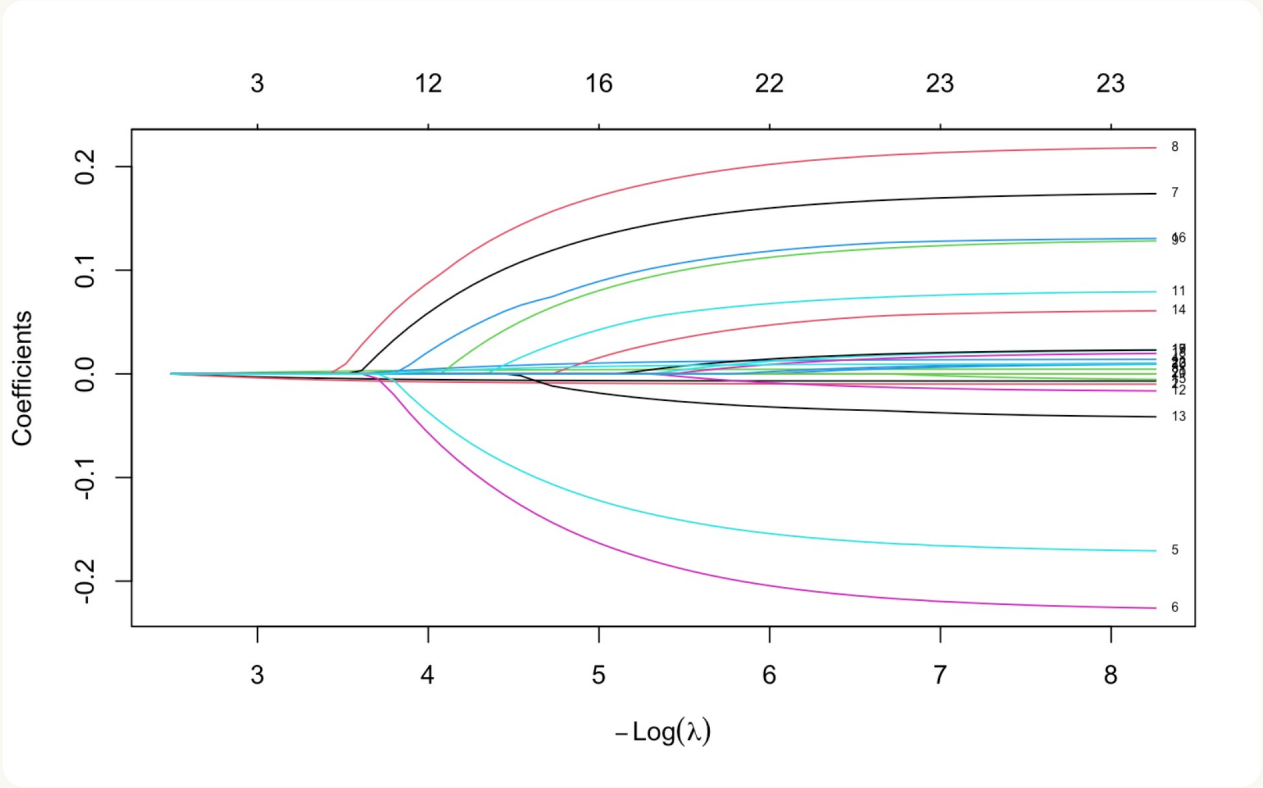
t se encoge al crecer λ

Elipses: contornos de la verosimilitud alrededor de β̂. La solución es el primer punto de la bola que tocan.

El rombo tiene los **vértices sobre los ejes**: la elipse suele tocarlo en uno, y ahí un coeficiente vale **0**.

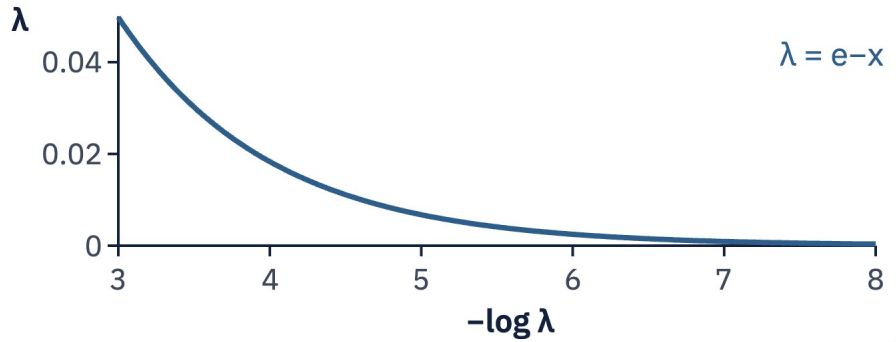
Hastie et al. (2009, sec. 3.4) · esquema con dos coeficientes

La ruta del lasso: quién entra y cuándo



Eje: **−log λ**. A la izquierda, castigo fuerte: todos en 0. Hacia la derecha entran. Arriba: cuántos son ≠ 0.

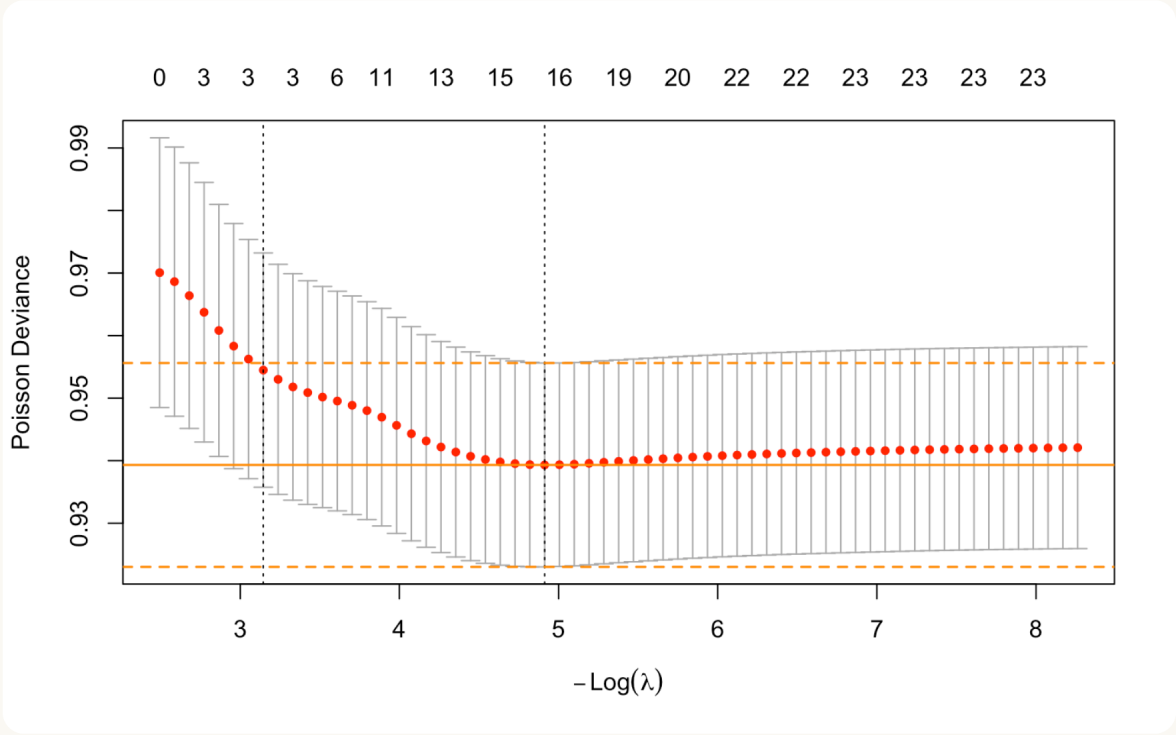
x: matriz 3071 × 23; **offset** en su argumento; predictores **estandarizados**.



Friedman et al. (2010) · fig-u21-ruta-lasso

1.6 · ELEGIR Λ

De dónde salen λ.min y λ.1se



Eje −log λ · puntos: izq. **λ.1se**, der. **λ.min**

Rejilla de valores de λ. Para **cada λ**, validación cruzada con K = 10 bloques:

· deviance de validación de cada bloque: **DV_b(λ)**

· su promedio: **DV(λ)** · su error estándar: **EE(λ)**

$\lambda.\min = \operatorname{argmin} DV(\lambda)$

el punto más bajo: **línea naranja continua**

$\lambda.1se = \max\{\lambda : DV(\lambda) \le DV(\lambda.\min) + EE(\lambda.\min)\}$

el λ más grande cuyo punto queda bajo la **discontinua superior**

Figura 9 (fig-u21-cvglmnet) · Hastie et al. (2009, sec. 7.10)

1.6 · LA REGLA DE DECISIÓN

Elegir λ depende de para qué se quiere el modelo

λ.min si importa **predecir**

El λ de menor DV: el que mejor predice según la estimación.

16 de 23 columnas · DV **0.9393**, como «riesgo» (0.9389), sin que nadie le diga cuáles eran

λ.1se si se quiere una **lista corta**

El mayor λ a menos de 1 EE del mínimo: el modelo más corto que no se distingue de él.

3 columnas · DV **0.9545**, entre el nulo (0.9704) y los modelos con predictores

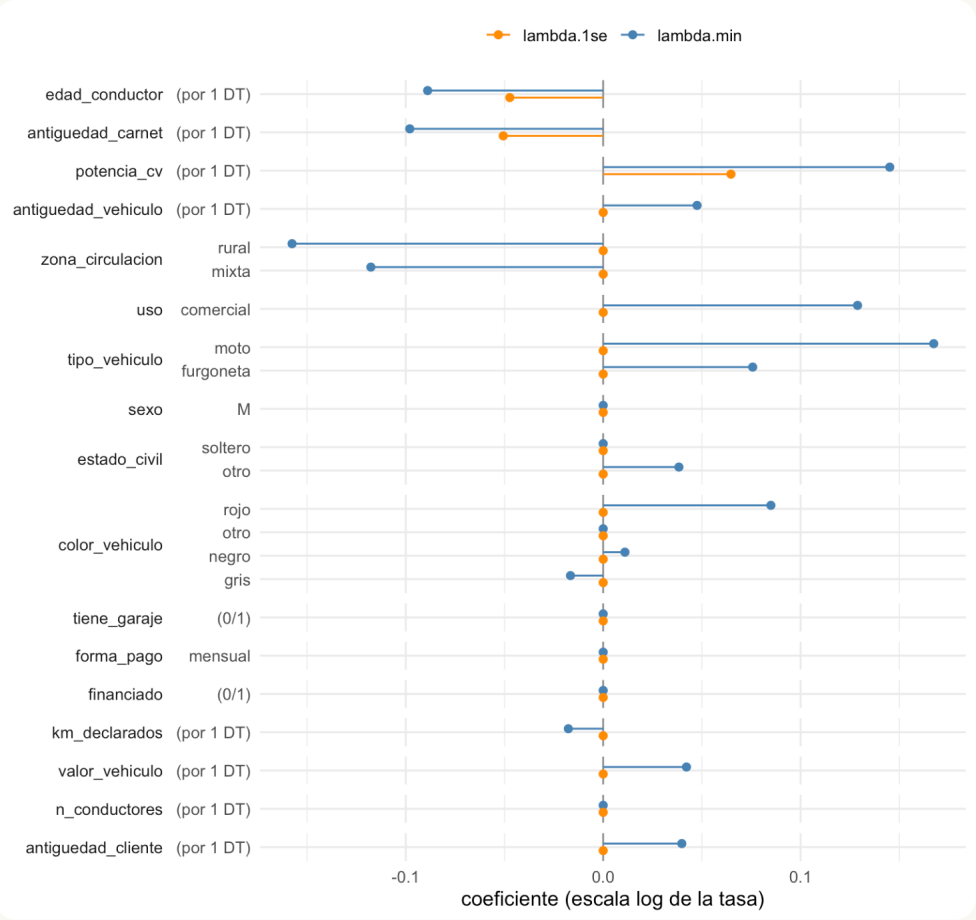
Castigo	DV λ.min	≠ 0	DV λ.1se	≠ 0
ridge (α = 0)	0.9396	23	0.9562	23
elastic-net (α = 0.5)	0.9392	16	0.9548	3
lasso (α = 1)	0.9393	16	0.9545	3

Diferencias entre castigos ≪ **EE**: ninguno domina. El ridge no selecciona.

Señal débil: 1 EE (0.0163) es el **52 %** de toda la mejora posible sobre el nulo (0.0315); el modelo de λ.1se conserva solo el **51 %**.

lasso_ref · cv.glmnet(alpha = 0, 0.5, 1, foldid = bloque)

Elegir por variables y validar el procedimiento entero



El lasso trabaja **por columnas**: con λ.min parte **estado_civil** (1 de 2 indicadoras) y **color_vehiculo** (3 de 4). Una indicadora a 0 **funde** su nivel con la referencia.

Un factor entra o sale **entero**: entra si sobrevive alguna de sus indicadoras. Luego, **glm()** sin castigo.

Criterio	Var.	Lasso	CV ingenua	CV anidada
λ.min	12	0.9393	0.9382	0.9412
λ.1se	3	0.9545	0.9457	0.9465

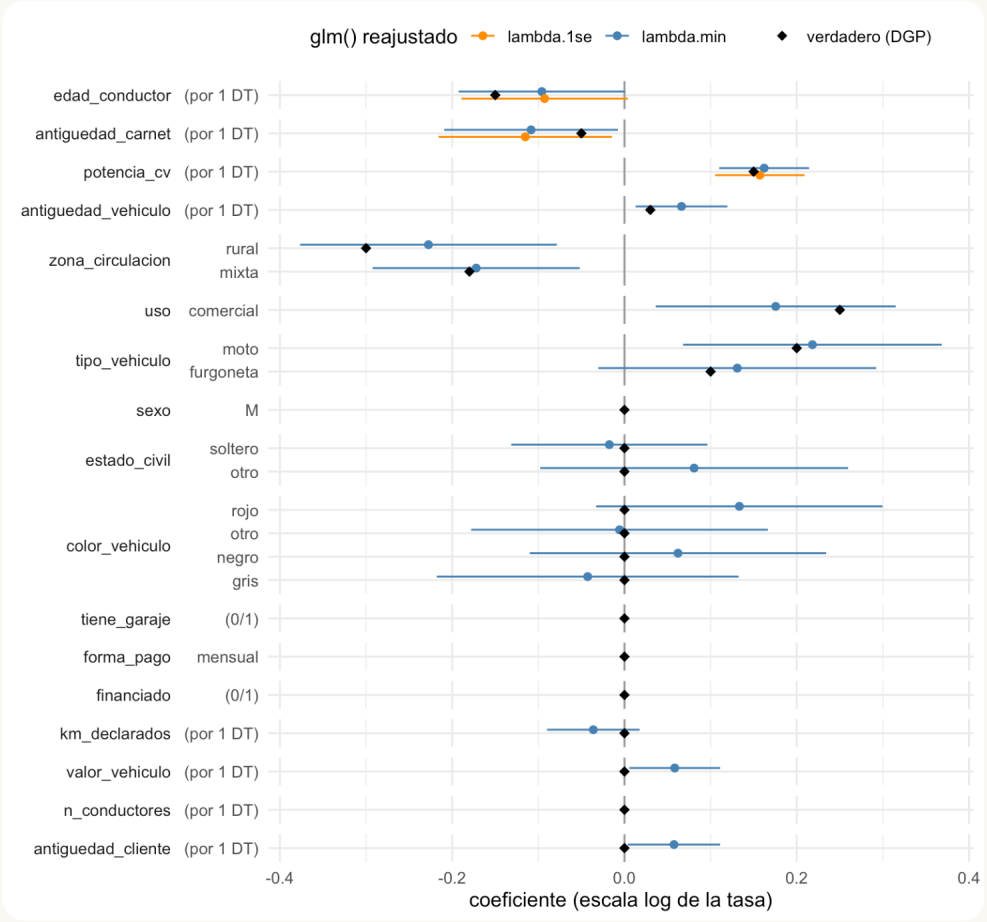
Ingenua: eligió con todos los datos → optimista.

λ.min: reajustar **empeora**, el ruido recupera su tamaño.

λ.1se: reajustar **mejora**, aunque no llega a m_tasa (0.9403).

fig-u21-coef-lasso · reajuste · Harrell (2015) · Yuan y Lin (2006)

El lasso criba, no adivina el modelo verdadero



Columnas	En el DGP	λ.min	λ.1se
activas	9	9	3
nulas	14	9	0

Fallan por **lados opuestos**: λ.min mete ruido, λ.1se pierde zona, uso y tipo de vehículo. La verdad queda entre los dos.

Columnas activas: **todos los IC cubren** la verdad, con los dos criterios.

Con λ.min, **2 nulas** (valor del vehículo, antigüedad como cliente) con IC que **excluye el 0**: inferencia tras la selección.

Señal débil: la mayor nula (0.133) supera al efecto real de la antigüedad del vehículo (0.03).

Correlación: edad y carnet se reparten el efecto.

fig-u21-reg-validacion · resumen_sel · coeficientes por DT

CIERRE

Lo que hay que llevarse

1

Tasa, no recuento

offset log(t): coeficiente fijado a 1, sin parámetro nuevo

2

IRR = e^{β}

Efecto multiplicativo y constante; continuas con un incremento con sentido

3

La frase completa

A igualdad de..., tasa esperada, asociación, con su IC

4

Predecir con margen

Intervalo en escala η y exponenciar; tasa media ≠ póliza concreta

5

Seleccionar

Pocos términos: LRT y AIC. Muchos candidatos: validación cruzada y lasso

6

¿Basta la Poisson?

Índice ≈ 1, rootograma y DHARMa; los residuos clásicos engañan con medias bajas

TAREA DEL ESTUDIANTE · 2.1

Preguntas 1 a 3 y 16 sobre la cartera de tu equipo

P1 · RITMO Y PERFILES

Tasa de **n_siniestros** con offset; IRR con IC y la frase completa. exposicion en **décadas**; sin **sexo**.

P2 · PREDICCIÓN

Ritmo esperado, con intervalo, de una **póliza nueva**; exposicion = 0.1 es un año.

P3 · ¿MISMO PATRÓN?

Repite con **n_asistencia** y dibuja las IRR de las dos respuestas lado a lado.

P16 · QUÉ VARIABLES CONSERVAR

CV en 10 bloques y **lasso** con cv.glmnet; justifica λ (min o 1se) y da IRR con un glm() reajustado.

Diagnóstico

Índice, rootograma y DHARMa. Si el índice se dispara, IC de P1–P2 demasiado estrechos (Unidad 2.3).

Validación, solo al final

attr(cartera, "verdad"); en P16, qué activos conserva el lasso y qué ruido descarta.