CASO 2 · CONTEOS Y TASAS · UNIDAD 2.2

Modelos log-lineales para tablas de contingencia

Cuando el dato es la celda: asociación, jerarquía de modelos, paradoja de Simpson y tablas de cambio

Modelos Lineales Generalizados · Grado en Ciencia de Datos e IA · UMH

PUNTO DE PARTIDA

Del dato-póliza al dato-celda

Unidad 2.1 · la póliza

- Una fila por póliza
- Respuesta: n_asistencia (un conteo)
- Se lee en IRR (cocientes de tasas)

Unidad 2.2 · la celda

- Una fila por combinación de factores
- Respuesta: Freq (pólizas en la celda)
- Se lee en odds ratios

```
tab <- xtabs(~ zona_circulacion + asistencia, data = cart_tab)
d <- as.data.frame(tab) # una fila por celda, columna Freq
glm(Freq ~ zona_circulacion * asistencia, family = poisson, data = d)
```

Lo que **no** cambia es la maquinaria: sigue siendo un GLM de Poisson.

Agresti (2015, cap. 7) · McCullagh y Nelder (1989, cap. 6)

LA DIRECCIÓN DE LA ASEGURADORA PREGUNTA

A · ASOCIACIÓN (2.1 A 2.3)

¿Se asocia la zona de circulación con que una póliza pida asistencia? Y con más factores en juego, ¿quién se asocia con quién?

B · CAMBIO (2.4)

El bonus-malus se reevalúa cada año: ¿cómo se mueven las pólizas de un nivel a otro?

La tabla zona × asistencia

Zona	Sin	Con	Total	% con
urbana	883	528	1.411	37,4
mixta	729	341	1.070	31,9
rural	406	184	590	31,2
Total	2.018	1.053	3.071	

De 3.071 pólizas a **6 números**: para esta pregunta, la tabla es un estadístico suficiente.

La proporción con asistencia **baja** de la zona urbana a la mixta y la rural.

¿Diferencia real o azar? Hace falta un modelo.

Datos: cartera del Caso 2 · asistencia = «con» si n_asistencia > 0

2.1 · DOS VÍAS

Tres esquemas de muestreo… y por qué da igual

Esquema	Cómo se recoge	Qué queda fijo	Distribución
Poisson	se cuenta lo que llega en una ventana	nada (n aleatorio)	Poisson independientes
Multinomial	se fija n y se clasifica	el gran total	multinomial
Multinomial-producto	se fija el tamaño de cada grupo	marginales de un factor	multinomial por fila

Nuestra cartera es **multinomial**: tenemos las pólizas que tenemos y las clasificamos. Ajustar como Poisson independientes («Poisson subrogado») da las mismas estimaciones, ajustados y deviances.

Regla práctica: fija en el modelo lo que estaba fijo en el diseño

Total fijo → intercepto. Marginales de un factor → su efecto principal. Esos términos **no se contrastan**; por eso el modelo más simple es la independencia, no el nulo.

Christensen (2025, § § 1.4–1.5, 3.5) · Dunn y Smyth (2018, § 10.4.3)

2.1 · DOS VÍAS

El modelo log-lineal de dos vías

$$\log \mu_{ij} = \lambda + \lambda^{A}_{i} + \lambda^{B}_{j} + \lambda^{AB}_{ij}$$

$N_{ij} \sim \text{Poisson}(\mu_{ij})$ independientes · A = zona (I = 3) · B = asistencia (J = 2) · primer nivel de cada factor = referencia

Término	Qué recoge	Parámetros	En la tabla
λ	el total n	1	1
λ^{A}_{i}	el marginal de zona	I – 1	2
λ^{B}_{j}	el marginal de asistencia	J – 1	1
λ^{AB}_{ij}	la asociación: lo único que preguntamos	(I – 1)(J – 1)	2
Total	modelo saturado	IJ	6

Independencia = quitar λ^{AB}: 4 parámetros, 6 – 4 = **2 gl**, y $\hat{\mu}_{i\square} = n_{i+}\, n_{+\square} / n$ (total de fila ŭ total de columna / n).

Notación clásica: aquí λ son parámetros, no la tasa de la Unidad 2.1

2.1 · DOS VÍAS

¿Hace falta la interacción? El contraste de independencia

11,43
G^2 de razón de verosimilitudes

11,44
X^2 de Pearson

2
grados de libertad

0,0033
p-valor: se rechaza la independencia

```
anova(m_ind, m_sat, test = "LRT") # G² = deviance residual de m_ind
chisq.test(tab2, correct = FALSE) # X² = suma de residuos de Pearson al cuadrado
```

¿Es fiable la aproximación χ^2?

Pide frecuencias **esperadas** ≥ 5. Menor esperada: **202,3**. Sí.

A diferencia de la Unidad 2.1

Allí fallaba (conteos pequeños, muchos ceros). Aquí el ajuste absoluto vuelve a valer.

LRT entre m_ind (independencia) y m_sat (saturado)

Leer la asociación: de las frecuencias al odds ratio

$\pi_i = \mu_{i2} / (\mu_{i1} + \mu_{i2})$ → $\text{odds}_i = \mu_{i2} / \mu_{i1}$ → $\text{OR}_i = \text{odds}_i / \text{odds}_1 = \exp(\lambda^{AB}_{i2})$

Zona	Pr(con)	odds	OR frente a urbana [IC 95 %]	Cociente de prob.
urbana	0,374	0,598	1 (referencia)	1
mixta	0,319	0,468	0,782 [0,661; 0,925]	0,852
rural	0,312	0,453	0,758 [0,617; 0,929]	0,833

Zona mixta: odds un **22 %** menores, probabilidad un **15 %** menor. Con un suceso frecuente (≈ 1 de cada 3), el OR no se parece al cociente de probabilidades: comunica los dos.

broom::tidy(m_sat, exponentiate = TRUE, conf.int = TRUE)

El puente con la logística

$$\log(\mu_{i2} / \mu_{i1})$$
$$= (\lambda + \lambda^{A}_{i} + \lambda^{B}_{2} + \lambda^{AB}_{i2}) - (\lambda + \lambda^{A}_{i})$$
$$= \lambda^{B}_{2} + \lambda^{AB}_{i2}$$

λ y λ^{A}_{i} se cancelan: dicen cuántas pólizas hay en cada zona, no cómo se reparten. Lo que queda es una logística con intercepto λ^{B}_{2} y efecto de zona λ^{AB}_{i2}.

Log-lineal	coef.	Logística	coef.
(Intercept)	6,7833	—	
zona mixta	−0,1917	—	
zona rural	−0,7770	—	
asistencia con	−0,5142	(Intercept)	−0,5142
mixta : con	−0,2456	zona mixta	−0,2456
rural : con	−0,2772	zona rural	−0,2772

Si hay una respuesta clara, usa la logística. El log-lineal gana cuando el objeto es la estructura de asociación entre varias variables. Con K > 2 categorías, equivale al logit multinomial de la Unidad 1.3.

Dunn y Smyth (2018, ù10.4.6) · Christensen (2025, ù2.5)

¿Dónde está la asociación? Residuos ajustados

$$r_i\text{杏} = (n_i\text{杏} - \hat{\mu}_i\text{杏}) \,/\, \sqrt{\hat{\mu}_i\text{杏}\,(1 - h_i\text{杏})}$$

El residuo de Pearson dividido por su error estándar: bajo el modelo, ≈ N(0, 1).

- |r| > 2: la celda merece atención
- |r| > 3: discrepancia clara
- Con muchas celdas, alguna pasa de 2 por azar: mira el patrón

```
rstandard(m_ind, type = "pearson")
```

Zona	sin	con
urbana	−3,37	+3,37
mixta	+2,07	−2,07
rural	+1,77	−1,77

Bajo independencia. Zona **urbana**: más pólizas con asistencia (y menos sin ella) de las que predice la independencia.

Tres vías: ¿quién se asocia con quién?

Añadimos el tipo de vehículo. A = zona (3) · B = tipo (3) · C = asistencia (2) → **18 celdas**.

1

¿Influyen la zona y el tipo, cada uno por su cuenta, en pedir asistencia?

`[AC] y [BC]`

2

¿Están la zona y el tipo relacionados entre sí? ¿Y si las motos se concentran en la ciudad?

`[AB]`

3

¿Es la diferencia entre zonas la misma para todos los tipos de vehículo?

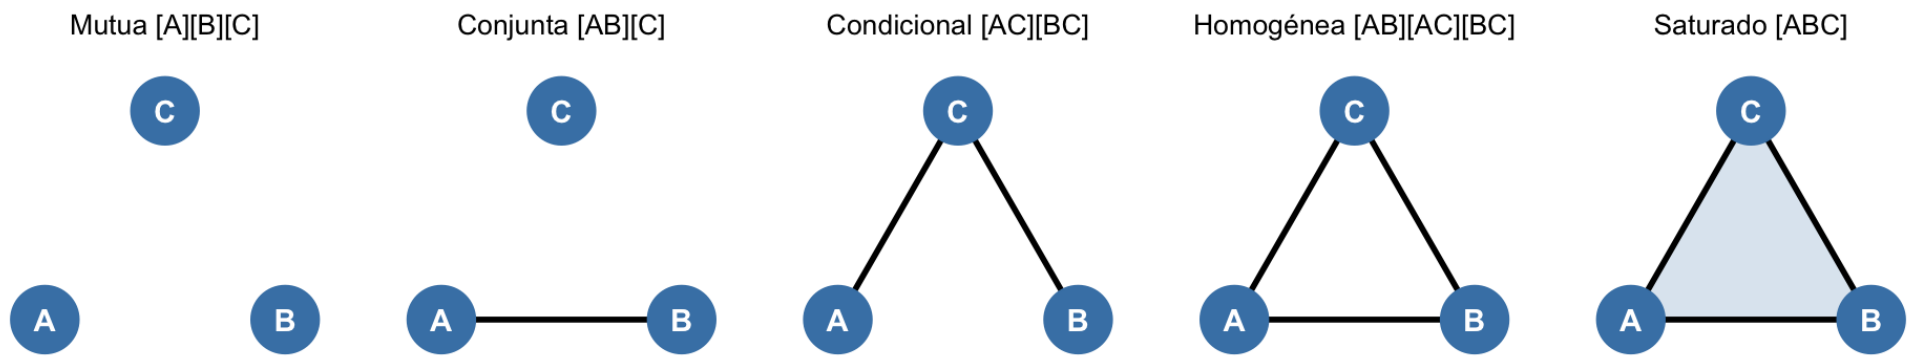
`[ABC]`

Cada pregunta es un **término** del modelo; la jerarquía de modelos las contesta a la vez.

[AB] = interacción λ^{AB} y sus efectos principales

2.2 · TRES VÍAS

Un modelo, un grafo



Cómo se dibuja

Arista = interacción doble permitida. Triángulo relleno = interacción triple.

Cómo se lee

Sin arista directa: independientes **dado** lo que hay entre ellos. Sin camino: independientes sin más.

A = zona · B = tipo de vehículo · C = asistencia

Ajustar los cinco modelos

Modelo	Notación	Fórmula en R	gl	Deviance	p (ajuste)	AIC
Mutua	[A][B][C]	A + B + C	12	27,84	0,0058	156,3
Conjunta	[AB][C]	A * B + C	8	25,73	0,0012	162,2
Condicional (elegido)	[AC][BC]	A * C + B * C	8	9,10	0,334	145,5
Homogénea	[AB][AC][BC]	(A + B + C)^2	4	7,00	0,136	151,4
Saturado	[ABC]	A * B * C	0	0	—	152,4

p (ajuste) = contraste frente al saturado. Mutua y conjunta no ajustan; sobreviven la condicional y la homogénea.

El p de la homogénea es el del término de **tres vías**: no hace falta (p = 0,136).

pchisq(deviance(m), df.residual(m), lower.tail = FALSE)

Elegir el modelo y responder a la dirección

Condicional frente a homogénea

$\Delta G^2 = 2{,}10 \cdot 4$ gl · p = 0,72 → zona × tipo [AB] sobra.

drop1() sobre la condicional

[AC]: LRT 11,43, p = 0,003 · [BC]: LRT 7,31, p = 0,026 → los dos hacen falta.

Diagnóstico

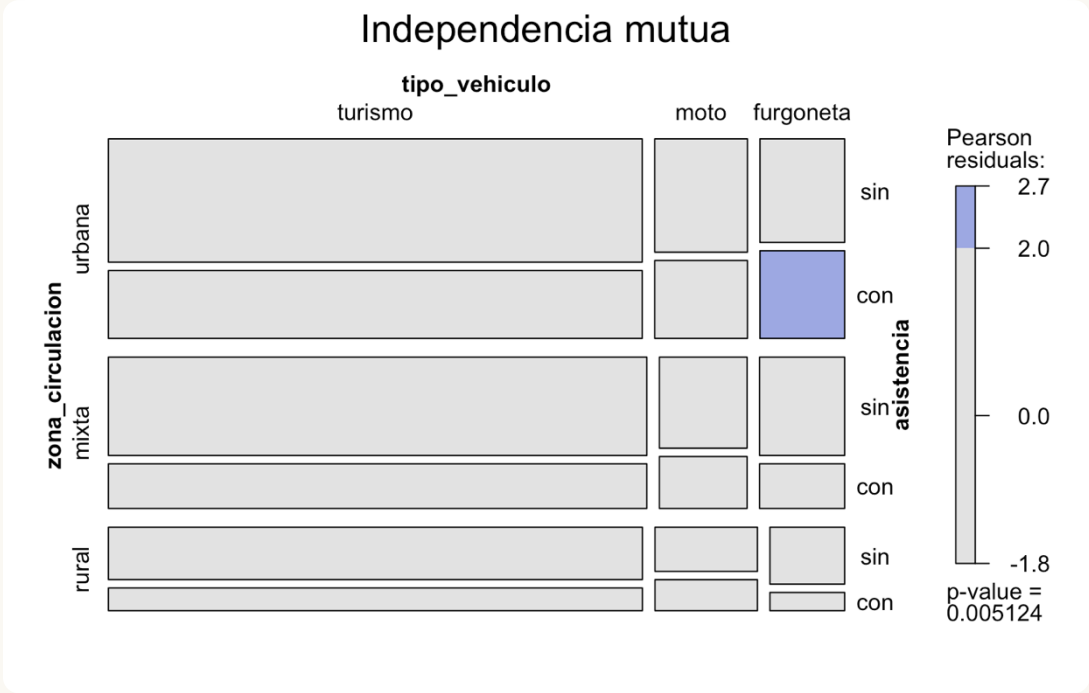
Deviance 9,10 con 8 gl; mayor residuo ajustado 2,01 en 18 celdas: ninguno destaca.

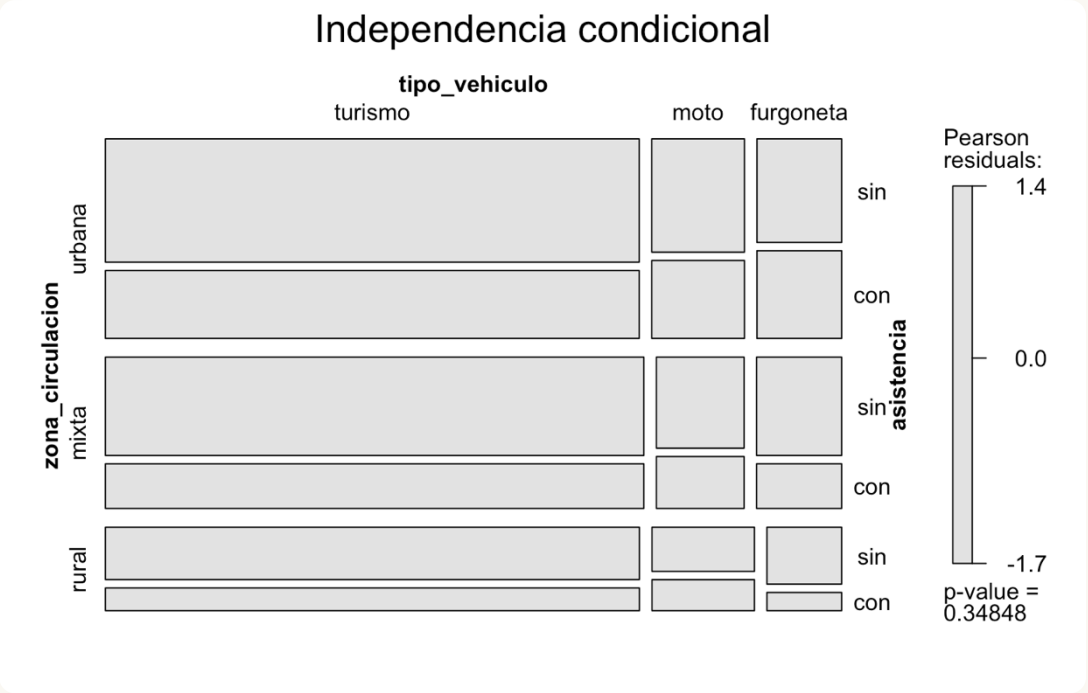
PARA LA DIRECCIÓN

«La zona y el tipo de vehículo influyen, cada uno por su lado, en que una póliza pida asistencia, y el efecto de la zona es el mismo para todos los tipos; pero, fijada la asistencia, la zona no dice nada sobre el tipo.»

anova(m_cond, m_hom, test = "LRT") · drop1(m_cond, test = "LRT")

El mosaico: qué le falta al modelo que le pasas





Independencia mutua (lo que usa vcd::mosaic si no declaras nada): furgonetas urbanas con asistencia, por encima de lo esperado.

Independencia condicional, con expected = ~ zona * asistencia + tipo * asistencia: todo gris.

vcd::mosaic(tab3, shade = TRUE, expected = ~ ...)

2.2 · TRES VÍAS · PARADOJA DE SIMPSON

¿Discriminaba Berkeley a las mujeres? (1973)

TABLA COLAPSADA · SEXO ǔ ADMISIÓN

OR = 1,84

IC 95 % [1,62; 2,09] · LRT 93,4, 1 gl, p < 0,001

Admitidos: hombres 44,5 % · mujeres 30,4 %

A IGUALDAD DE DEPARTAMENTO

OR = 0,905

IC 95 % [0,77; 1,06] · LRT 1,53, 1 gl, p = 0,22

Ninguna asociación significativa

OR hombres / mujeres, departamento a departamento:

A · 0,35	B · 0,80	C · 1,13	D · 0,92	E · 1,22	F · 0,83

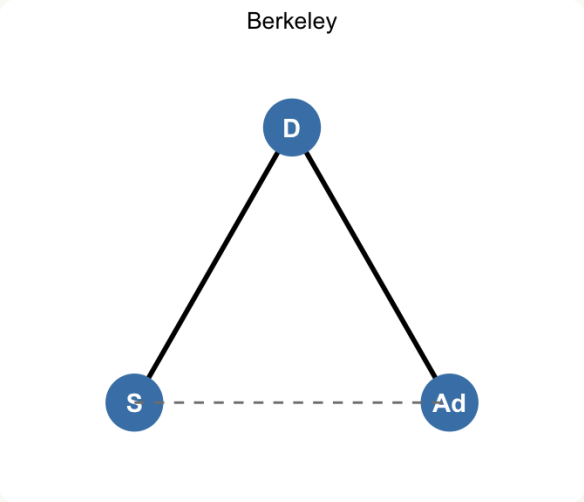
UCBAdmissions (R), 4.526 solicitudes · Bickel et al. (1975) · Christensen (2025, ù3.1)

Por qué: el camino a través del departamento

Departamento	A	B	C	D	E	F
Solicitudes de hombres (%)	30,7	20,8	12,1	15,5	7,1	13,9
Solicitudes de mujeres (%)	5,9	1,4	32,3	20,4	21,4	18,6
Admitidos en el departamento (%)	64,4	63,2	35,1	34,0	25,2	6,4

Los hombres solicitan sobre todo A y B, que admiten a la mayoría; las mujeres, C a F, mucho más selectivos.

El departamento se asocia a la vez con el sexo y con la admisión: al colapsar, ese camino indirecto se cuela en la comparación.



S = sexo · D = departamento · Ad = admisión. Discontinua: efecto directo del sexo, no significativo.

margin.table(ucb, c(2, 3)) · margin.table(ucb, c(1, 3))

¿Cuándo se puede colapsar una tabla?

Colapsar sobre C no distorsiona la asociación A–B si C es independiente de A **o** de B (condicionalmente al resto). Si C se asocia con los dos, colapsar sesga y puede invertir el signo.

Berkeley: no se puede

El departamento se asocia con el sexo y con la admisión. OR marginal 1,84 frente a condicional 0,905.

Nuestra cartera: sí

Zona ⊥ tipo | asistencia: los OR coinciden exactamente.

Zona	OR marginal	OR condicional
mixta vs urbana	0,782	0,782
rural vs urbana	0,758	0,758

Cuatro factores: subir por orden de interacción

Añadimos el uso (particular / comercial): 3 × 3 × 2 × 2 = **36 celdas**. Enumerar modelos deja de ser viable: preguntamos **hasta qué orden** hacen falta.

Orden	Fórmula	Parám.	gl	Deviance	p ajuste
1 · principales	A + B + C + D	7	29	40,31	0,079
2 · dobles	(A+B+C+D)^2	20	16	14,09	0,592
3 · triples	(A+B+C+D)^3	32	4	1,43	0,839
4 · saturado	A * B * C * D	36	0	0	—

Inquietante

Con 3 vías la independencia mutua se rechazaba (p = 0,0058); con 4, no (p = 0,079).

La deviance sube poco (27,8 → 40,3) y los gl mucho (12 → 29): la misma señal, **diluida**.

A = zona · B = tipo · C = uso · D = asistencia · Christensen (2025, § 6.2.1)

Contrastar órdenes consecutivos y podar

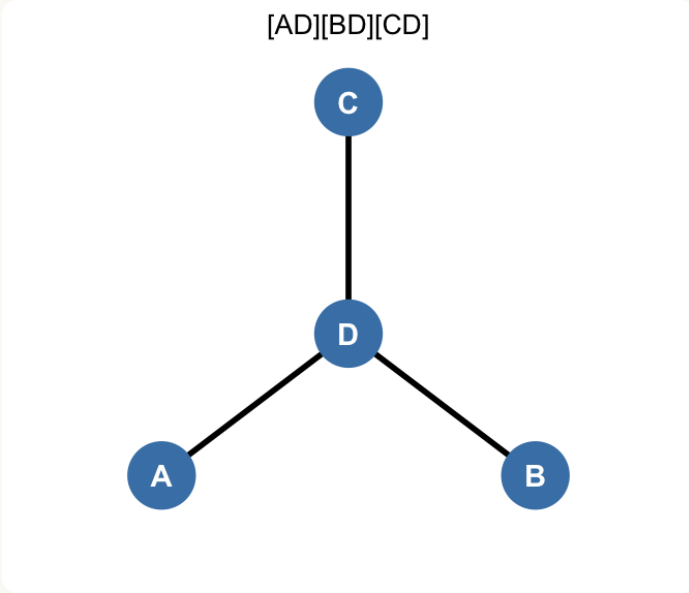
1 · ¿Aporta el orden siguiente?

Paso	ΔDeviance	gl	p
orden 1 → 2	26,22	13	0,016
orden 2 → 3	12,66	12	0,394
orden 3 → 4	1,43	4	0,839

2 · Podar dentro del orden 2 con drop1()

Dobles	p del LRT	Decisión
con la asistencia	zona 0,003 · tipo 0,027 · uso 0,035	se quedan
entre explicativas	zona×tipo 0,72 · zona×uso 0,96 · tipo×uso 0,67	fuera

Quitar las tres a la vez: 2,98 con 8 gl, p = 0,94. Modelo final: deviance 17,07 con 24 gl, p = 0,85.



[AD][BD][CD]: estrella centrada en la asistencia. Uso comercial: OR 1,24 [1,02; 1,52].

anova(m1, m2, m3, m4, test = "LRT") · drop1(m2, test = "LRT")

Celdas escasas y ceros

36	2	2	0
celdas en la tabla de 4 vías	recuento mínimo	celdas con menos de 5	celdas vacías

Si hay esperadas < 5

1. Colapsar niveles con sentido, comprobando que es legítimo
2. Renunciar al término de orden alto
3. Contrastes exactos: fisher.test(), chisq.test(simulate.p.value = TRUE), mantelhaen.test(exact = TRUE)

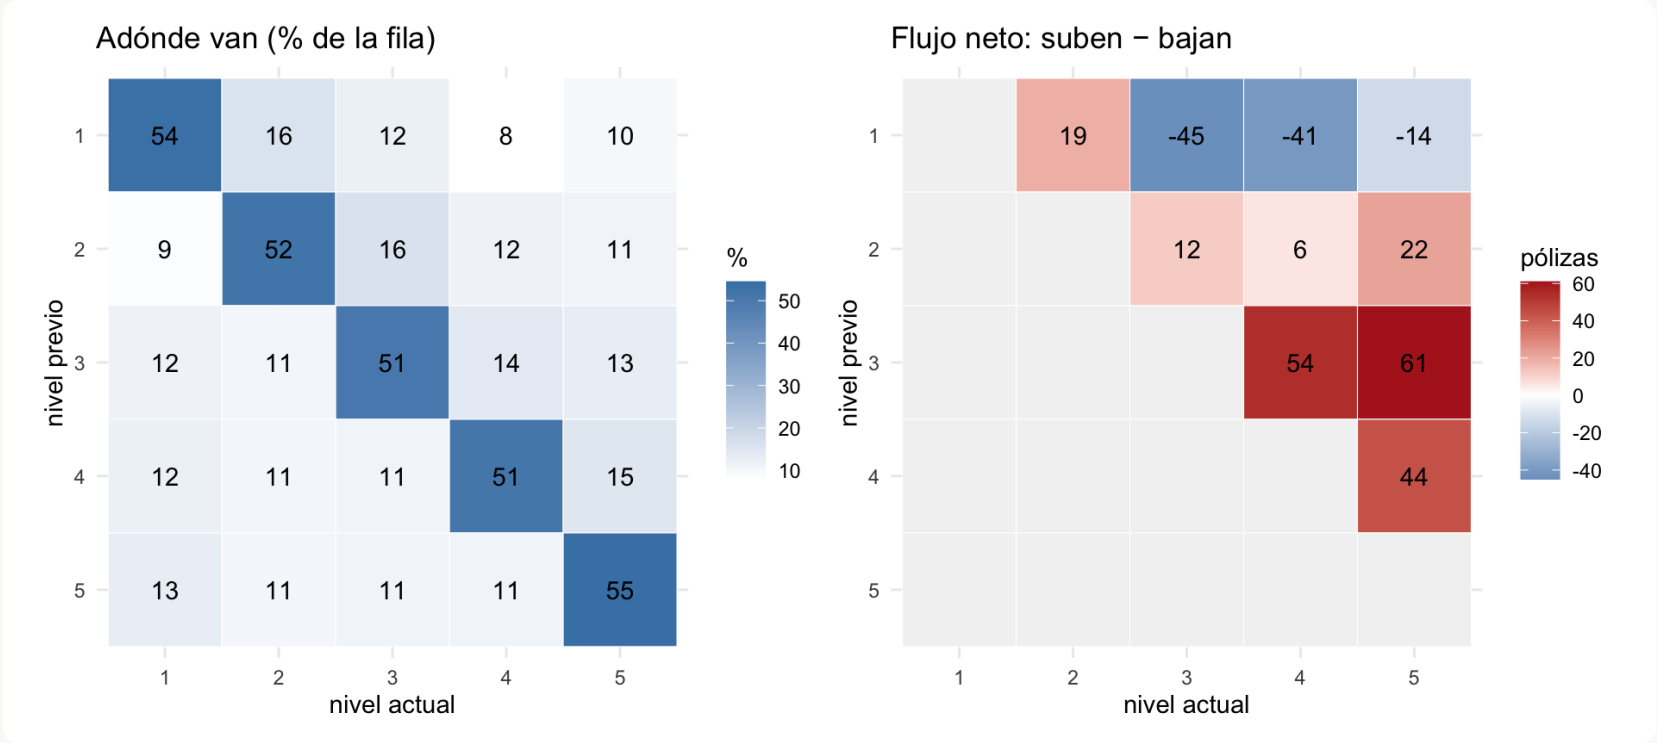
Dos tipos de cero

Muestral: la combinación es posible, no ha salido. Se estima (con EE grandes).

Estructural: imposible por diseño. Se excluye con subset = !imposible y R descuenta 1 gl por celda (cuasi-independencia).

Dunn y Smyth (2018, § 10.4.8) · Christensen (2025, cap. 14)

El bonus-malus de un año al siguiente



La **diagonal** domina: el 52,2 % de las pólizas no cambia de nivel.

Flujo neto: del 3 al 5 pasan 112 y del 5 al 3, 51 → **+61** hacia el malus.

La cartera no se desplaza en bloque: se abre hacia los extremos.

Tabla cuadrada bonus_malus_prev × bonus_malus_act · Agresti (2013, cap. 11)

Simetría, cuasi-simetría y homogeneidad marginal

Simetría · $\mu_{ij} = \mu_{ji}$

```
Freq ~ par # 10 gl
```

Cuasi-simetría · marginales libres

```
Freq ~ prev + act + par # 6 gl
```

Homogeneidad marginal · $\mu_{i+} = \mu_{+i}$

```
anova(m_sim, m_qs) # 4 gl
```

Contraste	Deviance	gl	p
Simetría	89,92	10	6×10^{-15}
Cuasi-simetría	34,28	6	6×10^{-6}
Homog. marginal	55,64	4	2×10^{-11}

Se rechazan las tres: hay **deriva**, el reparto de niveles cambia.

La cuasi-simetría tampoco ajusta: queda un flujo con sentido propio que el cambio de marginales no explica.

Significativo no es lo mismo que importante

3,007 → 3,026
nivel medio: deriva de 0,020

25,8 % · 22,0 %
empeoran · mejoran

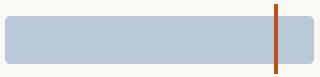
$p \approx 2 \times 10^{-11}$
homogeneidad marginal

Nivel	1	2	3	4	5
Año previo (%)	14,9	20,7	28,4	20,8	15,2
Año actual (%)	17,6	20,0	23,5	20,0	18,9
Cambio (puntos)	+2,6	−0,7	−4,8	−0,8	+3,7

La media apenas se mueve porque el cambio está en el **reparto**: el nivel 3 pierde y ganan los dos extremos. La cartera se **polariza**. El tamaño depende de cómo se mida.

Medias sobre las pólizas: mean(nva – niv), mean(nva > niv)

Aprovechar el orden: una escalera de modelos

Modelo	Términos añadidos	Deviance (escala log) · línea: p95 de $\chi^2 \approx 24$	Deviance · gl
Independencia referencia	`Freq ~ prev + act`		1.579,5 · 16
Asociación uniforme $e^{\beta} = 1{,}317$ (OR local)	`+ I(i * j)`		1.023,8 · 15
Inercia $e^{\delta} = 4{,}10 \cdot e^{\beta} = 1{,}031$	`+ I(i * j) + diagonal`		38,65 · 14
Inercia + paso hacia arriba ajusta: p = 0,42	`+ diagonal + sube1`		**14,39 · 14**

La uniforme gana 555,7 puntos con 1 gl… y sigue sin ajustar. **¿Aporta el término?** (LRT entre modelos) no es lo mismo que **¿ajusta el modelo?** (deviance frente a sus gl).

Todos con prev + act · Christensen (2025, cap. 7) · Agresti (2013, caps. 9–10)

El modelo que ajusta: inercia y paso hacia arriba

$$\log \mu_{ij} = \lambda + \lambda^{P}_{i} + \lambda^{A}_{j} + \delta \cdot I(i = j) + \gamma \cdot I(j = i + 1)$$

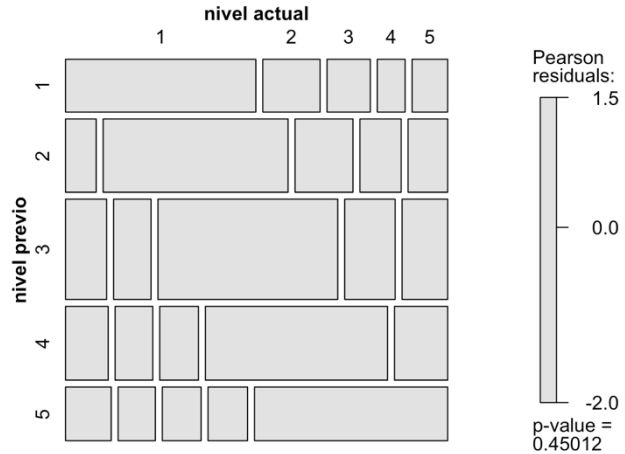
$e^{\delta} = 4{,}76$

[4,40; 5,16] · quedarse es casi 5 veces más frecuente que un cambio cualquiera

$e^{\gamma} = 1{,}41$

[1,25; 1,59] · subir exactamente un nivel es un 41 % más frecuente que otro cambio

- Ajusta: deviance 14,39 con 14 gl, p = 0,42; AIC 196,0 frente a 220,3
- Sobran el gradiente (p = 0,91) y «bajar un nivel» (p = 0,19)
- Residuos: 1 de 25 celdas pasa de |2| (−2,35); ninguna de |3|



Mosaico con expected = frecuencias del modelo: ninguna baldosa coloreada.

glm(Freq ~ prev + act + diagonal + sube1, family = poisson)

Qué esperar el año próximo

Nivel	Actual	Próximo	IC 95 %	IP 95 %
1	539	573	534–613	519–629
2	615	610	571–652	554–665
3 · baja	723	662	623–702	606–720
4	615	599	561–639	545–655
5 · sube	579	627	586–670	569–685

Cómo

$P(j \mid i) = \hat{\mu}_{i\square} / \hat{\mu}_{i+}$ y $n_{próx} = n_{act} \cdot P$

IC: 5.000 coeficientes simulados de $N(\hat{\theta}, \hat{V})$.

IP: además, reparto multinomial de cada nivel.

Supuestos: cartera cerrada y reglas de transición estables.

El nivel 3 sigue vaciándose y el 5 sigue creciendo: en los dos, el IC deja fuera la cifra actual.

MASS::mvrnorm(1, coef(m), vcov(m)) · rmultinom()

VALIDACIÓN

Validación contra el proceso generador (DGP)

Tablas de contingencia

El DGP sortea zona, tipo y uso por separado, y cada uno afecta a la asistencia: una estrella, justo [AC][BC] y [AD][BD][CD].

Odds ratio	DGP	Estimado [IC 95 %]
mixta vs urbana	0,785	0,782 [0,661; 0,925]
rural vs urbana	0,701	0,758 [0,617; 0,929]
moto vs turismo	1,243	1,320 [1,060; 1,640]
furgoneta vs turismo	1,142	1,186 [0,939; 1,492]
comercial vs particular	1,339	1,245 [1,017; 1,521]

Los cinco OR verdaderos caen dentro de su IC.

Bonus-malus

Persistencia 0,55; si cambia, salta al azar; los siniestros empujan un nivel hacia arriba.

Salto	Observado	Al azar
1 nivel	0,454	0,428
2 niveles	0,315	0,323
3 niveles	0,159	0,177
4 niveles	0,072	0,072

Inercia + empujón de un paso = diagonal + sube1.

attr(cartera, "verdad") · R/dgp_conteos.R

CIERRE

Lo que hay que llevarse

1

La celda es el dato: glm(Freq ~ ..., poisson). Fija en el modelo lo que fijó el diseño.

2

La asociación es la interacción: se lee como OR y coincide con la logística.

3

Con tres o más factores: jerarquía → grafo → frase de independencia condicional.

4

No colapses sobre un factor asociado con los otros dos: Simpson puede invertir el signo.

5

Con muchos factores, por orden de interacción; y mira la ocupación de las celdas.

6

Separa «¿aporta?» de «¿ajusta?», y da siempre el tamaño del efecto.

ESTUDIO DE CASO · UNIDAD 2.8

Tu tarea: preguntas P4, P5 y P19

P4

¿Qué factores se asocian con tener un siniestro, y cómo se relacionan entre sí?

tipo, zona y combustible × tuvo_siniestro · cinco modelos y grafo · órdenes consecutivos y drop1() · OR marginal frente a condicional

P5

¿Cómo se mueven las pólizas entre niveles de bonus-malus, y qué implica para el negocio?

mapa de calor · simetría, cuasi-simetría, homogeneidad marginal · uniforme, inercia, indicadores de celda · proyección con IC e IP

P19

Control de calidad: ¿dicen lo mismo el log-lineal y la logística?

reajusta una asociación de P4 como logística · explica por qué deben coincidir los OR y qué se cancela

Da siempre el **tamaño** del efecto junto al p-valor y **valida** al final contra attr(cartera, "verdad").