CASO 2 · CONTEOS Y TASAS · UNIDAD 2.3

Sobredispersión

Cuando la varianza supera a la media · cómo se detecta y de dónde viene · lineal o cuadrática · quasi-Poisson · binomial negativa NB1 y NB2 · predecir la media o la cola

PUNTO DE PARTIDA

De una media que manda en todo a una varianza propia

UNIDAD 2.1 · POISSON

$E[Y] = Var[Y] = \mu$

Un solo parámetro gobierna el centro **y** la dispersión: equidispersión

UNIDAD 2.3 · SOBREDISPERSIÓN

$Var[Y] > E[Y]$

Misma media; la varianza con **estructura propia**: $\phi\mu$ o $\mu + \alpha\mu^2$

El síntoma no es que prediga mal la media: es que **miente sobre su propia precisión**.

```
glm(y ~ ..., family = quasipoisson) # Var = ϕμ
MASS::glm.nb(y ~ ...) # NB2: Var = μ + μ²/θ
```


Agresti (2015, cap. 7) · Hilbe (2014)

LO QUE LA DIRECCIÓN QUIERE SABER

Unas pocas pólizas concentran muchísimos partes

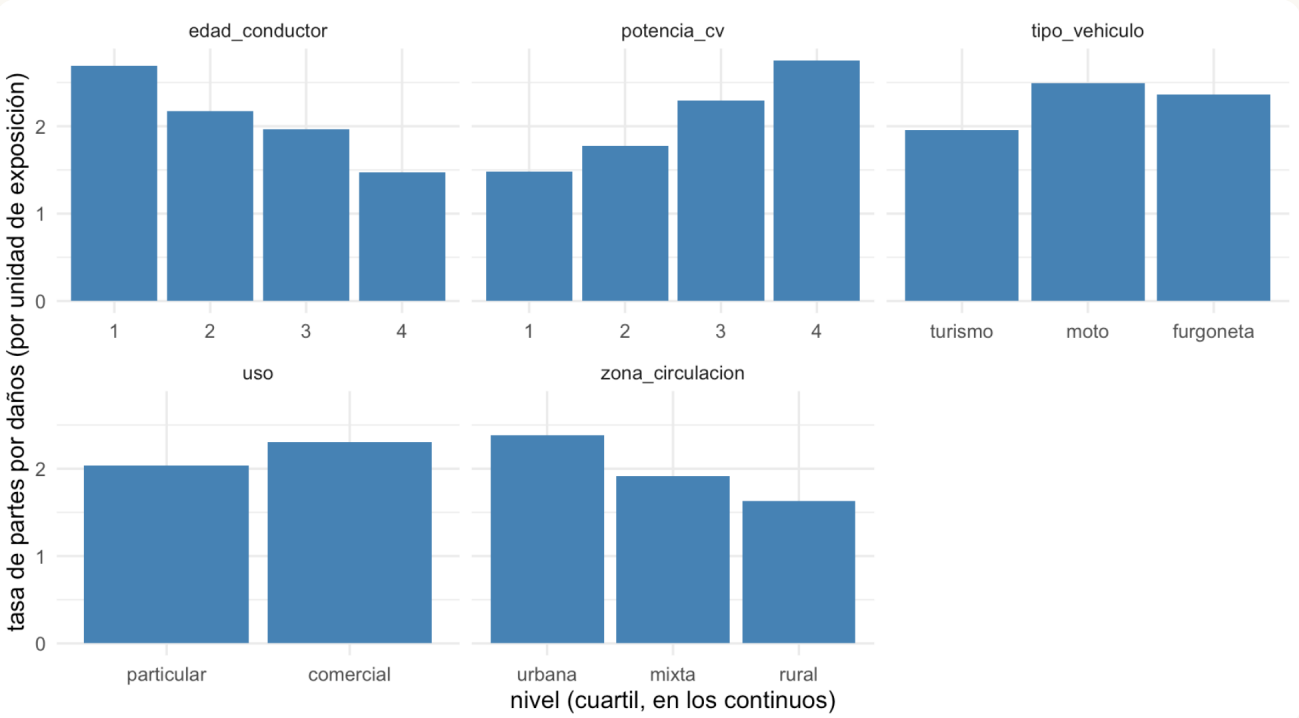
6 ¿Capta el modelo la **variabilidad** de los conteos? ¿Qué cambia —y qué no— en los **errores estándar** y en la **tarifa**?

7 ¿**De dónde** viene esa variabilidad extra? ¿Hay pólizas intrínsecamente más siniestrosas que las variables no capturan?

En la unidad trabajamos con **n_danos** (partes por daños propios); la tarea, con **n_siniestros**.

3.1 · EL PROBLEMA

Partes por daños: una Poisson con offset como referencia



La tasa **sube** con la potencia, es mayor en zona **urbana**, uso **comercial** y **moto**, y **baja** algo con la edad.

m_pois · deviance residual

6465.4

con **3063** gl: más del doble

Señal de **alarma**, no contraste: con conteos pequeños la deviance no sigue bien una χ^2.

fig-u23-eda-modelo · m_pois

El índice de dispersión mide el exceso

$$\hat{\phi} = X^2 / (n - p) = [\, \Sigma_i \, (y_i - \hat{\mu}_i)^2 / \hat{\mu}_i \,] / (n - p)$$

PEARSON

2.39

La que usamos

DEVIANCE / GL

2.11

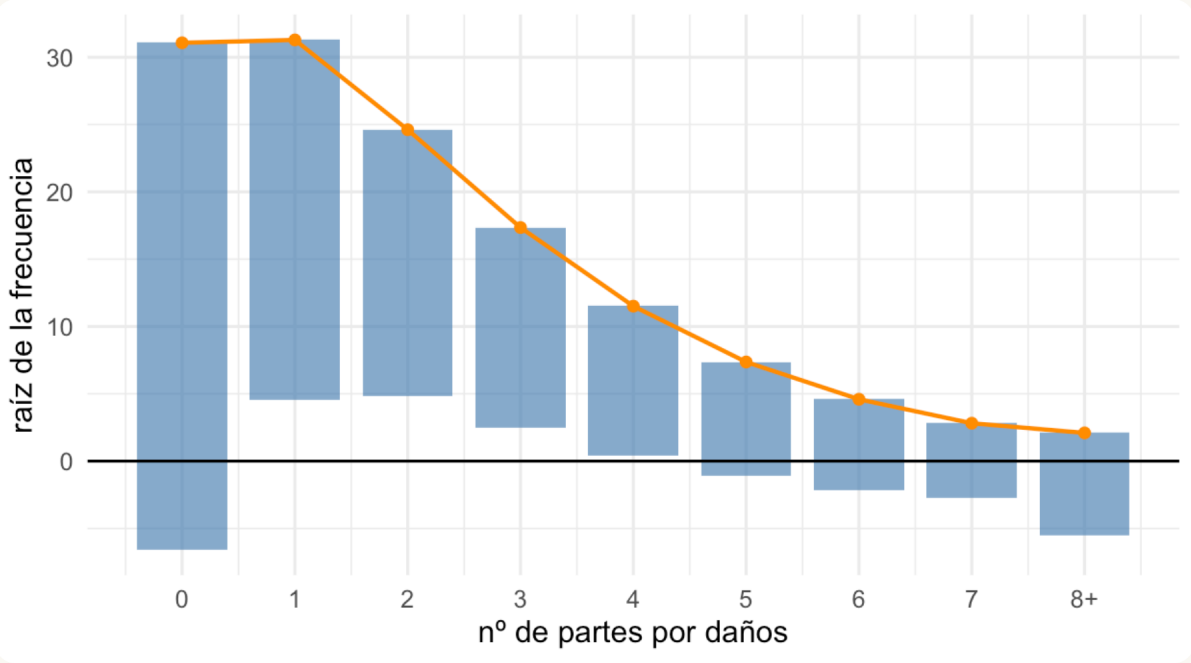
Puede rondar 1 con conteos escasos aunque haya sobredispersión

LECTURA

Muy por encima de 1: cada póliza varía bastante más de lo que la Poisson tolera.

El índice **cuantifica** el exceso, pero no dice **dónde** falla el ajuste ni **de qué forma** crece la varianza.

Acierta con el promedio, no con la forma



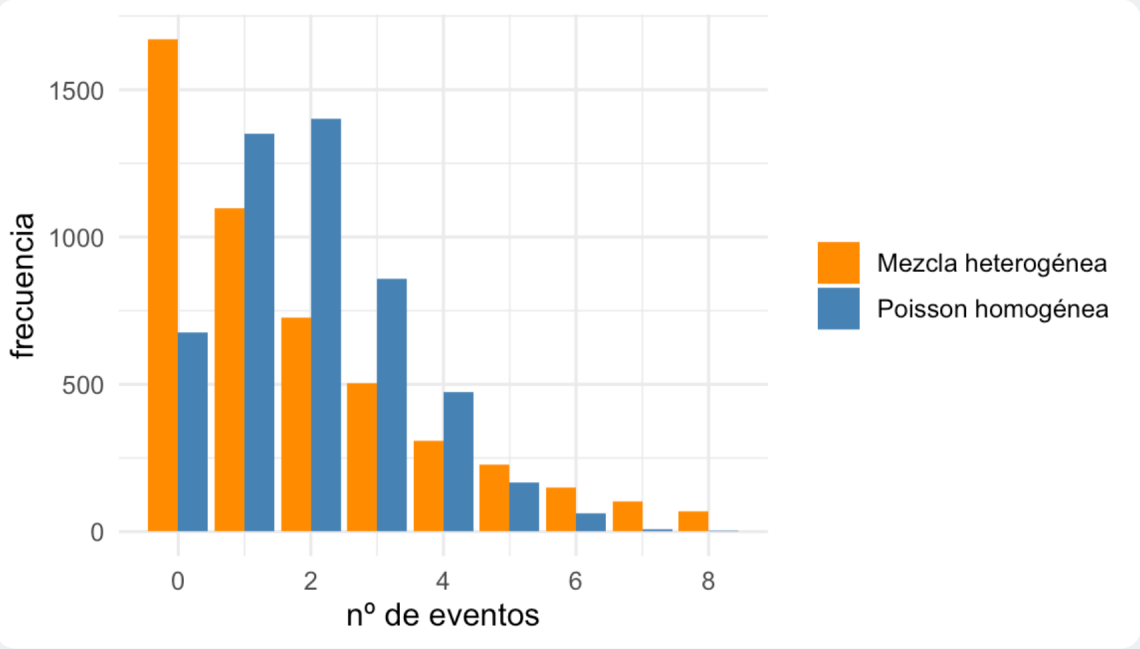
Partes	Observado	Poisson
0	1418	965.4
1	713	978.6
2	391	605.9
6	46	21.1
8 o más	58	4.4

Subestima los **ceros** y la **cola**; sobreestima los valores **intermedios**.

fig-u23-rootograma · tabla rootograma (filas seleccionadas)

3.1 · CAUSAS

Casi siempre señala estructura no modelada



Misma media (2), más varianza: así nace la sobredispersión

- **Heterogeneidad no observada**: mismo perfil, distinto riesgo real
- **Agrupamiento**: agencia, región → Unidad 2.5
- **Exceso de ceros**: pólizas que nunca reclaman → Unidad 2.4
- **Predictores omitidos** o mal especificados
- **Dependencia entre eventos**: contagio, reincidencia

fig-u23-heterogeneidad · simulación, set.seed(2026)

3.1 · CONTRASTES

¿Hay sobredispersión? Tres contrastes, un veredicto

Contraste	Dispersión	Estadístico	p
Pearson χ^2 · performance::check_overdispersion	2.393	χ^2 = 7329.571	< 0.001
Residuos simulados · DHARMa::testDispersion	2.7409	—	< 2.2e-16
Cameron–Trivedi · AER::dispersiontest	2.383	z = 12.029	< 2.2e-16

Cameron–Trivedi

H_0: $\mathrm{Var} = \mu$ frente a $\mathrm{Var} = \mu + \alpha\, g(\mu)$, $\alpha > 0$

Los tres rechazan la Poisson. Con la sobredispersión ignorada, los EE salen **≈ $\sqrt{\phi}$ veces** más pequeños de lo debido.

3.2 · ESTRUCTURAS PARA LA VARIANZA

Tres modelos, dos formas de hacer crecer la varianza

Modelo	Varianza	En una frase	Sección
quasi-Poisson	$\phi\mu$ · lineal	Corrige los EE, sin distribución propia	3.3
NB1	$\mu(1 + \alpha)$ · lineal	Misma varianza, con verosimilitud	3.4
NB2	$\mu + \alpha\mu^2$, $\alpha = 1/\theta$ · cuadrática	Mezcla Poisson–Gamma; la opción por defecto	3.4

Mezcla Poisson–Gamma

$Y \mid V \sim \text{Po}(\mu V)$, $E(V) = 1$

$\Rightarrow \text{Var}(Y) = \mu + \mu^2 \cdot \text{Var}(V)$

Ga(shape, rate): media 1 si shape = rate

NB1

$V \sim \text{Ga}(\mu/\alpha, \mu/\alpha)$

$\text{Var}(V) = \alpha/\mu$: **menor** cuanto mayor es el riesgo → Var(Y) lineal

NB2

$V \sim \text{Ga}(\theta, \theta)$

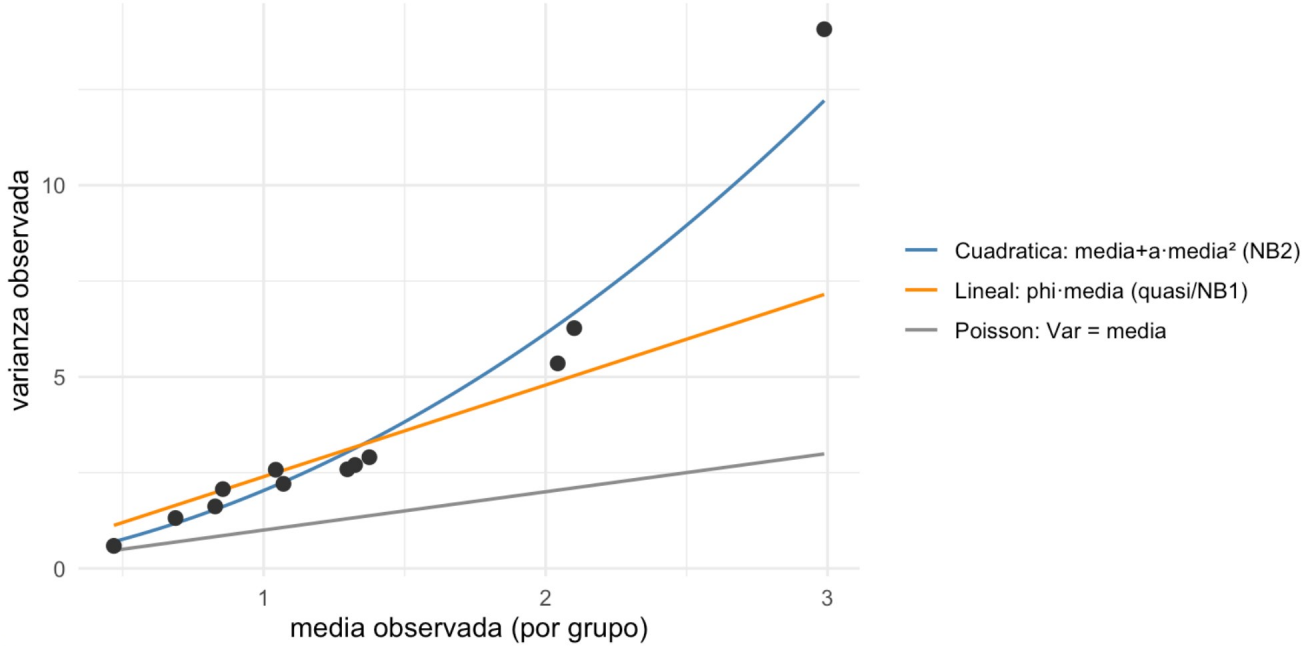
$\text{Var}(V) = 1/\theta = \alpha$: **la misma** para todas las pólizas → Var(Y) cuadrática

Lineal: la varianza crece en proporción a μ. **Cuadrática**: se dispara en las pólizas de mayor riesgo.

No es cosmético: una corrección lineal sobre una varianza cuadrática se queda corta en la **cola**, donde están las pólizas más costosas.

Hilbe (2014) · McCullagh y Nelder (1989)

La varianza crece más deprisa que la media



1 · $\hat{\mu}_i$ = fitted(m_pois)
2 · 12 grupos: ntile($\hat{\mu}$, 12)
3 · media y varianza de n_danos
4 · frente a tres formas

Todos por **encima** de Var = media. En el riesgo alto, cerca de la **cuadrática**.

Doce puntos: **sugiere** la forma, no la decide.

fig-u23-media-varianza

3.2 · CONTRASTES DE FORMA

El contraste confirma el exceso, pero no decide su forma

trafo = 1 · lineal

H_1: $\text{Var} = \mu + \alpha\mu$, $\alpha > 0$

$\hat{\alpha} = 1.383$

z = 12.029 · p < 2.2e-16

```
AER::dispersiontest(m_pois, trafo = 1)
```

trafo = 2 · cuadrática

H_1: $\text{Var} = \mu + \alpha\mu^2$, $\alpha > 0$

$\hat{\alpha} = 1.033$

z = 13.585 · p < 2.2e-16

```
AER::dispersiontest(m_pois, trafo = 2)
```

Los dos rechazan H_0: $\alpha = 0$ ($\text{Var} = \mu$). No es contradictorio: entre las pólizas, μ y μ^2 están **muy correlacionadas** y cualquiera de las dos alternativas recoge el exceso.

La forma se decide ajustando y comparando alternativas

Ajustar quasi-Poisson, NB1 y NB2 → re-diagnosticar cada una (índice, residuos, rootograma) → comparar por AIC las que tienen verosimilitud. Secciones 3.3 y 3.4.

Renunciar a la distribución: solo media y varianza

Supuestos

$$E[Y_i] = \mu_i = \exp(\eta_i)$$

$$\mathrm{Var}[Y_i] = \phi\, V(\mu_i) = \phi\, \mu_i$$

Cuasi-verosimilitud: se define por su derivada

$$\partial Q / \partial \mu_i = (y_i - \mu_i) / (\phi\, \mu_i)$$

Ecuaciones de estimación: ϕ se cancela

$$\Sigma_i\, (y_i - \mu_i)\, x_i = 0 \rightarrow \hat{\beta} \text{ idéntico al de la Poisson}$$

$\hat{\phi} = X^2/(n - p)$, el índice de 3.1: **2.393**

Covarianzas × $\hat{\phi} \rightarrow$ **EE** × $\sqrt{\hat{\phi}}$

McCullagh y Nelder (1989) · summary(m_quasi)$dispersion

Los mismos coeficientes, errores más anchos

Término	Estimación	EE Poisson	EE quasi
(Intercept)	0.6579	0.0752	0.1164
edad_conductor	−0.0150	0.0012	0.0018
potencia_cv	0.0068	0.0004	0.0007
zona mixta	−0.2082	0.0350	0.0541
zona rural	−0.3884	0.0454	0.0703
uso comercial	0.1363	0.0413	0.0638
moto	0.2679	0.0435	0.0673
furgoneta	0.1831	0.0466	0.0720

Factor de los EE

$$\sqrt{\hat{\phi}} = 1.547$$

Un efecto significativo puede dejar de serlo. Aquí ninguno: el menos claro, **uso comercial**, p = 0.033.

broom::tidy(m_pois) ⋈ broom::tidy(m_quasi)

3.3 · QUASI-POISSON · SELECCIÓN

Sin verosimilitud: QAIC y contraste F

$$\text{QAIC} = -2\ell(\hat{\beta})/\hat{c} + 2K$$

$\ell(\beta)$: log-verosimilitud de la **Poisson** con la misma media, logLik(update(m, family = poisson)) · $\hat{c}$: el $\hat{\phi}$ del modelo **más completo** de los que se comparan, común a todos · K = coeficientes + 1

$$F = [(D_0 - D_1)/(p_1 - p_0)] \,/\, \hat{\phi}_1$$

Anidados, con la cuasi-deviance D; $\approx F(p_1 - p_0, n - p_1)$ bajo H_0

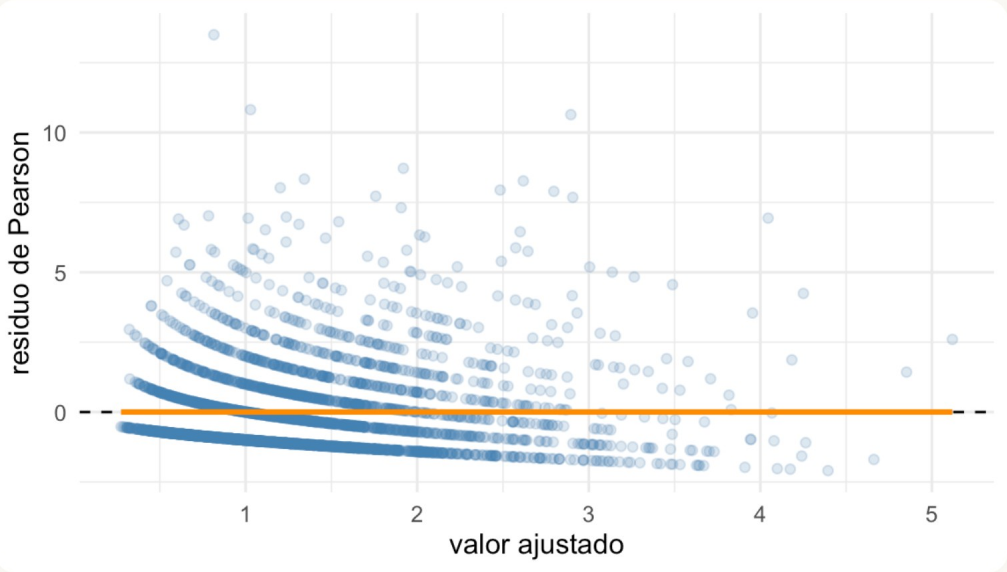
```
c_hat ← summary(m_quasi2)$dispersion   # ĉ del modelo más completo
qaic ← function(m) -2 * as.numeric(logLik(update(m, family = poisson))) / c_hat +
                   2 * (length(coef(m)) + 1)
```

Modelo	Resultado	QAIC ($\hat{c}$ = 2.38)
Efectos principales (m_quasi)	todos necesarios: p < 0.001; uso p = 0.025	4529.7
Todas las dobles (m_quasi2)	de las 10, solo edad_conductor:uso con p < 0.05 (p = 0.0498)	4547.7
m_quasi + edad_conductor:uso	anova(, test = "F"): p = 0.081	4528.7

Diferencia de QAIC de 1, por debajo del umbral de 2: por parsimonia, **sin interacciones**. Modelo elegido: m_quasi.

Burnham y Anderson (2002) · drop1(test = "F") · anova(test = "F")

La media está bien; la varianza no es ϕμ



Quintil	μ̂ medio	var_pearson
1	0.59	1.57
2	0.91	2.52
3	1.21	2.11
4	1.58	2.00
5	2.41	3.74

var_pearson = mean(residuals(m_quasi, type = "pearson")²) en cada quintil del ajustado

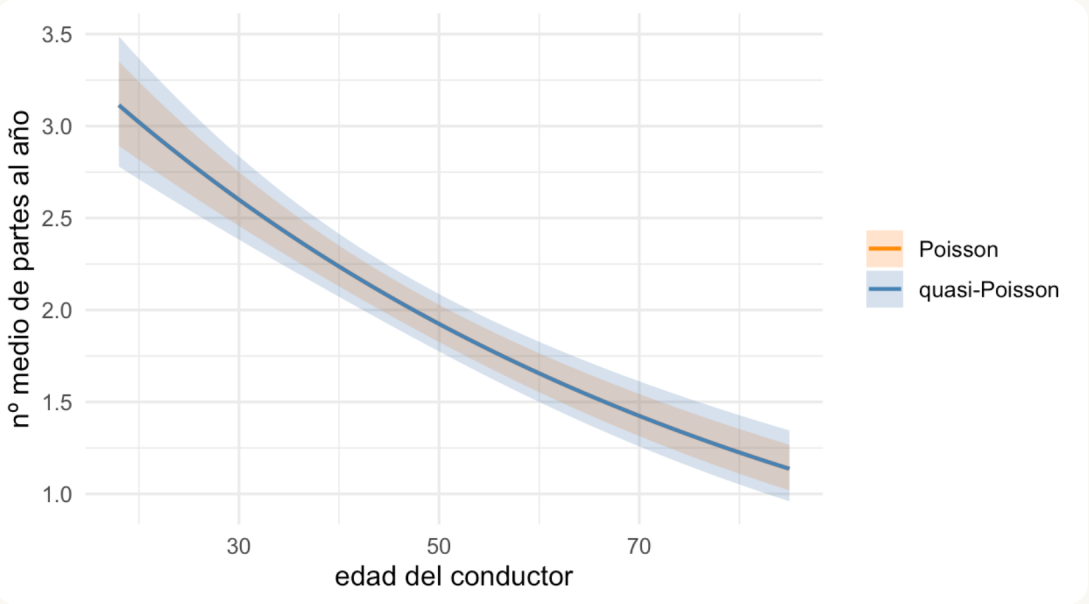
Si $\text{Var} = \phi\mu$, con $\hat{\phi} = 2.39 \approx$ var_pearson en todos

Sin distribución: **ni** contraste de bondad, **ni** rootograma, **ni** DHARMa.

La varianza crece **más deprisa** que la media: supuesto incumplido.

fig-u23-quasi-resid · r² por quintiles del ajustado

Misma curva, banda honesta… y solo la media



Turismo, particular, urbana, potencia mediana, 1 año · **45 años**

Modelo	$\hat{\mu}$	IC 95 %
Poisson	2.07	[1.97; 2.18]
quasi-Poisson	2.07	[1.92; 2.24]

$$IC(\mu_0) = \exp\left(\hat{\eta}_0 \pm 1.96 \cdot se(\hat{\eta}_0)\right)$$

$$\hat{\eta}_0 = x_0^T\hat{\beta},\ se^2 = x_0^T \hat{V} x_0,\ \hat{V} = \hat{\phi}\,(X^T\hat{W}X)^{-1}$$

$\hat{\beta}$ es asintóticamente normal; $\hat{\eta}_0$, lineal en $\hat{\beta}$, también. exp() conserva el orden y deja los límites por encima de 0.

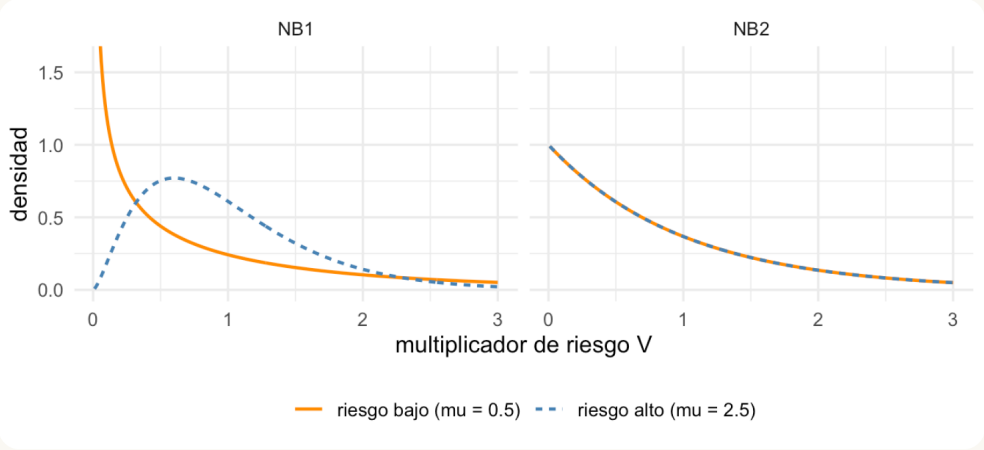
Sin distribución, **no hay probabilidades** Pr(Y = k): para eso hace falta un modelo **generativo**.

McCullagh y Nelder (1989, cap. 9) · fig-u23-quasi-pred

Una mezcla Poisson–Gamma, en dos versiones

$$Y \mid V \sim \text{Po}(\mu V),\ E(V) = 1 \Rightarrow E(Y) = \mu,\ \text{Var}(Y) = \mu + \mu^2\,\text{Var}(V)$$

	NB2	NB1
V	Ga(θ, θ)	Ga(μ/α, μ/α)
Var(V)	α = 1/θ, igual para todos	α/μ, menor con más riesgo
Var(Y)	μ + αμ² · cuadrática	μ(1 + α) · lineal
Var(Y)/μ	1 + αμ: crece	1 + α: constante



α = 1, μ de 0.5 a 2.5: índice NB2 de **1.5 a 3.5**; NB1, **2** constante.

Máxima verosimilitud, por dos caminos

NB2 · θ constante · IWLS alternado

$\ell_i(\beta, \theta) = \log[\, \Gamma(y_i + \theta) / (\Gamma(\theta)\, y_i!) \,]$

$+ \theta \log[\, \theta/(\theta + \mu_i) \,] + y_i \log[\, \mu_i/(\theta + \mu_i) \,]$

Con θ fijo es un GLM con $V(\mu) = \mu + \mu^2/\theta$: β por IWLS; luego θ; y se alterna.

NB1 · tamaño $r_i = \mu_i/\alpha$ · optimización directa

$\ell_i(\beta, \alpha) = \log[\, \Gamma(y_i + r_i) / (\Gamma(r_i)\, y_i!) \,]$

$+ r_i \log p + y_i \log(1 - p),\ p = 1/(1 + \alpha)$

μ_i entra en r_i, dentro de las Γ: no es familia exponencial. Todos los parámetros a la vez.

NB2 · MASS::glm.nb()

$\hat{\theta} = 0.975$

EE 0.053 · $\hat{\alpha} = 1/\hat{\theta} \approx 1.03$: heterogeneidad notable

NB1 · glmmTMB::glmmTMB(family = nbinom1)

$\hat{\alpha} = 1.468$

$1 + \hat{\alpha} \approx 2.5$, cerca del $\hat{\phi} = 2.39$ de la quasi

Venables y Ripley (2002) · m_nb$theta · sigma(m_nb1)

Misma varianza, otros coeficientes

Término	quasi	NB1	ΔEE rel.
edad_conductor	−0.0150	−0.0112	−0.083
potencia_cv	0.0068	0.0062	−0.082
zona mixta	−0.2082	−0.2032	−0.068
zona rural	−0.3884	−0.2711	−0.122
uso comercial	0.1363	0.0984	−0.058
moto	0.2679	0.1946	−0.045
furgoneta	0.1831	0.1318	−0.059

La NB1 **no es** la quasi-Poisson con distribución añadida.

Sus ecuaciones salen de su verosimilitud, con μ_i dentro de las Γ: **ponderan distinto** y, si la distribución no es la correcta, desplazan $\hat{\beta}$.

coef(m_quasi) · fixef(m_nb1) · ΔEE = (se_nb1 − se_quasi)/se_quasi

Vuelven el LRT y el AIC: misma conclusión

Pregunta	Resultado	AIC
Efectos principales (m_nb)	todos necesarios: p < 0.001; uso p = 0.021	9417.7
Interacción más prometedora	edad_conductor:uso, p = 0.062	—
Todas las dobles, LRT global	LR = 21.53, 19 gl, p = 0.31	9434.1

drop1() mantiene θ fijo en el del modelo mayor; **anova()** lo reestima en cada modelo.

Bondad de ajuste, en NB1 y NB2 (χ^2 de la deviance no vale con medias bajas):

· **Índice** ≈ 1: la varianza cuadra

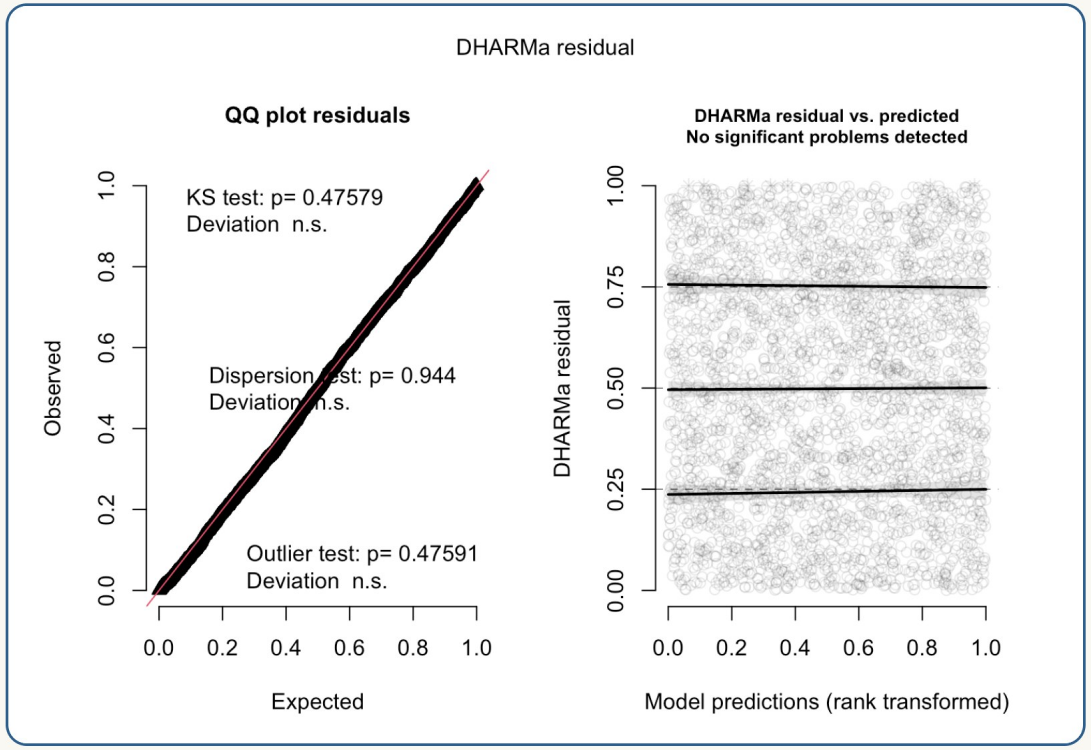
· **Residuos** (DHARMa): sin patrón

· **Rootograma**: reproduce la distribución observada

drop1(test = "Chisq") · anova(m_nb, m_nb_dobles)

Las dos bajan el índice a 1; solo la NB2 sale limpia

NB2 índice **1.012** · sin desviaciones



NB1 índice **0.974** · el cuartil inferior se hunde

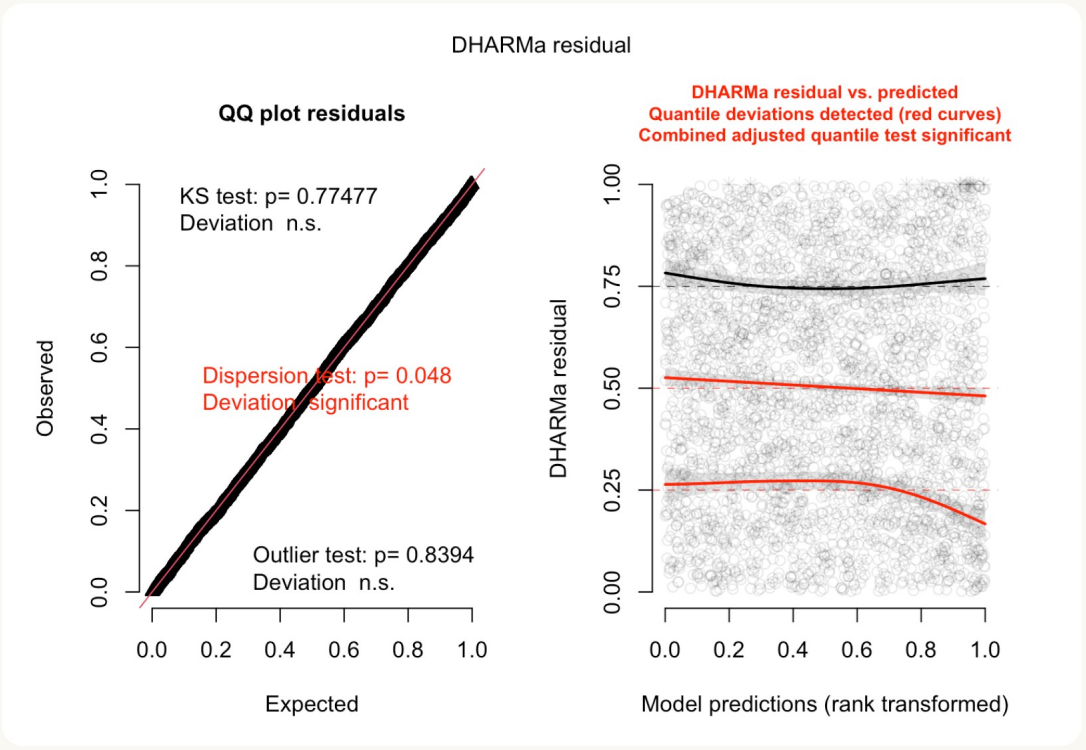
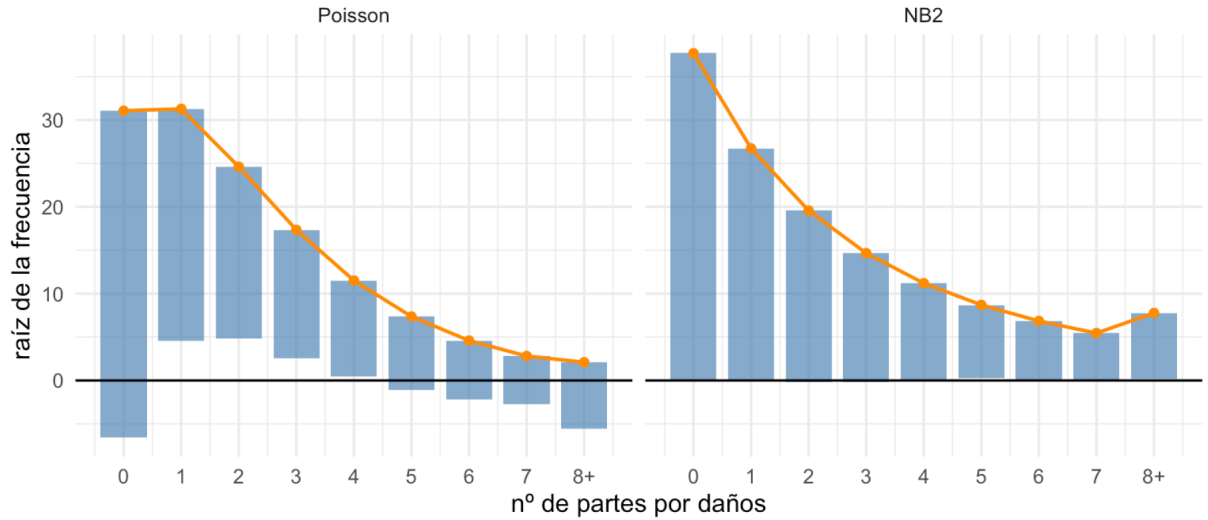


fig-u23-nb2-dharma · fig-u23-nb1-dharma · Hartig (2026)

3.4 · DIAGNÓSTICO · ROOTOGRAMA

La NB2 reproduce la forma, no solo la media



Partes	0	1	2	6	8 o más
Observado	1418	713	391	46	58
Poisson	965.4	978.6	605.9	21.1	4.4
NB2	1420.4	714.5	382.8	46.9	60.4

fig-u23-nb-rootograma · raiz_nb (columnas seleccionadas)

3.4 · LA DECISIÓN FORMAL ENTRE DISTRIBUCIONES

La NB2 gana con holgura

NB2 · 9 PARÁMETROS

9417.7

AIC · cuadrática

NB1 · 9 PARÁMETROS

9487.7

AIC · lineal

POISSON · 8 PARÁMETROS

10765.9

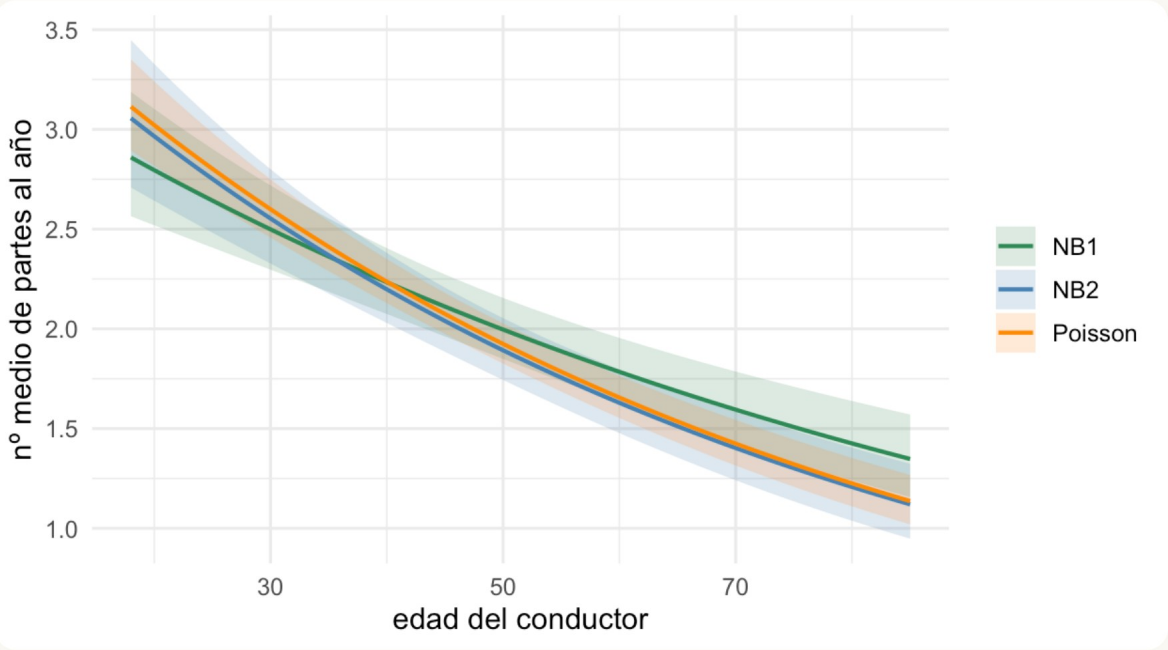
AIC

Poisson ⊂ NB2 ($\theta \to \infty$): **LR = 1350.2**; p prácticamente nulo, dividido entre 2 por el **borde**.

La quasi-Poisson **no entra**: su QAIC (4529.7) está en otra escala.

AIC(m_pois, m_nb1, m_nb) · Burnham y Anderson (2002)

La NB2 sigue a la Poisson; la NB1 aplana la edad

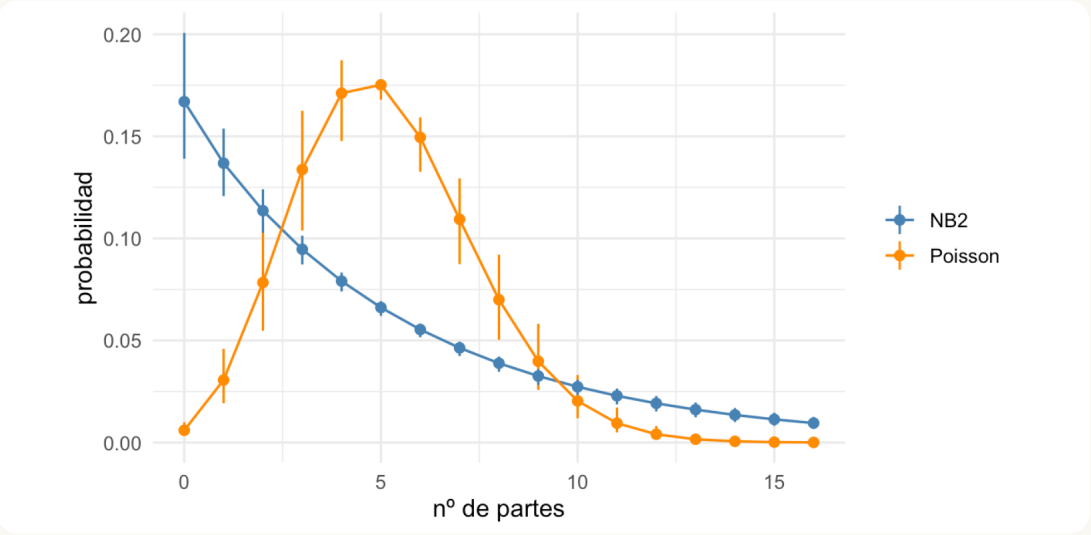


Edad	Poisson	NB1	NB2
25	2.80	2.64	2.75
45	2.07	2.11	2.04
65	1.54	1.69	1.51

NB2 a los 45: IC **[1.89; 2.21]**, tan ancho como el de la quasi.

3.4 · PREDICCIÓN DE LA DISTRIBUCIÓN

Casi la misma media, colas muy distintas



Póliza de mayor riesgo · 4000 réplicas

	Poisson	NB2
Media	5.12	5.14
Pr(Y = 0)	0.006	0.167
IC 95 %	[0.003; 0.010]	[0.139; 0.201]
Pr(Y ≥ 10)	0.036	0.170
IC 95 %	[0.020; 0.064]	[0.123; 0.223]
IP 90 %	2 a 9	0 a 17

Simulación paramétrica, b = 1, …, 4000 · en la Poisson, lo mismo sin θ

1 · PARÁMETROS

$\beta^{(b)} \sim N(\hat{\beta}, \hat{V})$ · $\theta^{(b)} \sim N(\hat{\theta}, se^2)$

por separado: independientes en la NB2

2 · MEDIA

$\mu^{(b)} = t \cdot \exp(x'\beta^{(b)})$

3 · PROBABILIDADES

$p_k^{(b)} = Pr(Y = k \mid \mu^{(b)}, \theta^{(b)})$

percentiles 2.5 y 97.5 → IC 95 %

4 · CONTEO

$y^{(b)} \sim NB(\mu^{(b)}, \theta^{(b)})$

percentiles 5 y 95 → IP 90 %

Para la **prima media** coinciden; para la **cola** (reservas, percentiles altos) la Poisson **infravalora el riesgo extremo**.

fig-u23-pred-dist · Lawless (1987) · simulación paramétrica

3.5 · CONCLUSIONES

¿Capta la Poisson la variabilidad? No. La NB2, sí

POISSON

$\hat{\phi} = 2.39$

Corta en los ceros y en la cola

QUASI-POISSON

$1.57 \rightarrow 3.74$

Corrige los EE, pero la varianza no es $\phi\mu$

NB2

$\hat{\phi} = 1.012$

Reproduce la distribución y gana por AIC (9417.7)

La elección apenas cambia la **prima media**, pero sí la **cola**: en la póliza de mayor riesgo, Pr(Y ≥ 10) pasa de **0.036** con la Poisson a **0.170** con la NB2.

3.5 · CUÁNDO CADA UNA

Una receta para conteos sobredispersos

Modelo	Varianza	¿Distribución?	¿AIC/LRT?	Cuándo
quasi-Poisson	$\phi\mu$ · lineal	No	No (QAIC)	Solo corregir EE
NB1	$\mu(1 + \alpha)$ · lineal	Sí	Sí	Varianza lineal
NB2	$\mu + \mu^2/\theta$ · cuadrática	Sí	Sí	Lo habitual

1–2

Poisson con offset; índice, rootograma, DHARMa. ¿$\hat{\phi} \approx 1$? Fin.

3–4

¿Ceros, grupos o heterogeneidad? Cameron–Trivedi y media–varianza.

5

Ajusta y **re-diagnostica**; AIC entre los que tienen verosimilitud.

6–7

IRR con EE corregidos; predice media o cola; **valida**.

¿Exceso de ceros? → **Unidad 2.4**. ¿Agrupamiento? → **Unidad 2.5**. A veces lo que parece sobredispersión es eso.

3.5 · VALIDACIÓN CONTRA EL DGP

A ciegas, elegimos el modelo que generó los datos

DGP

$\theta = 1$

Mezcla Poisson–Gamma: una NB2

NB2 AJUSTADA

$\hat{\theta} = 0.975$

EE 0.053: el 1 queda a menos de un EE

CAMERON–TRIVEDI

$\hat{\alpha} = 1.033$

trafo = 2, frente a 1/θ = 1

No solo un modelo que encaja: **la forma correcta** (cuadrática) y su parámetro, recuperados con criterios internos a los datos.

attr(cartera, "verdad")$theta_nb · m_nb$theta

CIERRE

Lo que hay que llevarse

1

Miente sobre su precisión

$\hat{\beta}$ razonables, EE ≈ $\sqrt{\phi}$ veces demasiado pequeños

2

Medir, ver, contrastar

Índice de Pearson, rootograma y Cameron–Trivedi

3

La forma importa

Lineal o cuadrática: se decide ajustando y comparando

4

Quasi: solo media y varianza

Mismos $\hat{\beta}$; sin AIC, rootograma ni DHARMa

5

NB2 = Poisson–Gamma

Heterogeneidad no observada con distribución propia

6

Media o cola

Para la prima media coinciden; para el riesgo extremo, no

TAREA DEL ESTUDIANTE · 2.3

Preguntas 6 y 7 sobre la cartera de tu equipo

P6 · ¿CAPTA LA VARIABILIDAD?

Diagnostica n_siniestros: índice, rootograma, residuos simulados y contraste de estructura. **Ajusta** quasi-Poisson y binomial negativa; **decide** con AIC y re-diagnóstico. Qué cambia —y qué no— en los **EE** y en la **tarifa**.

P7 · ¿DE DÓNDE VIENE?

Razónala como **heterogeneidad no observada** (fragilidad): pólizas intrínsecamente más siniestrosas que las variables no capturan. Puente a mixtos (2.5) y supervivencia (2.6).

Interpreta

En IRR, con los EE del modelo elegido.

Validación, solo al final

$\hat{\theta}$ frente a la verdad del DGP en attr(cartera, "verdad").