CASO 2 · CONTEOS Y TASAS · UNIDAD 2.4

Demasiados ceros

Ceros estructurales y muestrales · detectar el exceso frente a la NB · tres preguntas para elegir · zero-inflated (ZIP/ZINB) · hurdle · comparar, predecir y validar

PUNTO DE PARTIDA

De una varianza de más a unos ceros de más

UNIDAD 2.3 · N_DANOS

Un proceso, más disperso

La NB añade heterogeneidad entre pólizas: Var = μ + μ²/θ. Un único mecanismo genera todos los valores, también los ceros.



UNIDAD 2.4 · N_FRAUDE

Dos procesos detrás del cero

Un proceso decide si la póliza **puede** generar el evento; otro, **cuántos** genera si puede.

Muchos ceros no significan inflación de ceros: hay que ver si sobran **frente al mejor modelo de un solo proceso**.

```
glmmTMB(y ~ conteo, ziformula = ~ ceros, family = poisson) # mezcla: ZIP
glmmTMB(y ~ conteo, ziformula = ~ barrera, family = truncated_poisson) # dos etapas: hurdle
```


Lambert (1992) · Mullahy (1986) · Hilbe (2014)

LO QUE LA DIRECCIÓN QUIERE SABER

La mayoría de las pólizas no ha levantado nunca una alerta

8 Sospechamos que parte de la cartera queda, en la práctica, **fuera del alcance** del sistema antifraude. ¿Podéis distinguir esas pólizas de las que, vigiladas, **aún no** han dado motivo?

LA VARIABLE

n_fraude: alertas acumuladas por la póliza. Una alerta no es un fraude probado: es la señal que obliga a revisar.

LO QUE NO VEMOS

Si la póliza está dentro del **perímetro** de vigilancia. Solo vemos el número de alertas.

QUÉ ES

El mismo cero cuenta dos historias

CERO ESTRUCTURAL

No puede generar el evento

Fuera del perímetro: la póliza nunca acumulará una alerta. Un proceso aparte la fija en 0 pase lo que pase.

CERO MUESTRAL

Pudo, pero no ocurrió

Vigilada y sin alertas en el periodo observado: el azar del conteo le dio un 0.

En el dato son **idénticos**: solo difieren en su origen. Pasa siempre que conviven una subpoblación «inmune» y otra en riesgo: seguros, salud, ecología, fiabilidad, consumo.

Ignorarlo mezcla los dos ceros: el modelo reparte los eventos entre demasiadas pólizas, **infravalora la tasa** de las que sí están en riesgo y sesga la inferencia.

LA OPERATIVA DE LA UNIDAD

Siete pasos, en este orden

1	**¿Sobran ceros frente a la NB?**	testZeroInflation sobre la NB	§4.1
2	**¿Poisson o NB para el conteo?**	dispersión de una Poisson truncada en 0 sobre los positivos	§4.2
3	**¿Mezcla o barrera?**	la historia y si algún grupo tiene menos ceros de los esperados	§4.2
4	**¿Qué predictor va en cada parte?**	explorar las dos partes por separado	§4.3 · 4.4
5	**Ajusta y diagnostica**	ceros, rootograma, residuos simulados y frente a cada predictor	§4.3 · 4.4
6	**Compara**	AIC / BIC entre candidatos, y la historia del problema	§4.5
7	**Interpreta, predice y valida**	las dos partes; P(Y = 0); contra el DGP	§4.5

Casi el doble de ceros de los que espera la Poisson

OBSERVADOS

0.571

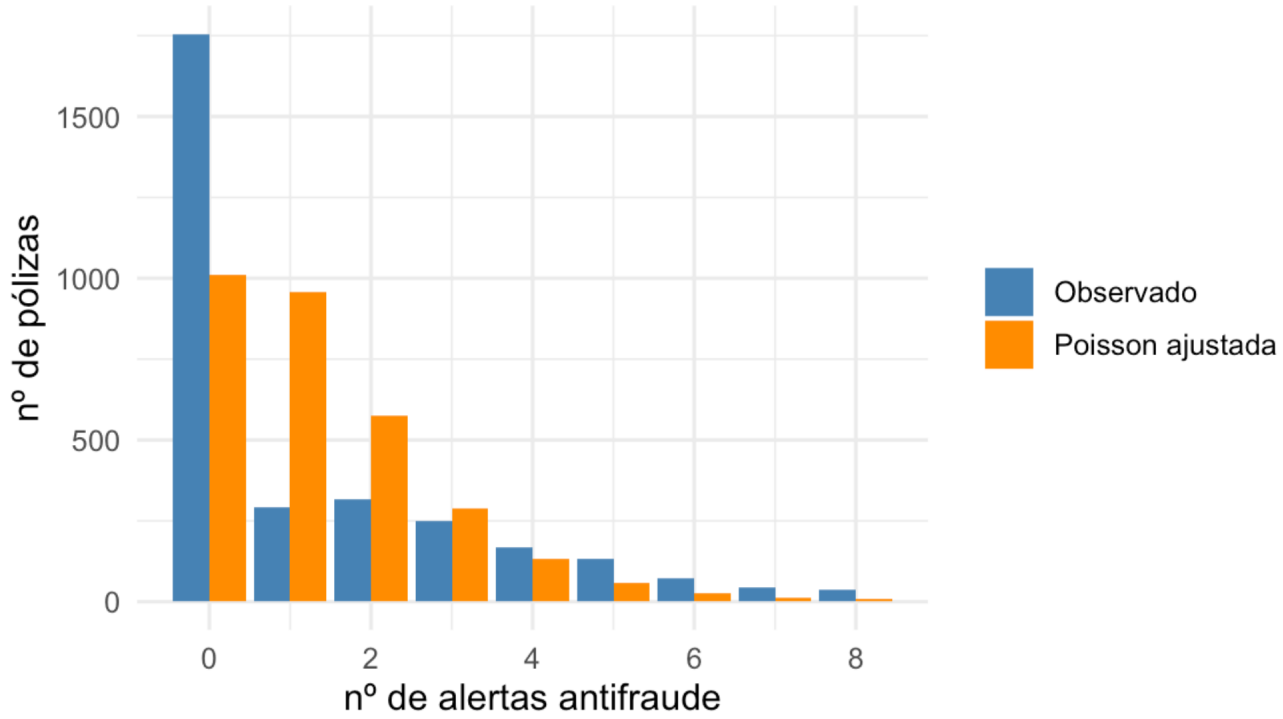
proporción de pólizas con 0 alertas

ESPERADOS · POISSON

0.330

media de $P(Y = 0) = \exp(-\hat{\mu}_i)$ sobre las pólizas

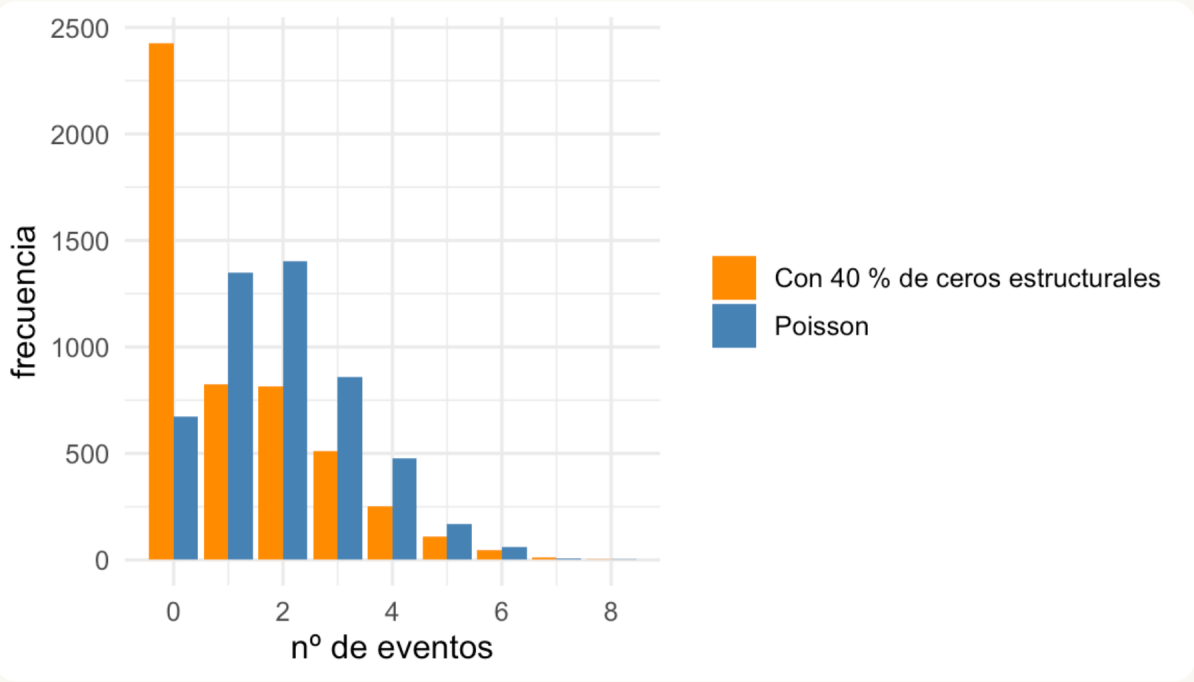
ratio = **1.73**



La barra del **0** se dispara y falta masa en 1 y 2: la Poisson reparte mal los ceros.

fig-u24-ceros · m_fp: glm(..., family = poisson) con offset

Una masa de ceros estructurales sumada a un conteo



MEZCLA

$$P(Y = 0) = \pi + (1 - \pi)\exp(-\mu)$$

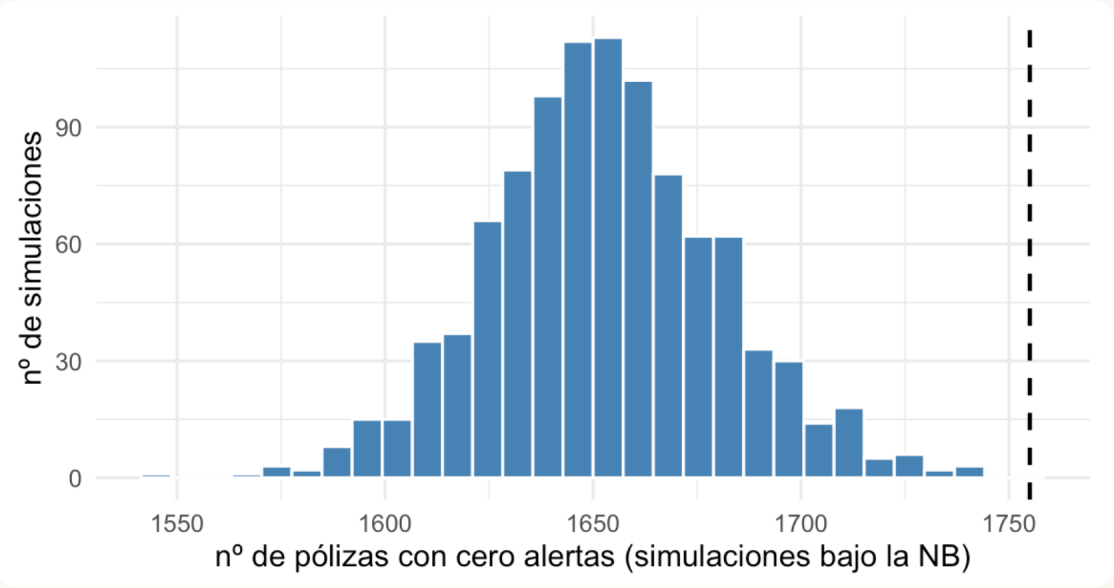
$$P(Y = k) = (1 - \pi) \cdot \exp(-\mu)\,\mu^k / k!,\ k \geq 1$$

Simulación: Poisson de media 2 frente a la misma Poisson con **π = 0.4** de ceros estructurales.

El 0 se dispara y **todos los positivos se encogen en la misma proporción**, 1 − π.

Frente a la NB sobran ceros: pocos, pero no por azar

La NB **ya fabrica** ceros de más: el exceso se mide frente a ella, no frente a la Poisson.



Ceros de las 1000 respuestas simuladas desde la NB; la línea discontinua, los observados.

DHARMa::testZeroInflation

$$T = no / \bar{no}^{sim}$$

Bajo H_0, n_0 es una suma de Bernoulli con $p_i = \hat{P}(Y_i = 0)$:

$$E[no] = \Sigma\, p_i \quad Var(no) = \Sigma\, p_i(1 - p_i)$$

DHARMa usa la distribución **simulada**: p = proporción de simulaciones tan extremas (dos colas), con resolución 1/B.

	ceros
observados	1755
media simulada (dt)	1653 (28)

T = 1.06
a 3.7 dt de la media

0 / 1000
p < 0.001

4.2 · ESTRUCTURAS PARA LOS CEROS

Quedan dos decisiones, y cada una fija un eje

Sobran ceros incluso frente a la NB (§4.1): necesitan un **proceso propio**. Muchos ceros no implican por sí solos inflación; aquí sí la hay.

	conteo Poisson	conteo NB
Mezcla · zero-inflated (§4.3)	ZIP	ZINB
Barrera · hurdle (§4.4)	hurdle-Poisson	hurdle-NB

COLUMNAS · PREGUNTA 1

¿Poisson o NB? Cómo se reparten los positivos: según estén o no sobredispersos una vez apartados los ceros.

FILAS · PREGUNTA 2

¿Mezcla o barrera? De dónde sale cada cero.

Mezcla: ceros estructurales (masa en 0) + aleatorios del conteo; solo puede **añadir** ceros.

Barrera: todos los ceros de un proceso binario y positivos truncados en 0; admite **más o menos** ceros.

Lambert (1992) · Mullahy (1986) · Feng (2021) · Blasco-Moreno et al. (2019)

¿Poisson o NB para el conteo? Poisson

EL INDICIO

$\hat{\theta} = 0.56$

Para reproducir tantos ceros, la NB necesita mucha heterogeneidad: Var = μ + μ²/θ. ¿Está en el **conteo** o la fabrican los **ceros**?

QUÉ HACEMOS

Solo las pólizas con alguna alerta: Poisson **truncada en 0**, con λ la media sin truncar.

$$m = \lambda / (1 - \exp(-\lambda))$$
$$\text{Var} = m\,(1 + \lambda - m)$$

Índice de dispersión = Σ (y − m)² / Var, dividido por los gl residuales.

RESULTADO

1.04

índice de los positivos

Qué concluimos. Los positivos no están sobredispersos: la heterogeneidad que pedía la NB la fabricaban los ceros. Versión **Poisson**: ZIP o hurdle-Poisson.

```
m_ztp ← glmmTMB::glmmTMB(n_fraude ~ ... + offset(log(exposicion)),
                         family = glmmTMB::truncated_poisson(), data = subset(cartera, n_fraude > 0))
```

¿Mezcla o barrera? Mezcla: empezamos por el ZIP

ZERO-INFLATED

$p_0 \geq p_0$ del conteo

solo puede **añadir** ceros

HURDLE

p_0 libre

admite grupos con **menos** ceros (deflación)

QUÉ HACEMOS

En 12 grupos de riesgo parecido, comparar los ceros observados con los que espera la Poisson, el conteo elegido.

Menor diferencia observada – Poisson

+0.119

positiva en los 12 grupos: no hay deflación

Qué concluimos. No hace falta la flexibilidad del hurdle, y la historia —un perímetro que deja fuera a parte de las pólizas— es la de una **mezcla**. Empezamos por el **ZIP**.

Los indicios **orientan**, no deciden: elegir con contrastes previos e inferir como si nada infla el error de tipo I. Deciden también la historia y la comparación (§4.5).

4.3 · ZERO-INFLATED

Una mezcla de dos poblaciones

CON PROBABILIDAD π_i

cero estructural: fuera del perímetro, aporta un 0 seguro

CON PROBABILIDAD $1 - \pi_i$

en riesgo: el conteo sigue f, Poisson o NB, de media μ_i

Ceros · dos vías

$$P(Y_i = 0) = \pi_i + (1 - \pi_i)\, f(0)$$

Positivos · solo el conteo

$$P(Y_i = k) = (1 - \pi_i)\, f(k),\ k > 0$$

PARTE ESTRUCTURAL · LOGIT

$$\operatorname{logit} \pi_i = z_i'\gamma$$

¿quién **no** está en riesgo? → exp(γ) es un OR

PARTE DE CONTEO · LOG

$$\log \mu_i = x_i'\beta + \log t_i$$

¿a qué **ritmo** acumulan las que sí? → exp(β) es una IRR

f Poisson → **ZIP** · f NB → **ZINB**. Los dos submodelos pueden llevar **predictores distintos**.

4.3 · VEROSIMILITUD Y ESTIMACIÓN

Se estiman a la vez: los ceros están repartidos

CONTRIBUCIÓN DE CADA PÓLIZA

$$\ell_i = \log(\pi_i + (1-\pi_i)\, f(0;\mu_i)) \text{ si } y_i = 0$$

$$\ell_i = \log(1-\pi_i) + \log f(y_i;\mu_i) \text{ si } y_i > 0$$

Un cero viene de dos fuentes (una **suma**); un positivo, solo del conteo.

	f(y; μ)	f(0; μ)
ZIP	exp(−μ) μʸ / y!	exp(−μ)
ZINB	NB(μ, θ) de la 2.3	(θ / (θ + μ))^θ

θ → ∞: la NB tiende a la Poisson y se recupera el ZIP.

Como la pertenencia de cada cero es **latente**, el método natural es el **algoritmo EM**, que alterna dos pasos hasta que ℓ deja de crecer:

PASO E · PERTENENCIA

$u_i = 1$ si la póliza es cero estructural. Por Bayes:

$$\hat{u}_i = \pi_i / (\pi_i + (1-\pi_i)\, f(0;\mu_i)) \text{ si } y_i = 0$$

$$\hat{u}_i = 0 \text{ si } y_i > 0$$

PASO M · DOS GLM CONOCIDOS

Logística de $\hat{u}_i$ sobre z_i → actualiza γ

Poisson de y_i sobre x_i, con offset y pesos $1 - \hat{u}_i$ → actualiza β (en el ZINB, NB ponderada: también θ)

```
glmmTMB::glmmTMB(y ~ conteo, ziformula = ~ ceros, family = poisson) # maximiza ℓ directamente
```


Lambert (1992) · Dempster et al. (1977)

¿En qué parte influye cada predictor?

¿INFLUYE EN LOS CEROS?

¿Cambia entre niveles la proporción de pólizas **fuera del perímetro**, π? → parte estructural

¿INFLUYE EN EL CONTEO?

¿Cambia entre niveles la **tasa de alertas** de las vigiladas, r? → parte de conteo

Cómo lo hacemos, para cada predictor y cada uno de sus niveles

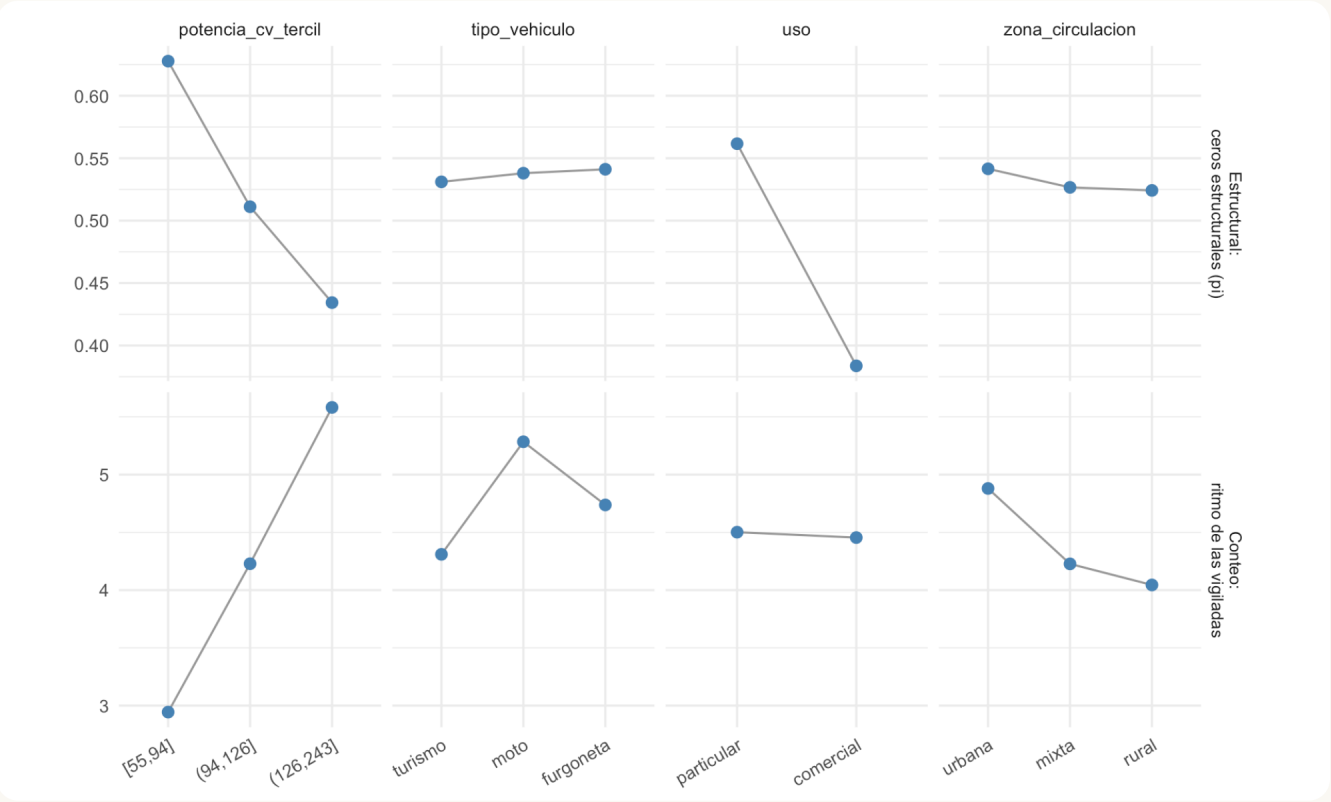
			Ejemplo: potencia baja
1	**Tasa de cada nivel**	Modelo **truncado en 0**, con el predictor solo y **sin los ceros**; alertas por unidad de exposición	$\hat{r} = 2.94$
2	**Ceros que daría el conteo**	Cero predicho de cada póliza, $\exp(-\hat{r}\, t_i)$, promediado en el nivel	$p_0^{conteo} = 18\ \%$
3	**Ceros observados**	Proporción de pólizas del nivel sin ninguna alerta	$p_0^{obs} = 69\ \%$
4	**Ceros estructurales**	$\hat{\pi} = (p_0^{obs} - p_0^{conteo}) / (1 - p_0^{conteo})$: fuera del perímetro	$\hat{\pi} = 0.63$

Ejemplo. Con $\hat{r} = 2.94$, solo un 18 % de las pólizas de potencia baja pasaría el periodo sin alertas; hay un 69 %. Se estima que un **63 %** queda fuera del perímetro.

Se representan $\hat{\pi}$ y $\hat{r}$ por nivel (diapositiva siguiente): si $\hat{\pi}$ cambia, el predictor va a los **ceros**; si cambia $\hat{r}$, al **conteo**.


```
glmmTMB(y ~ 0 + nivel + offset(log(t)), family = truncated_poisson(), data = subset(d, y > 0))
```

Cada predictor, a la parte que mueve



Si un predictor no influye en una parte, sus puntos quedan **a la misma altura** en esa fila.

ESTRUCTURAL · LOGIT

uso y **potencia_cv**

CONTEO · LOG

potencia_cv, **zona** y **tipo**

uso	tasa bruta	ritmo r̂
particular	1.95	4.50
comercial	2.78	4.45

La diferencia bruta del uso no es de ritmo: las comerciales están **vigiladas más a menudo**.

Dos fórmulas, una por parte del modelo

```
m_zip ← glmmTMB::glmmTMB(
  n_fraude ~ potencia_cv + zona_circulacion + uso + tipo_vehiculo + offset(log(exposicion)),
  ziformula = ~ uso + potencia_cv,
  family = poisson, data = cartera) # nbinom2 → ZINB
```

Fórmula principal · conteo · log

$$\log \mu_i = x_i'\beta + \log t_i$$

Lo que mueve el **ritmo** de una póliza vigilada. Lleva el **offset**.

ziformula · estructural · logit

$$\text{logit}\ \pi_i = z_i'\gamma$$

Lo que deja una póliza **fuera del perímetro**. Sin offset: es una condición, no se acumula con el tiempo.

ziformula = ~ 1

π constante para todas

ziformula = ~ .

los mismos predictores que el conteo

sin ziformula

(~ 0): sin ceros estructurales, una Poisson

family fija f: poisson → ZIP; nbinom2 → ZINB.

Dos preguntas respondidas a la vez

Conteo · IRR = exp(β) entre las vigiladas

Término	IRR	IC 95 %
potencia_cv (por CV)	1.007	[1.006; 1.008]
zona: mixta	0.866	[0.804; 0.932]
zona: rural	0.807	[0.737; 0.884]
uso: comercial	1.041	[0.959; 1.131]
tipo: moto	1.257	[1.148; 1.377]
tipo: furgoneta	1.071	[0.967; 1.187]

Estructural · OR = exp(γ) de estar fuera del perímetro

Término	OR	IC 95 %
uso: comercial	0.458	[0.362; 0.578]
potencia_cv (por CV)	0.989	[0.987; 0.992]

El IC del **uso** en el conteo contiene el 1; en la parte de ceros, queda lejos: su efecto es de **vigilancia**, no de ritmo.

LEER UNA IRR

Moto, IRR = 1.26: entre las pólizas vigiladas y con lo demás igual, una moto acumula alertas a un **ritmo un 26 % mayor** que un turismo.

LEER UNA OR

Uso comercial, OR = 0.46: a igual potencia, las **odds de quedar fuera del perímetro** de una póliza comercial son **menos de la mitad** que las de una particular.

Ni la edad aporta al conteo, ni la NB al ZIP

¿EDAD Y CARNET EN EL CONTEO?

```
m_zip_edad ← update(m_zip, . ~ . + edad_conductor +
antiguedad_carnet)
anova(m_zip, m_zip_edad)
```

	gl	log-verosimilitud
m_zip	10	−4280.98
+ edad + carnet	12	−4280.90

LR = 0.17, 2 gl, p = 0.918

No aportan: fuera del conteo.

¿HACE FALTA LA NB EN EL CONTEO?

```
m_zinb ← update(m_zip, family = glmmTMB::nbinom2)
AIC(m_zip, m_zinb)
```

	gl	AIC
ZIP	10	8582.0
ZINB	11	8583.9

Un parámetro más y no mejora: por **parsimonia**, el **ZIP**. Coincide con la pregunta 1 (índice 1.04).

update() cambia solo lo que se le indica: la fórmula del conteo o la familia; ziformula se mantiene.

Primero, tres comprobaciones globales (sin p-valor)

¿Hay un test de bondad de ajuste? El clásico, deviance o χ^2 de Pearson frente a una χ^2_{n-p}, **no es válido**: con conteos individuales de media baja no siguen una χ^2 (Unidad 2.1).

Se evalúa en **dos pasos**: **1** · tres comprobaciones globales, sin p-valor (aquí); **2** · un test formal por simulación, con DHARMa (siguiente).

1 · CEROS

observados **1755** · ZIP **1757**

suma de $\hat{P}(Y_i = 0)$ sobre las pólizas

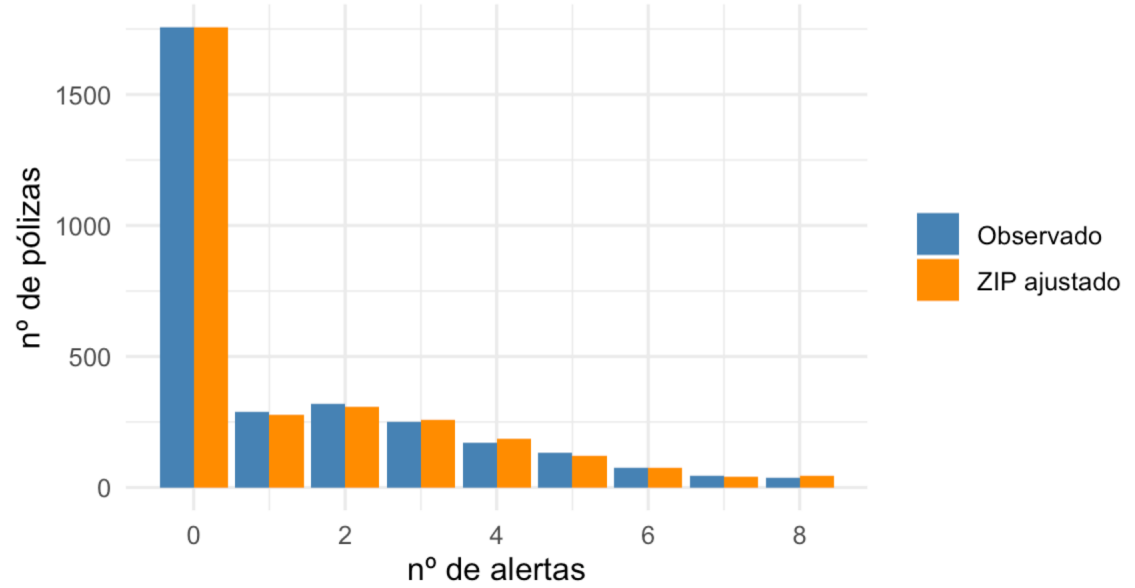
2 · POSITIVOS

El ZINB no mejora (AIC 8582.0 frente a 8583.9): conteo Poisson.

3 · FORMA

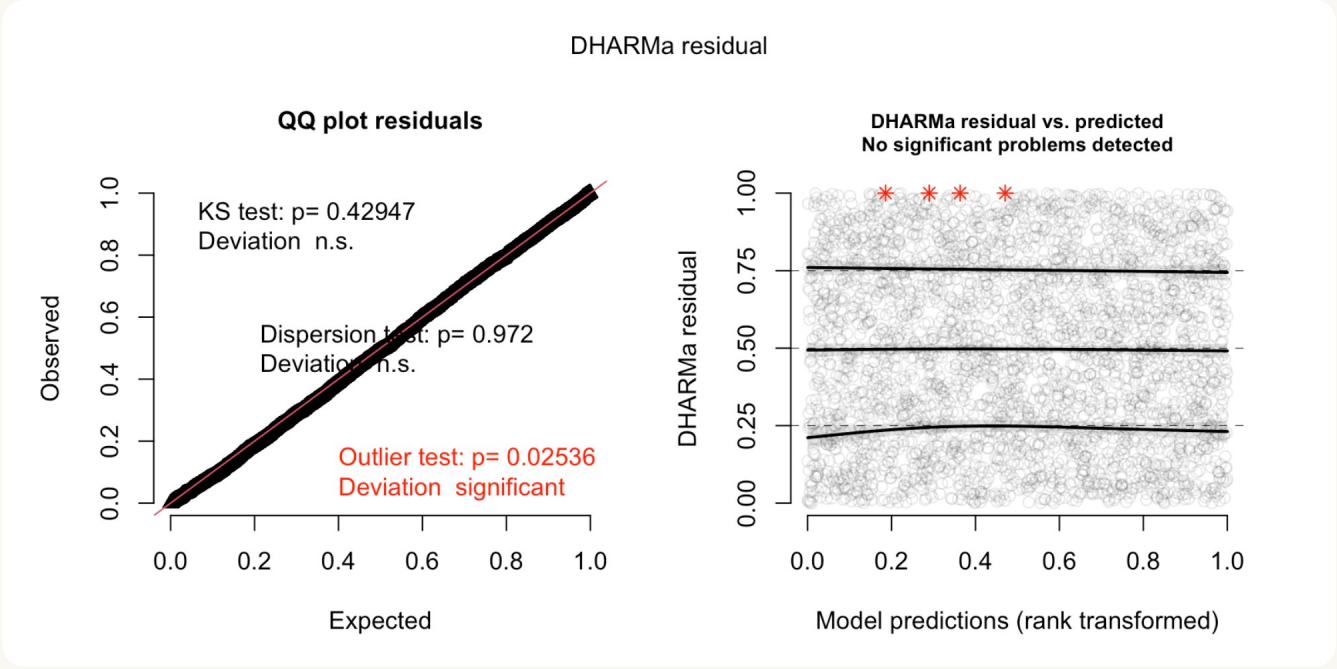
Rootograma: sigue el 0 y los positivos.

X^2 de frecuencias = **5.35**; bootstrap paramétrico **p = 0.52**.



A diferencia de la Poisson, el ZIP reproduce el pico de ceros **y** los positivos.

Después, el test formal: residuos simulados de DHARMa



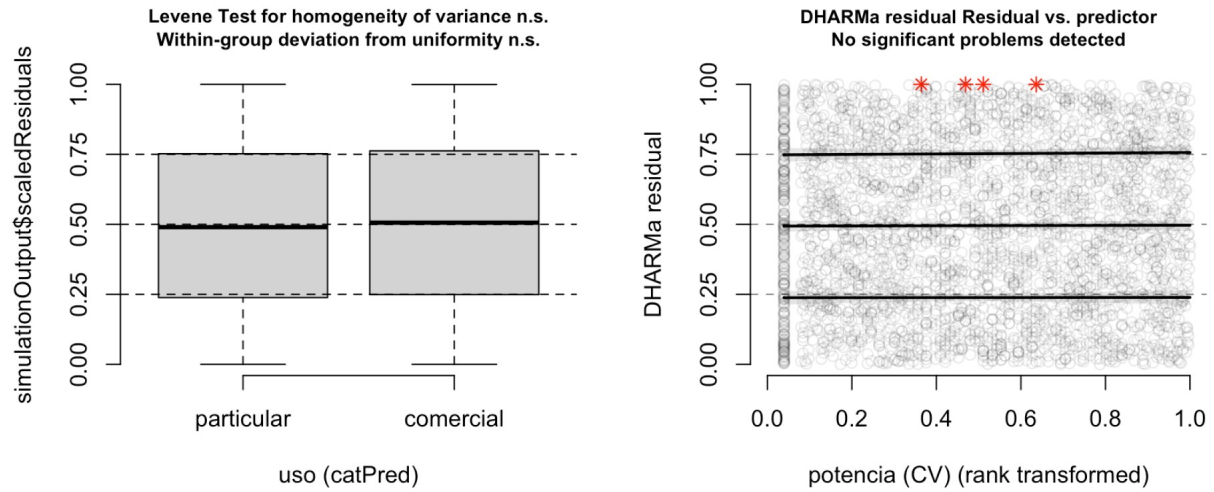
Contraste	Estad.	p
uniformidad (KS)	0.016	0.43
dispersión	1.00	0.97
exceso de ceros	1.00	0.92

H_0 del KS: el ZIP genera los datos (residuos uniformes). **No se rechaza.**

Cociente de ceros: **1.00** en el ZIP frente a **1.06** en la NB.

DHARMa simula directamente desde m_zip: decide primero si cada póliza es un cero estructural y, si no lo es, sortea su conteo.

¿Está cada predictor en su parte?



Cajas del **uso** centradas en 0.5 en los dos niveles; cuantiles **planos** frente a la potencia: el reparto de predictores entre las dos partes es coherente.

> **No uses el test de Vuong** (pscl::vuong) para Poisson frente a ZIP: exige modelos no anidados, y la Poisson es el ZIP con π = 0. Quédate con DHARMa y el AIC.

Una barrera y, si se cruza, un conteo sin ceros

ETAPA 1 · BARRERA · LOGIT

¿Ocurre **algún** evento?

$\text{logit}\ \pi_i = z_i'\gamma,\ \pi_i = P(Y_i = 0)$

ETAPA 2 · CONTEO TRUNCADO EN 0

Si la cruza, **¿cuántos?** (≥ 1)

$\log \mu_i = x_i'\beta + \log t_i$

Ceros · solo la barrera

$P(Y_i = 0) = \pi_i$

Positivos · solo el conteo truncado

$P(Y_i = k) = (1 - \pi_i)\, f(k) / (1 - f(0)),\ k > 0$

	Zero-inflated	Hurdle
π_i es la probabilidad de...	un cero estructural: solo parte de los ceros	cualquier cero: no cruzar la barrera
Los ceros vienen de	dos procesos: estructural + conteo	un único proceso
Estimación	conjunta: hay pertenencia latente	ℓ se separa; glmmTMB las maximiza a la vez

Mullahy (1986) · glmmTMB(family = truncated_poisson)

¿En qué parte influye cada predictor? Aquí se ve directamente

BARRERA

¿Cambia entre niveles la proporción de pólizas **sin ninguna alerta**, p_0^{obs}? Es la estimación directa de π.

CONTEO

¿Cambia el **ritmo r̂** de las pólizas con alguna alerta? Es el de la exploración del ZI.

No hay nada que separar: cada cero es de la barrera y cada positivo, del conteo.

Predictor (niveles)	sin alertas p_0^{obs}	ritmo r̂	Va a…
potencia: terciles bajo · medio · alto	0.69 · 0.56 · 0.46	2.94 · 4.23 · 5.58	las dos
uso: particular · comercial	0.60 · 0.44	4.50 · 4.45	barrera
zona: urbana · mixta · rural	0.57 · 0.57 · 0.57	4.88 · 4.23 · 4.04	conteo
tipo: turismo · moto · furgoneta	0.57 · 0.56 · 0.57	4.31 · 5.28 · 4.74	conteo

El mismo reparto que en el ZI: uso y potencia a la barrera; potencia, zona y tipo al conteo (y el uso también, para que el ajuste estime su efecto).

Un ZI con la familia truncada: ziformula pasa a ser la barrera

```
m_hp ← glmmTMB::glmmTMB(n_fraude ~ ... + offset(log(exposicion)), ziformula = ~ uso + potencia_cv,
                        family = glmmTMB::truncated_poisson(), data = cartera) # truncated_nbinom2 → hurdle-NB
```

Conteo truncado · IRR = exp(β)

Término	IRR	IC 95 %
potencia_cv (por CV)	1.007	[1.006; 1.008]
zona: mixta	0.862	[0.800; 0.930]
zona: rural	0.804	[0.732; 0.883]
uso: comercial	1.044	[0.961; 1.134]
tipo: moto	1.260	[1.149; 1.381]
tipo: furgoneta	1.072	[0.966; 1.190]

Prácticamente los **mismos efectos que en el ZIP**.

Barrera · OR = exp(γ) de no tener ninguna alerta

Término	OR	IC 95 %
uso: comercial	0.491	[0.401; 0.601]
potencia_cv (por CV)	0.988	[0.985; 0.990]

Mismo signo que en el ZI, otra lectura: las comerciales se quedan **sin alertas** menos a menudo, sin distinguir si es por estar más vigiladas o por acumularlas más deprisa.

AIC: hurdle-Poisson **8592.3** · hurdle-NB 8594.2. La Poisson truncada basta.

El test global no lo ve; los residuos frente a la exposición, sí

GLOBAL

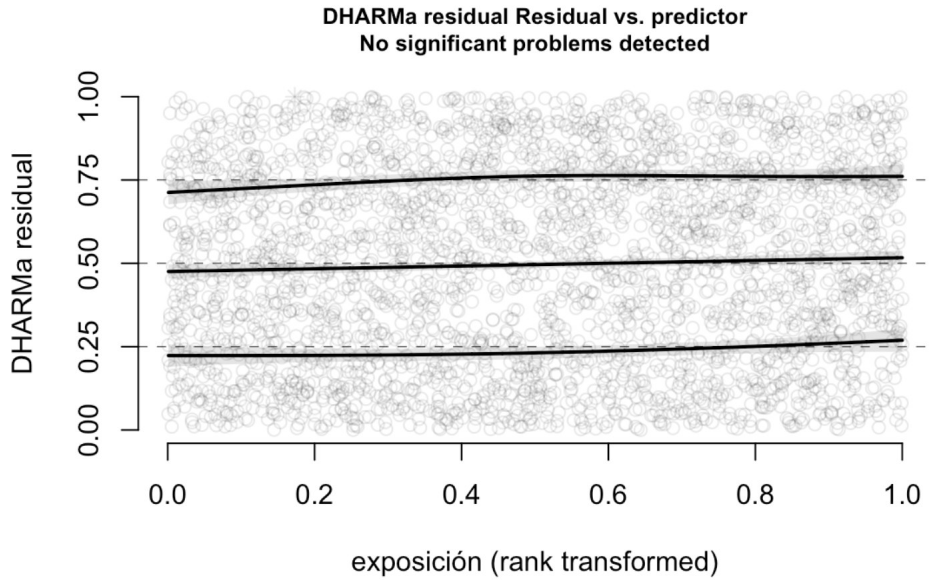
Ceros: **1755** observados = **1755** esperados, por construcción.

DHARMa: KS p = 0.09 · dispersión p = 0.59. No se rechaza.

MEDIANA DE RESIDUOS POR CUARTIL DE EXPOSICIÓN

Q1	Q2	Q3	Q4
0.467	0.510	0.524	0.501

Las pólizas observadas menos tiempo cruzan la barrera **menos** de lo predicho.



Por qué. Tener alguna alerta depende del tiempo observado, y la barrera no lo lleva. Corrección natural: **log(exposicion)** como predictor en **ziformula**.

Los seis modelos, lado a lado

Modelo	gl	AIC	BIC	RMSE	peso de Akaike
ZIP	10	8582.0	8642.3	1.8544	0.72
ZINB	11	8583.9	8650.3	1.8544	0.27
Hurdle-P	10	8592.3	8652.6	1.8549	0.004
Hurdle-NB	11	8594.2	8660.6	1.8549	0.002
NB	8	9187.8	9236.0	1.8569	≈ 0
Poisson	7	11002.9	11045.1	1.8553	0

1

Lo decisivo es tratar los ceros: Poisson y NB, muy por detrás.

2

La NB no aporta dentro de cada familia: un parámetro más, peor AIC.

3

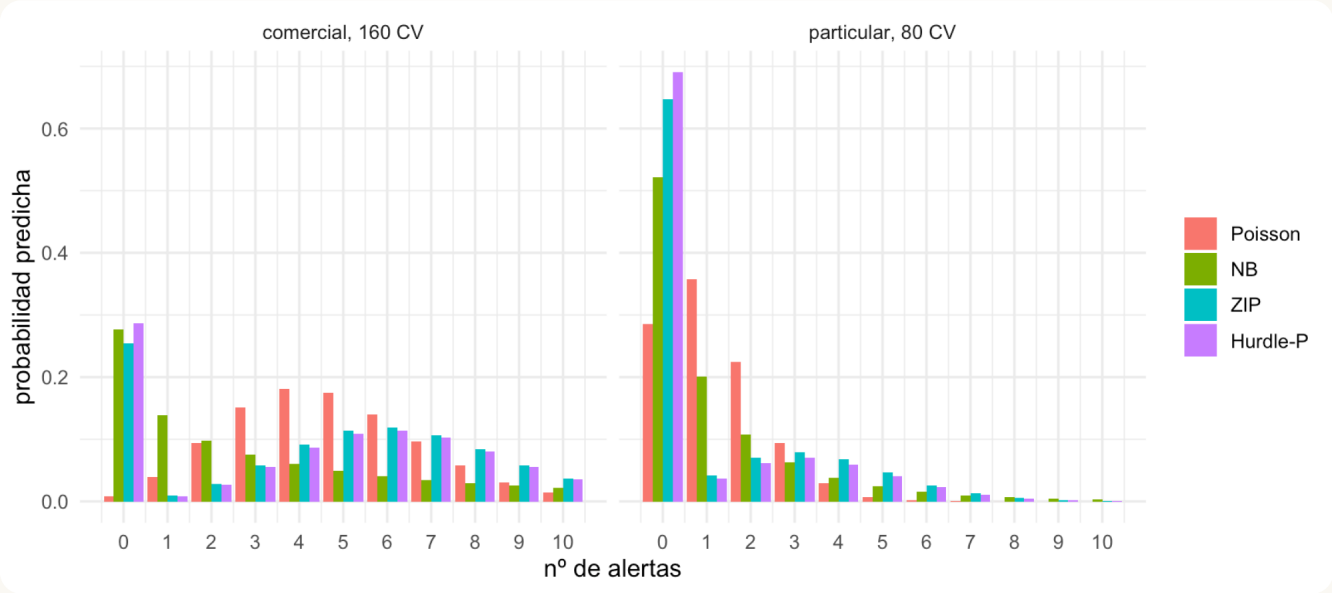
El ZIP, preferido: la historia es de mezcla y la barrera del hurdle no recoge la exposición.

El **RMSE apenas cambia**: todos predicen casi la misma media. Lo que los separa es la **distribución**, y eso miden AIC y BIC.

Casi la misma media, muy distinta probabilidad de cero

Urbana, turismo, exposición 1

	media	P(Y = 0)
Particular, 80 CV		
Poisson	1.25	0.29
NB	1.23	0.52
ZIP	1.24	0.65
Hurdle-P	1.09	0.69
Comercial, 160 CV		
Poisson	4.82	0.008
NB	4.99	0.28
ZIP	4.69	0.25
Hurdle-P	4.49	0.29



$E[Y] = (1 - \pi)\,\mu$ en el ZI $E[Y] = (1 - \pi)\,\mu / (1 - \exp(-\mu))$ en el hurdle

El ZIP la descompone: predict(m_zip, type = "zprob") → fuera del perímetro; type = "conditional" → ritmo si está dentro.

4.5 · CONCLUSIONES

Sí: el ZIP separa a las pólizas que el sistema no mira

EXCESO DE CEROS

1.06

cociente frente a la **NB**: pequeño pero sistemático (0 de 1000)

ESTRUCTURA

ZIP

conteo Poisson (índice 1.04) y mezcla (sin deflación)

COMPARACIÓN

0.72

peso de Akaike; ceros, forma y residuos sin patrón

Las pólizas **comerciales** y las **potentes** quedan fuera del perímetro menos a menudo (OR 0.46; × 0.58 por 50 CV). Dentro, el ritmo lo marcan la **potencia**, la **zona** y el **tipo**, no el uso.

4.5 · VALIDACIÓN CONTRA EL DGP

Los 10 intervalos contienen el valor verdadero

Parte	Término	DGP	ZIP	IC 95 %
conteo (log)	intercepto	1.253	1.232	[1.146; 1.318]
	potencia (tipificada)	0.250	0.254	[0.222; 0.287]
	zona: urbana (ref. rural)	0.200	0.214	[0.123; 0.306]
	zona: mixta	0.050	0.070	[−0.027; 0.167]
	uso: comercial	0.100	0.040	[−0.042; 0.123]
	tipo: moto	0.150	0.229	[0.138; 0.320]
	tipo: furgoneta	0.050	0.069	[−0.034; 0.171]
estructural (logit)	intercepto	0.200	0.221	[0.133; 0.310]
	uso: comercial	−0.700	−0.782	[−1.016; −0.548]
	potencia (tipificada)	−0.400	−0.383	[−0.466; −0.300]

El mismo ZIP, reajustado en la escala del DGP (potencia tipificada, zona rural de referencia): misma log-verosimilitud, −4280.982.

4.5 · VALIDACIÓN CONTRA EL DGP

Qué se recuperó, qué no, y por qué

1 · FUERA DEL PERÍMETRO

0.522 0.525

proporción media: **DGP** frente a **ZIP**. La P8 queda bien respondida; uso y potencia se recuperan con su signo.

2 · LO QUE NO SE DETECTÓ

Uso en el conteo: DGP 0.1 (IRR 1.11); ZIP 0.04, IC [−0.042; 0.123]: contiene **a la vez** el 0 y la verdad.

«No hay evidencia» no es «no hay efecto»: por eso se mantuvo con su intervalo. La edad y el carnet (0 en el DGP) no entraron.

3 · EL MECANISMO

A ciegas se eligió el ZIP: frente al **ZINB**, porque el conteo se generó Poisson; frente al **hurdle**, porque los ceros se generaron por mezcla.

Los ceros muestrales, $\exp(-\mu_i)$, crecen al bajar la exposición: el hurdle tiene que meterlos en su barrera, y sin la exposición no puede.

No basta con que el modelo ajuste bien: hay que comprobar **qué** ha recuperado y **qué no**, y por qué.

RECETA PARA EL EXCESO DE CEROS

La operativa, paso a paso, en R

1	**¿Sobran ceros frente a la NB?**	`DHARMa::testZeroInflation(DHARMa::simulateResiduals(m_nb, n = 1000))`
2	**¿Poisson o NB para el conteo?**	`glmmTMB(..., family = truncated_poisson())` sobre `y > 0` → índice ≈ 1
3	**¿Mezcla o barrera?**	ceros observados - esperados por grupos: ¿alguno < 0? + la historia
4	**¿Qué predictor en cada parte?**	explorar ritmo (truncada) y πˆpor nivel → `y ~ conteo, ziformula = ~ ceros`
5	**Ajusta y diagnostica**	`glmmTMB(family = poisson | truncated_poisson)`; rootograma; DHARMa + plotResiduals
6	**Compara**	`AIC(m_zip, m_zinb, m_hp, m_hnb, ...)` · nunca `pscl::vuong`
7	**Interpreta, predice, valida**	`broom.mixed::tidy(exponentiate = TRUE)`; `predict(type = "zprob")`; `attr(., "verdad")`

CIERRE

Lo que hay que llevarse

1

Dos historias del cero

Estructural (no puede) y muestral (pudo, no ocurrió): idénticos en el dato

2

Frente a la NB

Muchos ceros no son inflación: solo lo que sobra sobre la NB

3

Tres preguntas

¿Sobran? ¿Poisson o NB? ¿Mezcla o barrera?

4

Dos fórmulas

conteo y ziformula, con predictores propios; el offset, en el conteo

5

Diagnóstico por partes

DHARMa sobre el modelo, frente a cada predictor y la exposición

6

Media o probabilidad de cero

Todos predicen la misma media; difieren en P(Y = 0)

TAREA DEL ESTUDIANTE · 2.4

Pregunta 8 sobre la cartera de tu equipo

¿Podéis distinguir las pólizas que quedan **fuera del alcance** del sistema de las que, vigiladas, **aún no** han dado motivo? Sobre **n_fraude**:

Diagnostica
el exceso de ceros frente a la NB, no a la Poisson (pasos 1–3).

Ajusta
un zero-inflated y/o un hurdle, con los predictores repartidos entre las dos partes (pasos 4–5).

Decide y justifica
por AIC y por la historia: ¿subpoblación fuera del perímetro o proceso en dos etapas? (paso 6)

Interpreta y valida
las dos partes, y la estructural contra attr(cartera, "verdad")$g_cero (paso 7).