CASO 2 · CONTEOS Y TASAS · UNIDAD 2.5

Efectos aleatorios y modelos mixtos

Pólizas agrupadas en agencias y regiones · el GLMM de Poisson anidado · componentes de varianza · el factor de cada agencia · predecir una agencia nueva · el OLRE

PUNTO DE PARTIDA

De pólizas independientes a pólizas agrupadas

UNIDADES 2.1–2.4

Cada póliza, por su cuenta

Poisson, NB o modelos de ceros: las pólizas se tratan como **independientes**; toda la variación es de póliza o de covariables.

Unidad 2.5 · n_gestiones

Pólizas que comparten agencia y región

Las de una misma agencia se parecen; las agencias de una misma región, también. Un **efecto aleatorio** por nivel.

Espiral: los mixtos del **Caso 1** (logística con intercepto aleatorio), ahora sobre la **Poisson** y con dos niveles anidados.

```
glmmTMB(n_gestiones ~ x + offset(log(exposicion)) + (1 | region/agencia), family = poisson)
```

LO QUE LA DIRECCIÓN QUIERE SABER

Tres preguntas que una Poisson corriente no responde

1

¿Cuánto del ritmo de gestiones depende de la **región**, cuánto de la **agencia** y cuánto de la **póliza**?

2

¿Qué **agencias** se desvían de lo esperado para su región?

3

¿Qué esperar de una **agencia nueva**, sin historial?

Preguntas 9 a 12 del estudio de caso: ICC y efectos fijos (P9), región (P10), agencias atípicas (P11) y agencia nueva (P12).

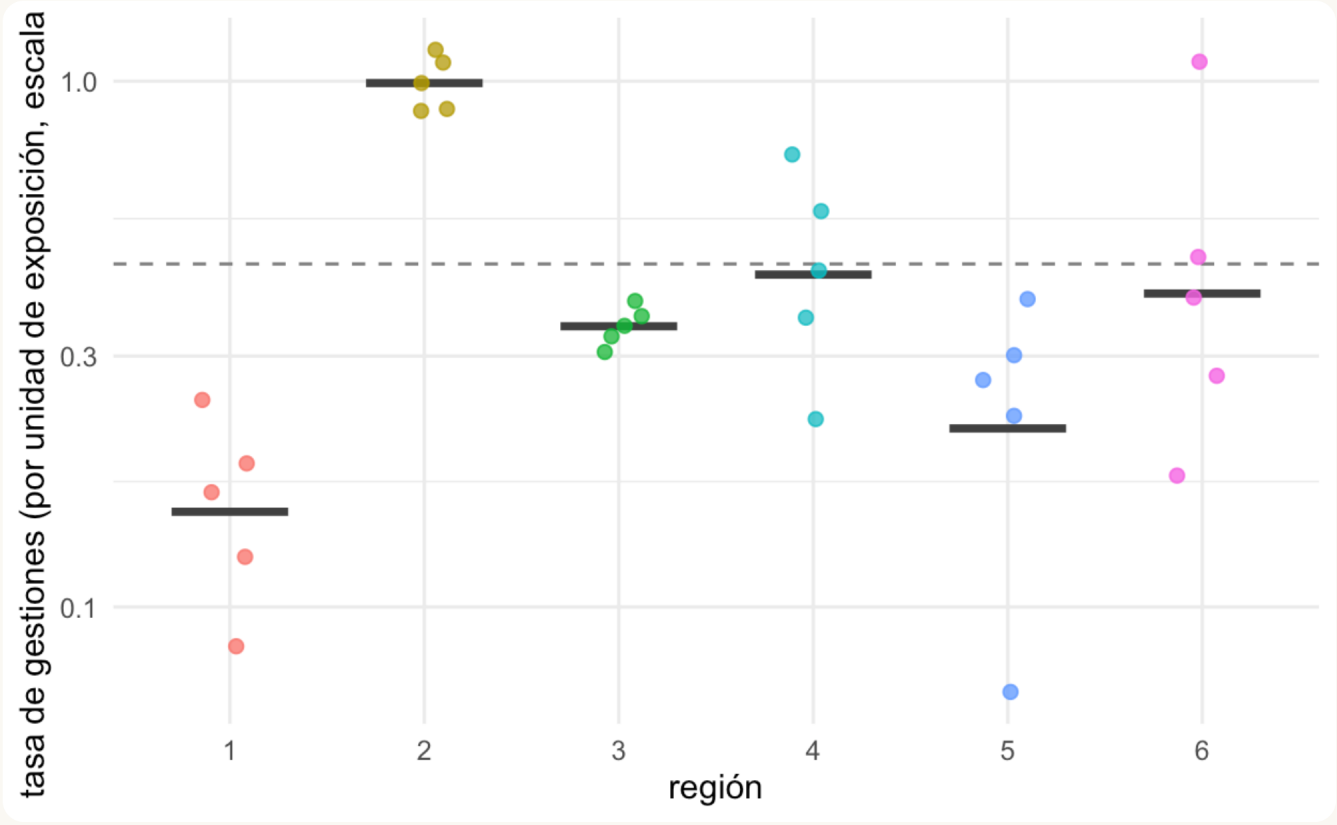
LA OPERATIVA DE LA UNIDAD

Problema, propuesta, solución: ocho pasos

Problema	1	**¿Hay agrupamiento?**	tasa por agencia, agrupada por región	§5.1
Propuesta	2	**Formula el anidamiento**	interceptos aleatorios de región y de agencia	§5.2
Propuesta	3	**Criba predictores**	cada candidato sobre el mixto nulo, con un LRT	§5.2
Solución	4	**Ajusta e interpreta**	glmmTMB e IRR condicionales	§5.3
Solución	5	**Reparte la varianza**	σ de cada nivel, R^2, ICC y LRT de frontera	§5.3
Solución	6	**Agencias y predicción**	BLUP, encogimiento y cinco predicciones	§5.3
Solución	7	**Selecciona y diagnostica**	drop1, pendientes, NB frente a GLMM, DHARMa	§5.4–5.5
Solución	8	**Valida contra el DGP**	qué se recuperó y qué no	§5.6

Al final, el **OLRE** (§5.7): el mismo modelo con un efecto aleatorio por observación, para la sobredispersión.

El ritmo cambia entre regiones y, dentro, entre agencias



CÓMO SE LEE

Punto: una agencia, a la altura de su tasa Σy / Σe.

Barra: la media de su región.

Discontinua: la tasa global.

DOS NIVELES DE VARIACIÓN

Las **barras** están a alturas distintas: varían las regiones.

Los **puntos** se dispersan en cada región: varían las agencias.

En el margen, n_gestiones parece casi bien portada: var/media = **1.18**.

Una jerarquía que rompe la Poisson corriente



1 · DEPENDENCIA EN DOS NIVELES

Dos pólizas de la misma agencia se parecen más entre sí que a las de otra; dos agencias de la misma región, también. La independencia falla **a los dos niveles**.

2 · SOBREDISPERSIÓN APARENTE

La variación entre agencias infla la varianza. Una NB la taparía; la estructura de los datos pide **efectos aleatorios** (se comprueba en §5.4).

Ignorarlo deja **errores estándar optimistas** y no permite repartir el ritmo entre región, agencia y póliza, ni predecir una agencia nueva.

Un desplazamiento aleatorio del log-ritmo en cada nivel

$$Y_{ij} \mid u \sim \text{Poisson}(\mu_{ij}),\ \log \mu_{ij} = \log e_{ij} + x_{ij}'\beta + u^{reg}_{r(j)} + u^{ag}_{j}$$

$$u^{reg}_{r} \sim N(0, \sigma^{2reg}) \cdot u^{ag}_{j} \sim N(0, \sigma^{2ag}) \cdot \text{independientes entre sí}$$

i: la póliza · **j**: su agencia (1 a 30) · **r(j)**: la región de la agencia j (1 a 6)

β · efectos fijos

Comunes a toda la cartera: lo que hacen las covariables.

u^{reg} · 6 valores

Lo que hace que una región tramite por encima o por debajo; lo comparten todas sus pólizas.

u^{ag} · 30 valores

La desviación de cada agencia respecto a **su** región r(j).

Los u no son parámetros: son **variables latentes**. De cada nivel solo se estima su **varianza**. En la tasa, e^{u} es el factor que aplican.

Cuánto se parecen dos pólizas según lo que compartan

MATRIZ DE COVARIANZAS DE LOS 36 EFECTOS

$$G = \mathrm{diag}\left(\sigma^{2reg} I_6 \, , \, \sigma^{2ag} I_{30} \right)$$

Solo **dos parámetros**: σ^{2reg} y σ^{2ag}.

Dos pólizas…	$\mathrm{Cov}(\eta_{ij}, \eta_{i'j'})$
de la misma agencia	$\sigma^{2reg} + \sigma^{2ag}$
misma región, otra agencia	σ^{2reg}
de distinta región	0

Condicionados a los u, los conteos vuelven a ser Poisson independientes.

¿UNA VARIANZA DE AGENCIA POR REGIÓN?

Con **5 agencias por región**, $4s^2/\sigma^{2ag} \sim \chi^2_4$: su DT muestral cae, por azar, entre **0.35 σ^{ag}** y **1.67 σ^{ag}**.

Por debajo de los unos 6 niveles que pide Bates (2010): se asume **común**.

```
(1 | region/agencia)
# = (1 | region) + (1 | region:agencia)
```

Cómo se ajusta: integrar los u, aproximando por Laplace

VEROSIMILITUD MARGINAL

$$L(\beta, \theta) = \int \prod f(y_{i\,j} \mid u; \beta) \cdot \phi(u; 0, G_\theta)\, du\ ,\ \theta = (\sigma^{reg}, \sigma^{ag})$$

Con la Poisson-log no tiene forma cerrada.

APROXIMACIÓN DE LAPLACE

$$\log L \approx h(\hat{u}) + (q/2)\log(2\pi) - \tfrac{1}{2}\log\det(-\nabla^2 h(\hat{u})),\ q = 36$$

h(u) = log f(y | u) + log φ(u); û es su moda. Se sustituye la integral por la de una normal centrada en û.

BUCLE INTERNO · NEWTON

Calcula la moda û para cada (β, θ).

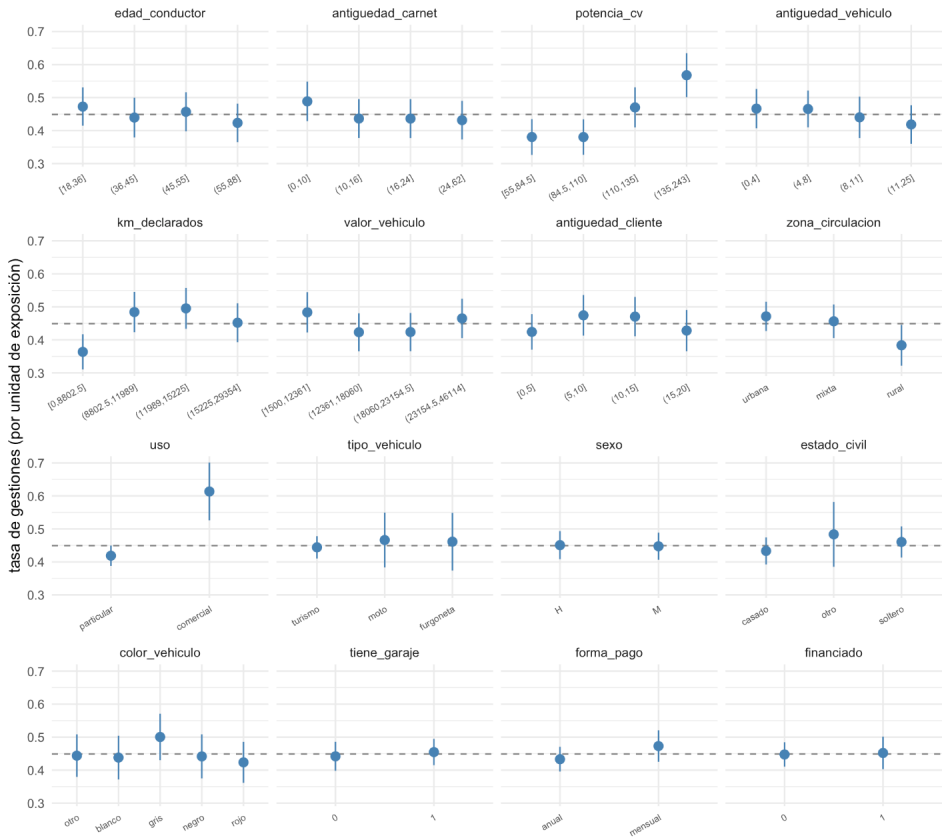
BUCLE EXTERNO · NLMINB

Maximiza la verosimilitud aproximada en (β, θ).

AL TERMINAR

El hessiano da los **errores estándar**; û son los **BLUP**.

Explorar: la tasa por nivel de cada candidato



16 candidatos: 7 continuos (por cuartiles) y 9 categóricos. Tasa Σy / Σe con un intervalo aproximado.

LO QUE SE VE

La tasa sube con la **potencia** y es mayor en uso **comercial**. El resto ronda la línea global.

Los intervalos tratan como independientes las pólizas de una agencia: son **demasiado estrechos**. Hace falta un criterio que respete el agrupamiento.

El bonus-malus queda fuera: se fija con la siniestralidad del propio año.

Cribar uno a uno sobre el mixto nulo

```
m_nulo ← glmmTMB(n_gestiones ~ offset(log(exposicion)) + (1
| region/agencia),
                  family = poisson, data = cartera)
update(m_nulo, . ~ . + x) # y un LRT frente a m_nulo
```

Candidato	gl	LR	p (mixto)	p (sin agrupar)
potencia_cv	1	22.42	2.2e−6	< 0.0001
uso	1	13.93	1.9e−4	< 0.0001
antiguedad_carnet	1	2.39	0.12	0.13
zona_circulacion	2	2.77	0.25	0.086
… 12 restantes			> 0.15	

EDAD Y CARNET, JUNTAS

Correlación **0.82**: una podría tapar a la otra.

$LR = 2.41$, 2 gl, $p = 0.30$

Tampoco aportan juntas.

Qué concluimos. Entran la **potencia** y el **uso**. Sin descontar el agrupamiento, la zona parecería más relevante (0.086 frente a 0.25).

Los efectos fijos se leen como IRR condicionales

```
m_glmm ← glmmTMB(n_gestiones ~ potencia_c + uso + offset(log(exposicion)) + (1 | region/agencia),
                 family = poisson, data = cartera) # potencia_c: CV respecto a la media
```

IRR = exp(β) · IC 95 % de Wald

Término	IRR	IC 95 %
(Intercept): tasa de referencia	0.337	[0.213; 0.534]
potencia_c (por CV)	1.004	[1.003; 1.006]
uso: comercial	1.383	[1.176; 1.625]

Convergencia correcta y hessiano definido positivo.

LEER UNA IRR

Uso comercial, 1.38: a igual potencia y **en la misma agencia**, una póliza comercial genera gestiones a un ritmo un **38 % mayor**.

Condicional = poblacional aquí: con enlace log y solo interceptos, E[exp(η + u)] = exp(η) E[exp(u)] y el factor se cancela. No así en la logística mixta (Unidad 1.4).

Cuánto varía cada nivel

ENTRE REGIONES

$\hat{\sigma}^{reg} = 0.54$

IC 95 %: [0.284; 1.018] · solo 6 grupos

ENTRE AGENCIAS DE UNA REGIÓN

$\hat{\sigma}^{ag} = 0.37$

IC 95 %: [0.250; 0.542] · 30 grupos

COVARIANZA ENTRE PREDICTORES (ESCALA LOG)

Dos pólizas…	Cov
de la misma agencia	0.4248
misma región, otra agencia	0.2895
de distinta región	0

misma agencia: $\hat{\sigma}^{2reg} + \hat{\sigma}^{2ag}$ · misma región: $\hat{\sigma}^{2reg}$ · distinta región: 0

glmmTMB estima **θ = log σ**: el IC se construye en esa escala y se exponencia, por eso **no es simétrico**.

Correlación entre las **estimaciones** de las dos σ: **−0.039**. Casi nula: un error en una no se compensa con la otra.

```
VarCorr(m)$cond; confint(m, parm = "theta_")
```

Dónde se tramita pesa más que qué se asegura

Fracción de la varianza del log-ritmo que explica cada fuente



Efectos fijos 0.023 ($\sigma^{2f} = 0.038$) **Región** 0.177 (0.289) **Agencia** 0.083 (0.135) **Poisson** 0.717 ($\sigma^2\varepsilon = 1.172$)

R^2 DE NAKAGAWA

marginal **0.023** · condicional **0.283**

Fracción de la varianza total que explican los fijos (**marginal**) o fijos + aleatorios (**condicional**):

$$\text{marginal} = \sigma^{2f} / \text{total}$$
$$\text{condicional} = (\sigma^{2f} + \sigma^{2reg} + \sigma^{2ag}) / \text{total}$$

ICC POR NIVEL

región **0.181** · agencia **0.085**

Fracción de cada nivel sin contar los efectos fijos:

$$ICC^{reg} = \sigma^{2reg} / (\sigma^{2reg} + \sigma^{2ag} + \sigma^2\varepsilon)$$
$$ICC^{ag} = \sigma^{2ag} / (\sigma^{2reg} + \sigma^{2ag} + \sigma^2\varepsilon)$$

RAZONES ROBUSTAS

La región pesa **2.1** veces la agencia; las dos juntas, **11** veces las covariables.

$0.289 / 0.135 \approx 2.1$

$(0.289 + 0.135) / 0.038 \approx 11$

No usan $\sigma^2\varepsilon$.

total = $\sigma^{2f} + \sigma^{2reg} + \sigma^{2ag} + \sigma^2\varepsilon$. $\sigma^2\varepsilon$ de la Poisson se aproxima por $\ln(1 + 1/\lambda)$: las fracciones dependen de esa aproximación; las razones entre componentes del modelo, no.

u25-particion · u25-r2-icc · Nakagawa y Schielzeth (2013) · Nakagawa et al. (2017)

¿Son las varianzas distintas de cero? Las dos, sí

H_0: $\sigma^2 = 0$ está en el borde del espacio

$$LR \sim \tfrac{1}{2}\chi^2_0 + \tfrac{1}{2}\chi^2_1 \Rightarrow p = \tfrac{1}{2}\Pr(\chi^2_1 > LR)$$

El p correcto es la **mitad** del ingenuo (Self y Liang, 1987; Stram y Lee, 1994).

QUITAR LA REGIÓN

LR = 15.47

p corregido = **4.2e−5**

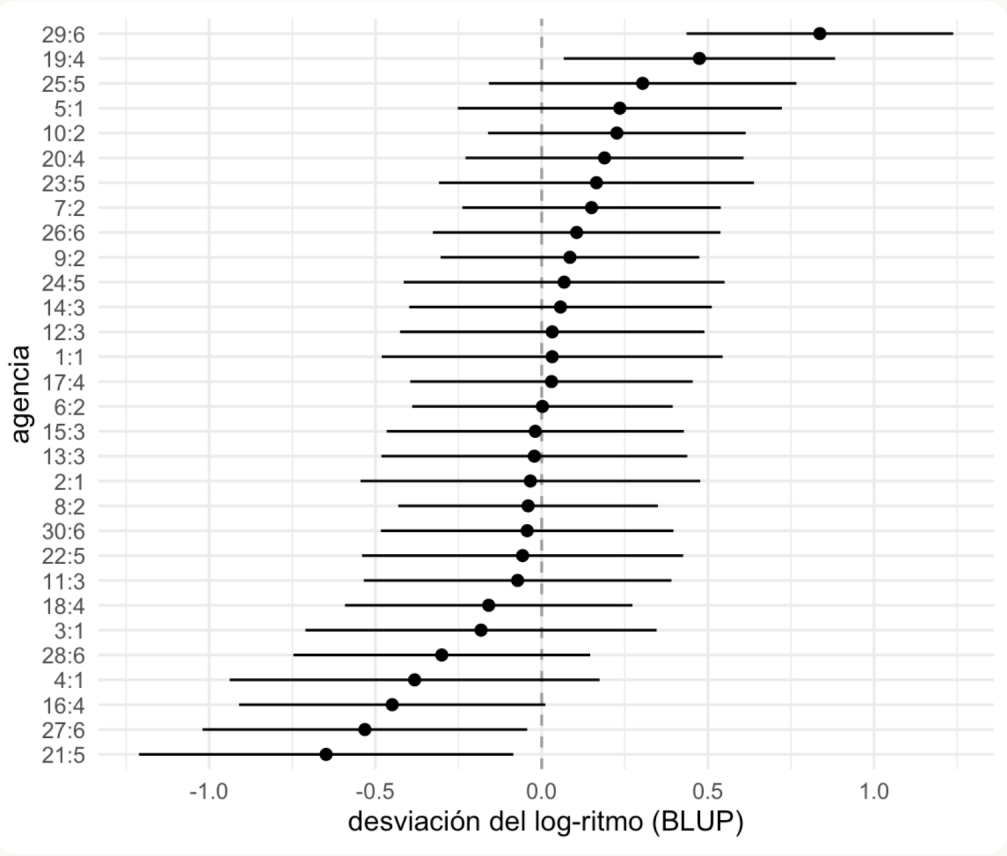
QUITAR LA AGENCIA

LR = 51.37

p corregido = **3.8e−13**

Con **6 regiones**, la aproximación asintótica es frágil: léelo junto al intervalo de σ^{reg}, [0.284; 1.018].

Solo 4 de las 30 agencias se distinguen de su región



QUÉ ES UN BLUP

La moda û del ajuste, **encogida** hacia 0. $\exp(\hat{u}^{ag}{}_j)$ es el **factor** por el que la agencia multiplica la tasa respecto a una agencia típica (u = 0) **de su región**.

EXCLUYEN EL 0

4 / 30

RANGO DEL FACTOR

0.52 – 2.31

de la agencia 21 (región 5) a la 29 (región 6)

No es un IRR: compara un grupo con el típico. Entre regiones, suma su región: $\exp(\hat{u}^{reg} + \hat{u}^{ag})$.

Qué dice el gráfico. Diferencias reales, sí, pero solo en los **extremos**: casi todos los intervalos cortan el 0 y se solapan entre sí. Sirve para **señalar** agencias, no para ordenarlas.

Cuanta menos información, más se encoge

$$\hat{u}^{ag}_{\,j} \approx \lambda_j \cdot \tilde{u}_j \,, \; \lambda_j = I_j \,\sigma^{2ag} / (1 + I_j \,\sigma^{2ag}) \,, \; I_j = \Sigma\, \hat{\mu}_{i\,j}$$

$\tilde{u}_j$: log(observadas / esperadas para una agencia típica de su región). I_j: gestiones que el modelo espera en la agencia.

Agencia	Región	Pólizas	Gestiones	I_j	Cruda $\tilde{u}$	λ	BLUP
4	1	109	6	8.83	−0.77	0.54	−0.38
21	5	111	5	9.79	−1.32	0.57	−0.65
3	1	111	9	10.35	−0.32	0.58	−0.18
29	6	101	74	67.81	0.92	0.90	0.84
7	2	103	71	69.89	0.17	0.90	0.15
10	2	102	76	74.33	0.25	0.91	0.23

Ejemplo. La agencia 4 registra solo 6 gestiones: su desviación cruda, −0.77, se queda en un BLUP de −0.38 (λ = 0.54). Con pólizas parecidas, lo que cuenta son las **gestiones esperadas**.

¿Cuántas gestiones esperamos? Depende de qué sabemos de su agencia

$$\mu = e \cdot \exp(\eta + u),\ \eta = x^{\intercal}\beta,\ u = u^{reg} + u^{ag} \sim N(0, \sigma^2_u),\ \sigma^2_u = \sigma^{2reg} + \sigma^{2ag}$$

Con e = 1, una ventana completa, tasa y número esperado coinciden.

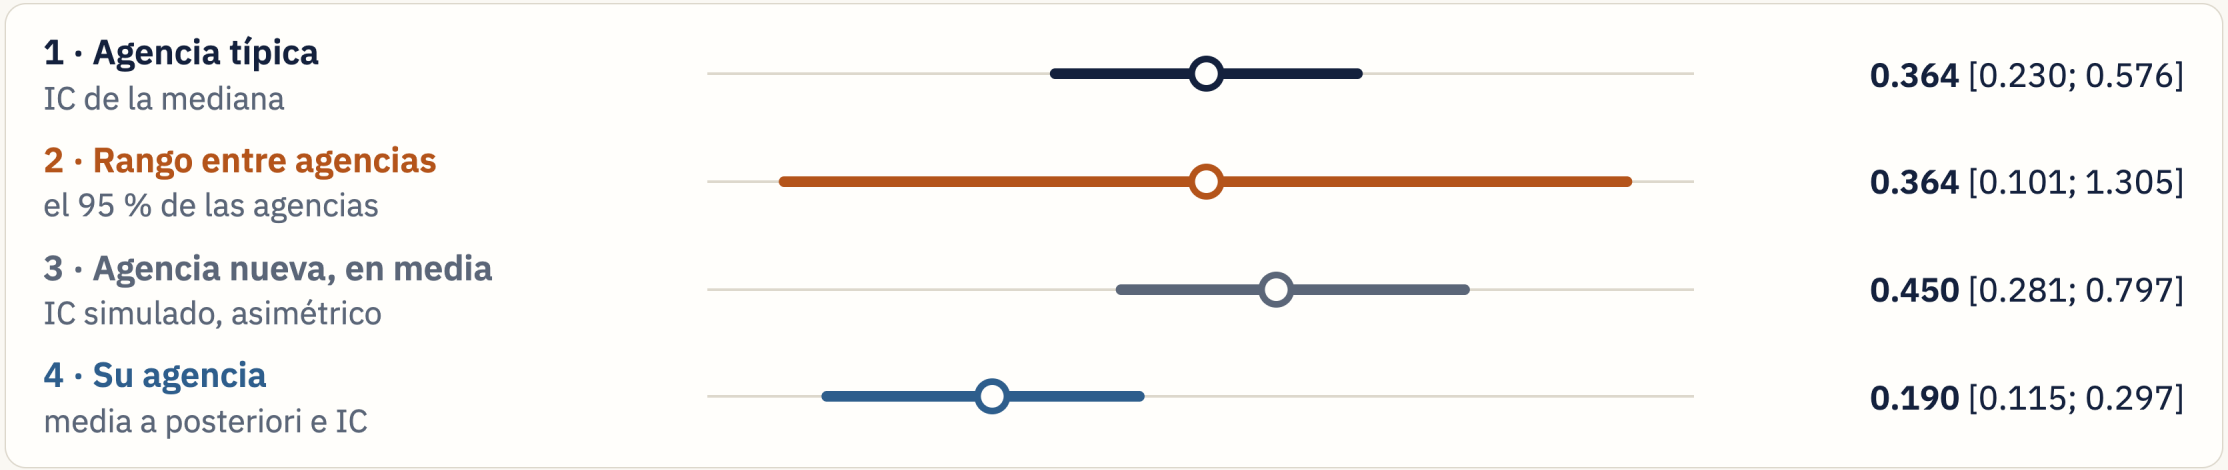
	Situación	Qué se calcula	Incertidumbre	Para qué
1	Agencia típica (u = 0)	$\exp(\hat{\eta})$: la mediana	IC: $\exp(\hat{\eta} \pm 1.96\ SE_{tip})$	comparar perfiles
2	Rango entre agencias	$\exp(\hat{\eta} \pm 1.96\ \hat{\sigma}_u)$	no es un IC: heterogeneidad	medir la heterogeneidad
3	Agencia nueva, en media	$\exp(\hat{\eta} + \hat{\sigma}^2_u/2)$	IC simulando (β, log σ)	planificar
4	Agencia existente	$\exp(\hat{\eta} + \hat{u} + SE^2_{ag}/2)$	IC: $\exp(\hat{\eta} + \hat{u} \pm 1.96\ SE_{ag})$	la cartera actual
5	Número de gestiones	P(Y = k): Poisson-lognormal	distribución predictiva	la operativa

Estimar un valor esperado fijo: intervalo de **confianza**, que se estrecha con más datos.

Predecir algo que varía (una agencia nueva, un conteo): intervalo o distribución de **predicción**, que no.

Saber en qué agencia está pesa más que la incertidumbre de β

Póliza 1, exposición 1 · región 1, lenta ($\hat{u}^{reg} = -0.71$) · tasa esperada, escala log de 0.08 a 1.6



TÍPICA FRENTE A RANGO

IC de 0.230 a 0.576; entre agencias, de 0.101 a 1.305: el extremo alto multiplica por **13** al bajo.

AGENCIA NUEVA

La media, **0.450**, supera a la mediana; su IC se alarga por arriba por la incertidumbre de σ^{reg}.

SU AGENCIA

0.190. Sustituir el BLUP daría 0.184: diferencia pequeña, pero siempre en el mismo sentido.

¿Cuántas gestiones hará la póliza? Una distribución, no un intervalo

$$P(Y = k) = \int \text{Poisson}(k;\, e \cdot e^{t})\ \phi(t;\, m,\, s^2)\ dt$$

Su agencia: $m = \hat{\eta} + \hat{u}$, $s^2 = SE^2_{ag}$ · **agencia nueva**: $m = \hat{\eta}$, $s^2 = SE^2_{tip} + \hat{\sigma}^2_u$. Mezcla **Poisson-lognormal**, como el OLRE (§5.7); una dimensión: integrate(), sin simular.



LECTURA

En su agencia, casi seguro **ninguna** gestión; dos o más, casi descartables. En una nueva, P(Y ≥ 2) se multiplica: región lenta frente a cualquiera, y u desconocido engorda la cola.

POR QUÉ LAS VARIANZAS SE SUMAN

$(\eta + u) - \hat{\eta} = (\eta - \hat{\eta}) + u$, y la u de una agencia nueva es independiente de los datos: $SE^2_{tip} + \sigma^2_u$.

Ningún predictor más, ninguna pendiente aleatoria

¿Sobra alguno? · drop1()

Quitar	LRT	p
potencia_c	23.00	1.6e−6
uso	14.52	1.4e−4

Las dos son necesarias.

¿FALTA ALGUNO? · LOS 14 RESTANTES

Uno a uno sobre potencia + uso (continuos con scale()):

$$\text{mínimo } p = 0.15 \text{ (carnet)}$$

El AIC baja como mucho **0.09**; el BIC **empeora** con todos.

¿PENDIENTES POR REGIÓN?

(0 + x | region), con x **centrada**:

$$LR = 0 \cdot p = 0.5$$

para la potencia y para el uso: su varianza se queda en 0.

Qué concluimos. Potencia y uso, con **solo interceptos aleatorios**: su efecto es el mismo en todas las regiones.

No era sobredispersión: era agrupamiento

CRITERIOS DE INFORMACIÓN

Modelo	AIC	BIC
Poisson	4135.8	4153.9
NB	4115.8	4139.9
GLMM	3824.4	3854.6

El mixto queda muy por delante en los dos criterios.

ÍNDICE DE DISPERSIÓN

POISSON

1.127

$p < 0.001$

→

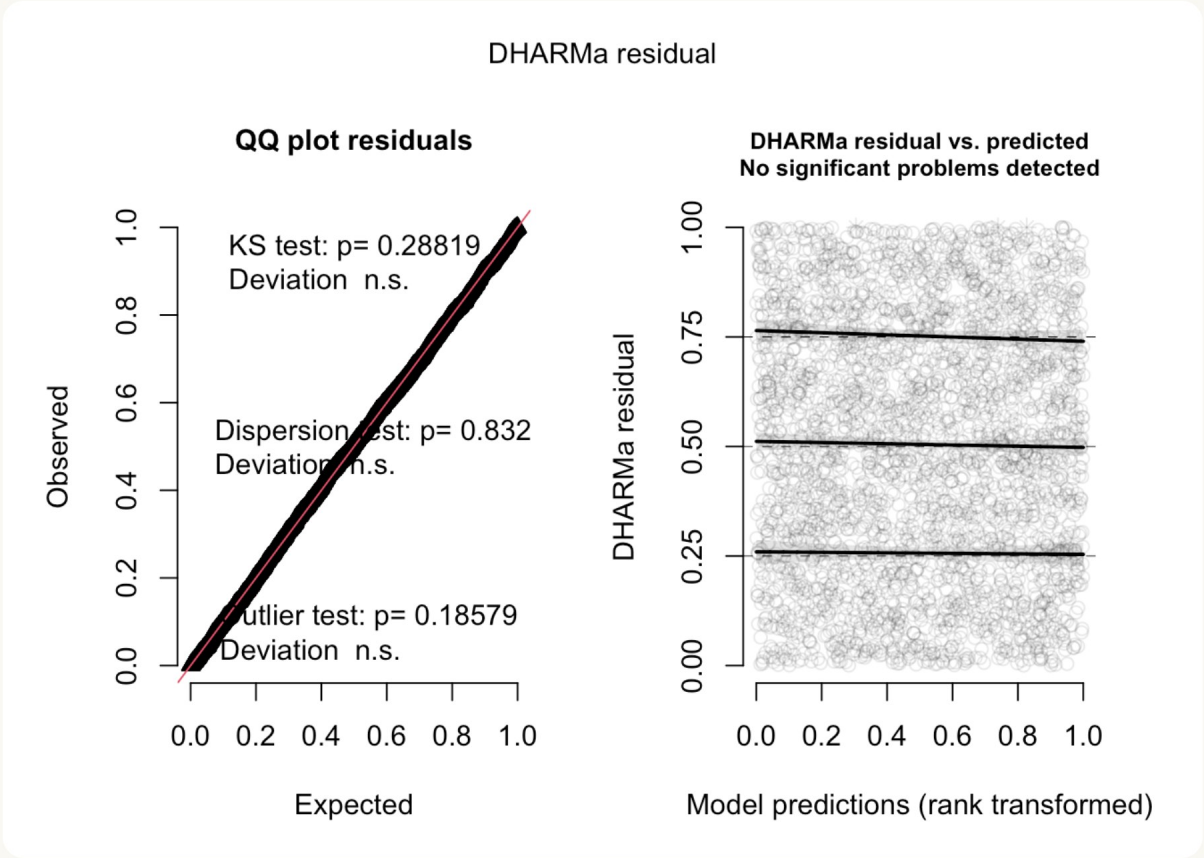
GLMM

0.995

$p = 0.57$

Una vez modelada la jerarquía no queda sobredispersión. Si quedara: **glmmTMB(..., family = nbinom2)**, que combina las dos fuentes. En n_danos ocurre lo contrario: sobredispersión sin grupos (§5.7).

Ningún contraste de DHARMa rechaza



Deviance frente a χ^2: **no**. Media ajustada **0.29**, **76.7 %** de ceros, y no está claro cuántos gl gastan los u.

Contraste DHARMa	p
uniformidad (KS)	0.288
dispersión	0.832
atípicos	0.186
ceros	0.960
cuantiles	0.682

Simula **condicionando** a los efectos aleatorios estimados: dadas región y agencia, ¿son Poisson los conteos?

Los efectos se recuperan; σ^{ag} sale por debajo

Parámetro	Verdad	Estimado	IC 95 %	¿Lo contiene?
σ región	0.50	0.538	[0.284; 1.018]	sí
σ agencia	0.60	0.368	[0.250; 0.542]	no
potencia (por DT)	0.15	0.160	[0.095; 0.224]	sí
uso comercial	0.25	0.324	[0.162; 0.485]	sí

¿Por qué σ^{ag}?

0.60 es la DT de la distribución de la que se **sortearon** las agencias, no la de las 30 que salieron. Con 5 por región, parte de su dispersión cae **entre** regiones y el modelo se la atribuye a la región.

LO QUE NO SE DETECTÓ

Efectos pequeños de edad, zona, tipo y antigüedad del vehículo (como mucho **0.20** en log): con **890** gestiones no hay potencia. Descartar no es demostrar que no existe.

LO QUE SÍ ACERTÓ

Carnet y predictores adicionales, sin efecto, quedaron fuera; y **no hay pendientes aleatorias** en el DGP.

5.7 · EL EFECTO ALEATORIO POR OBSERVACIÓN (OLRE)

El mismo modelo mixto, con un «grupo» por póliza

$$\log \mu_i = \log e_i + x_i^T \beta + v_i \,,\; v_i \sim N(0, \sigma^2_{\beta_s}) \cdot \text{en R: } (1 \mid \text{id_obs})$$

PROBLEMA

n_danos, sobredispersa

En la Unidad 2.3 su varianza superaba con holgura a la media. Una fuente: **heterogeneidad no observada** entre pólizas con las mismas covariables.

PROPUESTA

Un impulso por póliza

Cada póliza multiplica su tasa por su propio **exp(v_i)**: grupos de tamaño 1. No modela dependencia, sino la **heterogeneidad sobrante**.

CONSECUENCIA

Poisson-lognormal

Al integrar v_i, la marginal deja de ser Poisson: una **mezcla** cuya varianza supera a la media.

OLRE · mezcla Poisson-lognormal

$Y \mid v \sim \text{Po}(\lambda\, e^v)$

$e^v \sim \text{LogN}(0, \sigma^2_{\beta_s})$ · mediana 1, media $\exp(\sigma^2_{\beta_s}/2)$

$\text{Var}(Y) = m + (\exp(\sigma^2_{\beta_s}) - 1)\, m^2$ · $m = \lambda \exp(\sigma^2_{\beta_s}/2)$

NB2 · mezcla Poisson-Gamma (Unidad 2.3)

$Y \mid V \sim \text{Po}(\mu\, V)$

$V \sim \text{Ga}(\theta, \theta)$ · media 1, $\text{Var}(V) = 1/\theta$

$\text{Var}(Y) = \mu + \mu^2/\theta$

¿Mediana 1 y media mayor que 1? El multiplicador e^v es asimétrico: la póliza típica ($v = 0$) multiplica su tasa por 1, pero las de v alto la suben más de lo que las de v bajo la reducen, y el promedio queda en $\exp(\sigma^2_{\beta_s}/2) > 1$. En la NB, V tiene media 1. Misma forma cuadrática: **$\exp(\sigma^2_{\beta_s}) - 1$** hace de **$1/\theta$**.

Una heterogeneidad entre pólizas grande e indudable

```
cartera$id_obs ← factor(seq_len(nrow(cartera))) # un nivel por observación
m_olre ← glmmTMB(n_danos ~ edad_conductor + potencia_cv + zona_circulacion + uso + tipo_vehiculo +
                 offset(log(exposicion)) + (1 | id_obs), family = poisson, data = cartera)
```

POISSON: DISPERSIÓN

2.393

p < 0.001 · check_overdispersion()

$\hat{\sigma}_{o\beta s}$, escala log

0.94

IC 95 %: [0.89; 1.00] · estrecho: 3071 pólizas

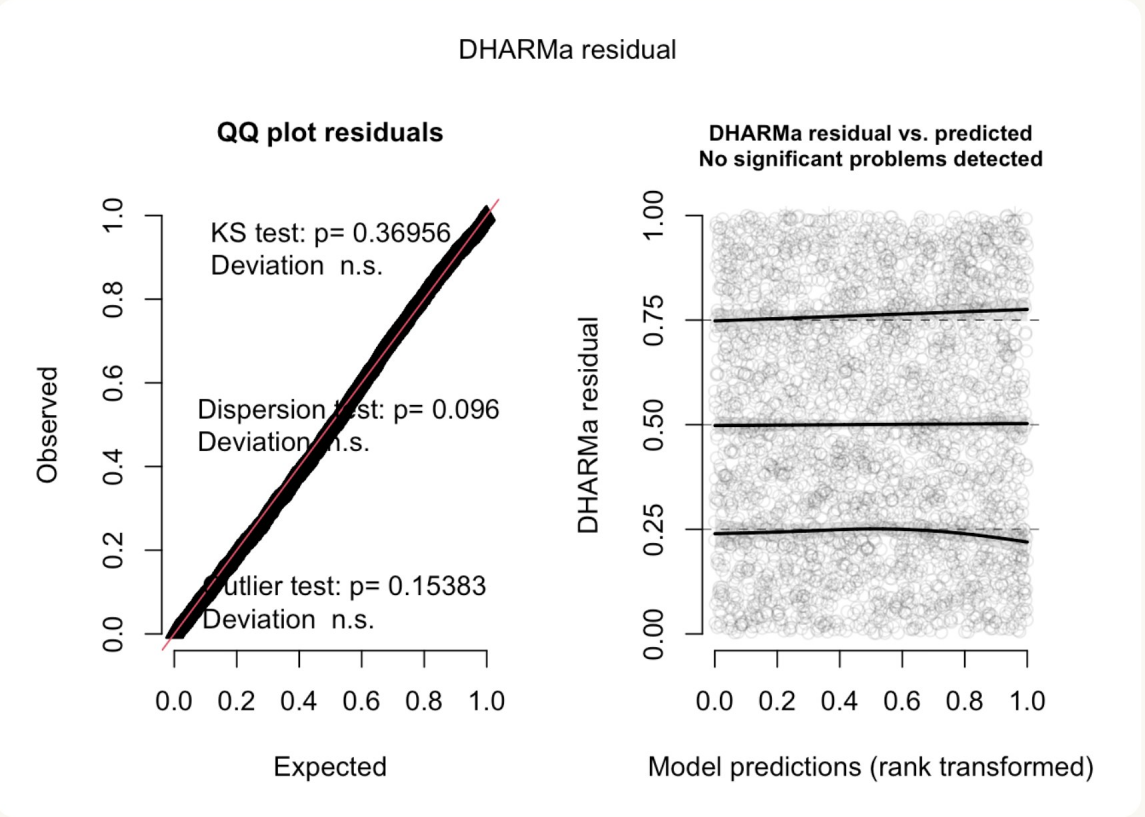
Frontera: $\sigma_{o\beta s} = 0$

LR = 1357.5

p = ½ Pr(χ^2_1 > LR): indudable

Qué significa. El multiplicador exp(v_i) es lognormal con mediana 1: el 95 % de las pólizas multiplica su tasa por un factor entre **0.16** y **6.34** respecto a lo que predicen sus covariables. Los IRR se leen **netos** de esa variabilidad.

Simular sin condicionar: un impulso nuevo en cada réplica



No simulateResiduals(m_olre): cada $\hat{v}_i$ se estima con su propia y_i, y condicionar apiña los residuos en 0.5 aunque el modelo sea correcto.

```
sim ← replicate(250, rpois(n, lam * exp(rnorm(n, 0, s))))
createDHARMa(sim, y, lam * exp(s^2 / 2))
```

Contraste	p
uniformidad	0.370
dispersión	0.096
atípicos	0.154
ceros	0.224

Absorbe la sobredispersión y reproduce los ceros.

5.7 · OLRE FRENTE A BINOMIAL NEGATIVA

Dos lentes para la misma sobredispersión

n_danos · 9 parámetros cada corrección

Modelo	AIC	BIC
Poisson	10765.9	10814.1
NB2 · Poisson-Gamma	9417.7	9471.9
OLRE · Poisson-lognormal	9410.4	9464.6

Anidadas en la Poisson (frontera), pero **no entre sí**: solo las compara el AIC.

DIFERENCIA OLRE – NB2

7.3 puntos

Pequeña, y el AIC del OLRE descansa en Laplace, poco precisa con un efecto por fila y conteos bajos: **no concluyente**.

NB2

La opción práctica por defecto: distribución cerrada y más rápida.

OLRE

La natural cuando el modelo **ya tiene** otros efectos aleatorios: separa la dispersión de observación de la de grupo.

CONCLUSIONES

Las tres preguntas de la dirección, respondidas

1 · ¿DÓNDE ESTÁ LA VARIACIÓN?

0.177 · 0.083

región · agencia; las covariables, **0.023**. La región pesa 2.1 veces la agencia; las dos, 11 veces las covariables.

2 · ¿QUÉ AGENCIAS SE DESVÍAN?

4 de 30

excluyen el 0; factores de 0.52 a 2.31 respecto a su región, encogidos según su información.

3 · ¿Y UNA AGENCIA NUEVA?

0.450

tasa media para la póliza 1, IC [0.281; 0.797]; entre agencias va de 0.101 a 1.305. En su agencia, **0.190**.

Dónde se tramita una póliza pesa más que **qué** se asegura. A igual agencia, el uso comercial acelera las gestiones un **38 %**. La sobredispersión aparente era **agrupamiento**: el mixto la absorbe (dispersión 0.995).

RECETA PARA DATOS AGRUPADOS

La operativa, paso a paso, en R

1	**¿Hay agrupamiento?**	`group_by(region, agencia) ▷ summarise(tasa = sum(y) / sum(t))`
2	**Formula el anidamiento**	`y ~ ... + offset(log(t)) + (1 | region/agencia)`
3	**Criba predictores**	`update(m_nulo, . ~ . + x)` y LRT, uno a uno sobre el mixto nulo
4	**Ajusta e interpreta**	`glmmTMB(..., family = poisson)` · exp(β) e IC de Wald
5	**Reparte la varianza**	`confint(m, parm = "theta_")` · `get_variance()` · `r2()` · `icc()` · p/2
6	**Agencias y predicción**	`ranef(condVar = TRUE)` · `predict(re.form = NA)` · `mvrnorm` · `integrate()`
7	**Selecciona y diagnostica**	`drop1()` · `(0 + x_c | region)` · `check_overdispersion()` · DHARMa
8	**Valida contra el DGP**	`attr(cartera, "verdad")`: ¿cada verdad dentro de su IC?

Sobredispersión sin grupos: **(1 | id_obs)**, el OLRE, con DHARMa incondicional.

CIERRE

Lo que hay que llevarse

1

Agrupado no es independiente

Pólizas de una agencia, agencias de una región: (1 | region/agencia)

2

Cribar sobre el mixto

El margen confunde predictor y agrupamiento: LRT sobre el mixto nulo

3

IRR condicional = poblacional

Solo con enlace log y sin pendientes aleatorias

4

Varianzas en la frontera

$\sigma^2 = 0$ en el borde: p/2; con pocos grupos, mira el IC

5

BLUP: factor encogido

Menos gestiones esperadas, más encogimiento; señala, no ordena

6

Di qué predicción das

Típica, rango, media de una nueva, la de su agencia o el conteo

Y el **OLRE**: un efecto aleatorio por fila es sobredispersión, no agrupamiento; se diagnostica sin condicionar.