

Guía docente · Modelos Lineales Generalizados con R

Grado en Ciencia de Datos e Inteligencia Artificial · Universidad Miguel Hernández

A. M. Mayoral

3/9/26

Tabla de contenidos

1. Contexto de la asignatura y requisitos	2
Por qué esta asignatura	2
Enfoque problema-primerero	3
Requisitos previos	3
2. Objetivos de aprendizaje	3
Objetivos generales del curso	3
Resultados de aprendizaje por caso	4
3. Metodología	4
Cómo se trabaja	4
Tres hilos transversales	5
Pila de software	5
4. Contenidos	5
Caso 1 · «¿Ocurre el evento? ¿Y cuándo?»	6
Caso 2 · «¿Cuántas veces y a qué ritmo?»	6
Caso 3 · «¿Cuánto y hasta cuándo?»	7
5. Cronograma	9
6. Sistema de evaluación	11
Dos itinerarios	11
Los proyectos grupales	12
Factor individual de implicación (w)	13

Examen oral individual	13
7. Rúbricas y plantillas	14
Rúbricas de la evaluación continua	14
Rúbricas de la evaluación final	15
Guías y plantillas de entrega	15
8. Bibliografía	16
Bibliografía básica	16
Bibliografía complementaria	16
Fuentes primarias que vertebran el curso	16
Software	17
Referencias citadas en este documento	17

i Sobre este documento

Versión **simplificada y de trabajo** de la guía docente, alineada con el material del curso. La guía oficial (`guia_docente_GLM_R.docx`) conserva los campos administrativos y sus versiones en valenciano e inglés, y prevalece en caso de discrepancia formal. Aquí se recoge lo que el profesorado y el estudiantado necesitan para trabajar.

1. Contexto de la asignatura y requisitos

Titulación	Grado en Ciencia de Datos e Inteligencia Artificial
Curso y carga	Tercer curso · 6 ECTS · 15 semanas · 60 h de clase
Lenguaje de trabajo	R (con Quarto y Git)
Enfoque	Portafolio de tres estudios de caso, resolución de problemas
Formato de sesión	4 h semanales: teoría + práctica integradas

Por qué esta asignatura

Los modelos lineales generalizados son una herramienta central del análisis de datos profesional: predicen e interpretan respuestas **binarias**, de **recuento**, **categorías** y **continuas asimétricas** en sanidad (riesgo clínico), banca y seguros (impago, siniestralidad), marketing (conversión, abandono) o industria (calidad y mantenimiento). Saber ajustarlos y diagnosticarlos en R, interpretarlos en la escala correcta y comunicarlos en distintos formatos es una base imprescindible en la formación de un científico de datos, que lo diferencia sustancialmente del resto de profesionales vinculados al tratamiento de datos.

La asignatura capacita para **elegir, ajustar, diagnosticar e interpretar** el GLM adecuado a cada tipo de respuesta, y para reconocer los datos **censurados de tiempo-a-evento** como casos especiales del propio marco, . El hilo conductor es el ciclo completo de modelización: del dato al modelo, del modelo al diagnóstico, y del diagnóstico a la interpretación y finalmente la comunicación.

Enfoque problema-primero

El curso no arranca con teoría abstracta, sino con **datos sobre los que el modelo lineal clásico falla de forma evidente** —probabilidades predichas imposibles, residuos heterocedásticos, soporte acotado—. Esa insuficiencia motiva la necesidad del GLM, y la teoría se introduce a demanda, bajo el paraguas de un estudio de caso que se resuelve por etapas. Cada bloque termina con un caso completo que el estudiantado desarrolla, expone y defiende.

Requisitos previos

Cálculo, álgebra lineal, probabilidad e inferencia estadística básica, regresión lineal por mínimos cuadrados y soltura en programación. **No se exige experiencia previa en R:** se introduce de forma progresiva desde el primer estudio de caso.

2. Objetivos de aprendizaje

Objetivos generales del curso

Objetivo	
O1	Reconocer el marco común de los GLM. Estructura común (familia exponencial, predictor lineal, función de enlace) y justificación de cuándo un dato exige un GLM frente a OLS.
O2	Respuestas binarias y politómicas. Logística y binomial agrupada, politómica nominal y ordinal: <i>odds ratios</i> y probabilidades, separación y calibración, selección por <i>deviance</i> y AIC/BIC.
O3	Conteos y tasas. Poisson y binomial negativa con <i>offset</i> : razones de tasas, sobredispersión, exceso de ceros, y selección por AIC/BIC, validación cruzada y regularización.
O4	Magnitudes positivas y vida útil. Gamma y log-normal con enlace log, Tweedie para importes agregados con ceros, y modelos AFT : interpretación multiplicativa y diagnóstico del ajuste.

Objetivo	
O5	Extender a mixtos y supervivencia. GLMM sobre datos agrupados y tiempo-a-evento censurado (tiempo discreto, riesgos a trozos, AFT), con Cox como frontera del marco. Dos hilos en espiral.
O6	Comunicar y reproducir. Desarrollar, presentar y defender estudios de caso reproducibles ante audiencias técnicas y profesionales, en distintos formatos.

Resultados de aprendizaje por caso

Cada bloque desarrolla los objetivos en **resultados de aprendizaje concretos (RA)**, listados al inicio del documento del caso y vinculados unidad a unidad en su *Mapa del caso*.

Caso	RA	Objetivos que desarrolla
Caso 1 · Respuestas binarias y tiempo hasta el evento	RA1–RA8	O1, O2, O5 (inicio de los dos hilos), O6
Caso 2 · Conteos, tasas e intensidad del riesgo	RA1–RA9	O3, O5 (mixtos y riesgos a trozos), O6
Caso 3 · Magnitudes positivas y vida útil	RA1–RA9	O4, O5 (AFT, Cox, fragilidad), O6

3. Metodología

Cómo se trabaja

Cada estudio de caso se construye en **sesiones de laboratorio con acompañamiento docente**, sobre datos reales o simulados con proceso generador conocido, y siempre de forma **reproducible** (Quarto + Git). La teoría se imparte integrada en cada caso y se consolida en sesiones de síntesis. Las primeras sesiones de cada bloque son de fundamentación; la última, de trabajo del caso y exposiciones.

Un rasgo distintivo del material: los bancos de datos están **simulados con verdad conocida**. El estudiantado ajusta **a ciegas** y valida **al final** contra los parámetros generadores, un control de calidad que ningún dato real permite y que convierte cada unidad en un experimento comprobable.

Tres hilos transversales

- **Comunicación.** Desde el primer caso se trabaja la estructura del informe de modelización y la interpretación en la escala correcta; se practica con un informe y una exposición por bloque, con **tipología distinta** en cada uno.
- **Efectos mixtos (en espiral).** Los datos agrupados y los efectos aleatorios se introducen en el Caso 1 (intercepto aleatorio), se reactivan en el Caso 2 (GLMM de conteo) y culminan en el Caso 3 (GLMM Gamma y Tweedie, fragilidad de Cox), en lugar de quedar como un tema terminal aislado.
- **Censura y supervivencia (en espiral).** El andamiaje —supervivencia, *hazard*, conjunto de riesgo, censura— se introduce una sola vez al final del Caso 1 y se reactiva en cada bloque. La supervivencia se presenta como **caso especial del marco GLM**: los riesgos a trozos equivalen a una Poisson con *offset* (Aitkin & Clayton, 1980; Holford, 1980; Laird & Olivier, 1981), el tiempo discreto a un modelo binario con enlace **cloglog** (Prentice & Gloeckler, 1978), y Cox se sitúa como referencia semiparamétrica fuera del marco (Cox, 1972). La **Unidad 3.7** cierra el hilo comparando las tres lentes sobre los mismos datos.

Pila de software

Papel	Paquetes
Núcleo	<code>stats::glm()</code> , <code>tidyverse</code> , <code>broom</code> , <code>broom.mixed</code>
Interpretación	<code>marginalEffects</code> , <code>emmeans</code> , <code>ggeffects</code> , <code>car</code>
Diagnóstico	<code>DHARMa</code> , <code>performance</code> , <code>pROC</code>
Modelos específicos	<code>MASS</code> (NB, ordinal), <code>nnet</code> / <code>VGAM</code> (politómicas), <code>pscl</code> (ceros), <code>glmmTMB</code> (GLMM, ceros y Tweedie), <code>glmnet</code> (regularización), <code>lme4</code> (GLMM)
Supervivencia	<code>survival</code> , <code>survminer</code> , <code>flexsurv</code>
Validación	<code>rsample</code> (validación cruzada agrupada)
Entorno	<code>Quarto</code> , <code>renv</code> , <code>Git</code>

4. Contenidos

La asignatura se organiza en **tres estudios de caso**, uno por familia de modelos, con **22 unidades** repartidas en **cinco semanas por bloque**. En cada uno, las cuatro primeras semanas son de fundamentación y la quinta se dedica al estudio de caso y a las exposiciones.

Caso 1 · «¿Ocurre el evento? ¿Y cuándo?»

Respuestas binarias y tiempo hasta el evento. Entrada al marco GLM desde una respuesta dicotómica: dónde falla el modelo lineal, cómo se formula y estima un GLM, y cómo se interpreta y evalúa.

Unidad	Contenido
1.1	Cuando la recta no llega: OLS falla en binaria; los tres componentes del GLM; tipología de respuestas; primer <code>glm</code> .
1.2	Logística: familia exponencial, enlace, IWLS y <i>deviance</i> ; inferencia; interpretación (OR, efectos marginales); evaluación y comparación de clasificadores.
1.3	Respuesta categórica generalizada: binomial agrupada (bondad de ajuste con χ^2) y politómicas —multinomial nominal y ordinal (odds proporcionales)—.
1.4	Datos agrupados: GLMM logístico con intercepto y pendiente aleatorios; validación con datos reales (GLOW); puente a la supervivencia.
1.5	Supervivencia: función de supervivencia, <i>hazard</i> , riesgos proporcionales; el tiempo discreto como GLM (<code>cloglog</code> persona-periodo).
1.6	Estudio de caso, exposiciones y evaluación.

Bibliografía del bloque. Dobson & Barnett (2018) (caps. 1–5, 7); Agresti (2015) (caps. 4–7); Nelder & Wedderburn (1972); McCullagh & Nelder (1989) (caps. 1–2); Faraway (2016) (caps. 2, 5–8); Hosmer et al. (2013); Allison (1982); Prentice & Gloeckler (1978).

Caso 2 · «¿Cuántas veces y a qué ritmo?»

Conteos, tasas e intensidad del riesgo. La familia Poisson y sus extensiones, sobre una cartera de seguro de automóvil.

Unidad	Contenido
2.1	Poisson y log-lineal: recuentos, tasas y <i>offset</i> ; IRR; tablas de contingencia y de cambio; inferencia, bondad de ajuste y predicción.
2.2 (<i>ampliación</i>)	Modelos log-lineales para tablas: esquemas de muestreo y grados de libertad, jerarquía de tres vías, paradoja de Simpson, diagnóstico de celdas, tablas cuadradas y detección de <i>proxies</i> .
2.3	Sobredispersión: causas, diagnóstico, quasi-Poisson y binomial negativa.
2.4	Exceso de ceros: modelos de barrera (<i>hurdle</i>) e inflados de ceros (ZIP/ZINB).
2.5	Conteos agrupados: GLMM de Poisson (componentes de varianza, ICC, BLUP).
2.6	Del conteo al reloj: riesgos a trozos $\equiv$ Poisson con <i>offset</i> ; fragilidad.
2.7	Selección, validación cruzada y regularización (glmnet sobre Poisson).
2.8	Estudio de caso, exposiciones y evaluación.

Bibliografía del bloque. Hilbe (2014) (caps. 1–8, 11–12); Dobson & Barnett (2018) (cap. 9); Agresti (2015) (cap. 7); Faraway (2016) (cap. 5); McCullagh & Nelder (1989) (cap. 6); Lambert (1992); Mullahy (1986); Holford (1980); Laird & Olivier (1981); Friedman et al. (2010); Tibshirani (1996).

Caso 3 · «¿Cuánto y hasta cuándo?»

Magnitudes positivas y vida útil hasta el fallo. Respuestas continuas positivas, su agregado con ceros, y las fronteras del marco, sobre un banco de averías de una línea de fabricación.

Unidad	Contenido
3.1	GLM Gamma : el coste de una avería. Dónde falla el gaussiano; enlaces log e inverso; dispersión ϕ ; interpretación multiplicativa; inferencia, diagnóstico y validación.
3.2	Elegir familia y escala : inversa gaussiana y lognormal (log-OLS) frente a Gamma; la relación media-varianza como criterio; <i>smearing</i> de Duan; modelar la dispersión; AIC con jacobiano.
3.3	GLMM Gamma : intercepto y pendiente aleatorios por máquina; condicional frente a marginal; resolución de la $\hat{\phi}$ inflada y del falso positivo.
3.4	Tweedie : el coste anual con ceros como mezcla Poisson–Gamma; la recta $\text{Var} = \phi\mu^p$ y el índice p ; presupuesto con intervalo; GLMM Tweedie y validación cruzada agrupada .
3.5	AFT : Kaplan–Meier; tiempos entre fallos; censura en la verosimilitud; exponencial, Weibull, log-normal y log-logística; factor de aceleración.
3.6	Cox como frontera : riesgos proporcionales, verosimilitud parcial y por qué no es un GLM; fragilidad ; diagnóstico de proporcionalidad; Cox extendido con covariables dependientes del tiempo.
3.7	Cierre : las tres lentes del mismo fallo (cloglog, Poisson a trozos, Cox) y un mapa de fronteras del marco (dos partes, GAM, eventos recurrentes, riesgos competitivos, bayesiano).
3.8	Estudio de caso, exposiciones y evaluación.

Bibliografía del bloque. Dobson & Barnett (2018) (cap. 8); McCullagh & Nelder (1989)

(cap. 8); Faraway (2016) (cap. 9); Fox (2016) (cap. 15); Tweedie (1984); Jørgensen (1997); Dunn & Smyth (2005); Cox (1972); Therneau & Grambsch (2000); Grambsch & Therneau (1994); Vaupel et al. (1979); Self & Liang (1987).

5. Cronograma

Quince semanas y **60 horas de clase**: 2 h de teoría y 2 h de laboratorio por semana. Cada bloque ocupa **cinco semanas** —cuatro de fundamentación y una de estudio de caso—, de modo que las **defensas** (exposición y Q&A individual) se celebran tres veces a lo largo del curso, repartiendo la evaluación individual y evitando el cuello de botella del periodo de examen.

Sem.	Bloque	Teoría (2 h)	Laboratorio (2 h)	Unidades
1	Caso 1	OLS falla en binaria; los tres componentes del GLM	Refresco de R/tidyverse; primer <code>glm(binomial)</code>	1.1
2	Caso 1	Familia exponencial y enlace; MV e IWLS; <i>deviance</i>	<code>family()</code> , enlaces logit/probit; lectura del <code>summary</code>	1.2
3	Caso 1	Inferencia (Wald, LRT, AIC/BIC); OR y efectos marginales; evaluación de clasificadores	<code>marginalEffects</code> , <code>emmeans</code> , <code>pROC</code> , <code>DHARMa</code>	1.2
4	Caso 1	Politómicas; datos agrupados (efectos aleatorios); tiempo discreto y <i>hazard</i>	<code>nnet/MASS</code> ; <code>glmer</code> ; <code>personaperiodo</code> con <code>cloglog</code>	1.3–1.5

Sem.	Bloque	Teoría (2 h)	Laboratorio (2 h)	Unidades
5	Caso 1	—	Estudio de caso, exposiciones y defensas	1.6
6	Caso 2	Poisson; tasas, <i>offset</i> e IRR; inferencia y predicción	<code>glm(poisson)</code> + <i>offset</i> ; <code>marginaleffects</code>	2.1
7	Caso 2	Modelos log-lineales para tablas; sobredispersión	Tablas de contingencia y cuadradas; <code>glm.nb</code> , quasi-Poisson	2.2, 2.3
8	Caso 2	Exceso de ceros; conteos agrupados	<code>pscl/glmTMB</code> ; <code>glmer</code> ; ICC y BLUP	2.4, 2.5
9	Caso 2	Riesgos a trozos Poisson; selección, CV y regularización	Persona- periodo; <code>glmnet</code> , <code>cv.glmnet</code>	2.6, 2.7
10	Caso 2	—	Estudio de caso, exposiciones y defensas	2.8
11	Caso 3	Gamma e inversa gaussiana; enlaces; media- varianza y log-OLS	<code>glm(Gamma(link="log"))</code> ; <i>smearing</i> ; comparación por AIC	3.2
12	Caso 3	GLMM Gamma; la familia Tweedie y el índice p	<code>glmmTMB</code> (Gamma y <code>tweedie</code>); DHARMA; <code>group_vfold_cv</code>	3.3, 3.4

Sem.	Bloque	Teoría (2 h)	Laboratorio (2 h)	Unidades
13	Caso 3	Tiempo hasta el fallo: censura y modelos AFT	Surv, survfit, survreg; survminer	3.5
14	Caso 3	Cox como frontera y proporcionalidad; las tres lentes y las fronteras del marco	coxph, frailty, cox.zph; comparación de las tres lentes	3.6, 3.7
15	Caso 3	—	Estudio de caso , exposiciones, defensas y cierre	3.8

Dónde está la holgura

Las semanas **4** y **14** son las más densas: la primera encadena politómicas, efectos aleatorios y tiempo discreto; la segunda, el Cox extendido y el cierre del hilo de supervivencia. Si el ritmo se resiente hay dos amortiguadores previstos: la **Unidad 2.2** es de ampliación, y la **Sección 7.2** del cierre —el mapa de fronteras— se lee de forma autónoma y puede quedar como lectura guiada.

6. Sistema de evaluación

Dos itinerarios

Evaluación continua. Requiere seguimiento sostenido. Es sumativa y se construye sobre **tres proyectos grupales** —uno por bloque, en equipos cooperativos de un máximo de tres personas, con coevaluación 360— y un **examen oral individual** vinculado a cada proyecto.

Componente	Peso
Proyectos grupales (ponderados por implicación individual)	60 %
Exámenes orales individuales	40 %

Ambos se reparten equitativamente entre los tres proyectos. Para superar la evaluación continua se exige un mínimo de **3,5/10 en cada prueba** (grupal e individual) y una media ponderada ≥ 5 .

Evaluación final. Para quien no participe o no supere la continua, en convocatoria ordinaria o extraordinaria: un **examen final** que aporta el 100 % de la calificación, planteado a partir de uno o varios estudios de caso resueltos total o parcialmente, sobre los que se desarrolla un **informe escrito** (50 %) y su **defensa oral** (50 %). Sin recursos de consulta.

Los proyectos grupales

Cada estudiante asume un **rol** con tareas definidas, que **rota** de un proyecto al siguiente de modo que pasa por los tres:

- **Coordinación** — planificación y plazos, consultas al profesorado, integración y revisión de la coherencia del conjunto, bitácora del equipo y control de versiones.
- **Análisis** — datos, modelización, código reproducible y validación técnica (diagnóstico).
- **Comunicación** — informe, narrativa y diseño de la exposición.

La nota grupal se compone de **informe (50 %)**, **exposición (40 %)** y **defensa oral / Q&A (10 %)**, y se pondera por el factor individual de implicación:

$$\text{Gru} = (0,5 \text{ Inf} + 0,4 \text{ Expo} + 0,1 \text{ Def}) \cdot w$$

Tipología de informe, distinta en cada bloque:

Bloque	Formato del informe
Caso 1	Informe técnico
Caso 2	Informe ejecutivo dirigido a empresa
Caso 3	Artículo de investigación

! Uso ético de la IA

Todo informe incluye un apartado **obligatorio** de reflexión sobre el uso de la IA: qué herramientas se usaron, para qué y **cómo se verificaron sus respuestas**. Sin ese

apartado, el informe no puede alcanzar la calificación de «excelente».

Factor individual de implicación (w)

Se obtiene de la **bitácora individual** y de la **coevaluación 360** que se entregan con cada proyecto, a partir de la **mediana** de las puntuaciones de implicación recibidas (escala 0–4) —robusta a un voto atípico—:

Banda	Mediana	w
Implicación plena	≥ 3	1,00
Implicación parcial	1,5 – 2,9	0,80
Implicación insuficiente	$< 1,5$	$\leq 0,50$

Salvaguardas. Las coevaluaciones emitidas por quien queda en la banda insuficiente no computan al evaluar a los demás; no entregar la bitácora o la coevaluación limita w a un máximo de 0,80; y el profesorado revisa, con la bitácora y la evidencia de contribución (*com-mits*), cualquier discrepancia antes de fijar w .

La **bitácora** recoge rol asumido, tareas realizadas, incidencias, uso de recursos (apuntes/IA), percepción del aprendizaje y valoración global. La **coevaluación 360** puntúa a cada compañero de 0 a 4 en **cumplimiento**, **contribución** y **colaboración**.

Examen oral individual

Individual, en sesión de tutoría, en fecha posterior a la corrección del proyecto y no más de una semana después. Duración de **10 a 12 minutos**, sin apoyos salvo la propia presentación. Tres bloques, cada uno con una cuestión:

Bloque	Contenido	Peso
1	Justificación de respuestas e interpretación de un resultado	40 %
2	Solución a un punto débil señalado en la corrección	35 %

Bloque	Contenido	Peso
3	Extensión o nuevo reto sobre el problema ya resuelto	25 %

7. Rúbricas y plantillas

Todas las rúbricas usan la escala **0–3**. Aquí figuran los criterios y sus pesos; los descriptores de cada nivel están en el libro de rúbricas, `evaluacion/Rubricas_evaluacion.xlsx`, y desarrollados en `evaluacion/Rubricas_evaluacion_desarrolladas.docx`.

Rúbricas de la evaluación continua

Informe

Criterio	Peso
Problema, audiencia y objetivos	20 %
Datos, método y reproducibilidad	20 %
Resultados, visualización e interpretación	30 %
Redacción, formato y referencias (APA 7)	20 %
Uso ético de la IA	10 %

Exposición y defensa

Criterio	Peso
Narrativa: hilo entre audiencia, contexto, resultados, implicaciones y cierre	12,5 %
Soporte visual: estética y estructura de las diapositivas	7,5 %
Foco: ideas clave, resultados y justificaciones	12,5 %
Desempeño: oralidad, tiempos y decoro	7,5 %
Defensa (Q&A): corrección y justificación de la respuesta	10 %

Examen oral — los tres bloques de §6, con pesos 40 % / 35 % / 25 %.

Rúbricas de la evaluación final

Aplicables **solo** en la evaluación final. No incluyen uso de IA ni referencias: el foco es técnico y comunicativo.

Informe (50 %)	Peso	Defensa oral (50 %)	Peso
Justificaciones técnicas e interpretación	35 %	Justificación y corrección técnica	40 %
Soluciones e implicaciones derivadas	25 %	Interpretación	35 %
Comunicación escrita	20 %	Comunicación oral	25 %
Ajuste al formato estandarizado	20 %		

Guías y plantillas de entrega

En la carpeta **evaluacion/** del material del curso:

Recurso	Fichero
Guía de redacción de informes (los tres formatos)	Guia_informes_eficaces_datos_tres_formatos.docx
Guía de presentaciones eficaces	Guia_presentaciones_eficaces_datos_tres_formatos.docx
Plantilla de informe técnico (Caso 1)	Plantillas_informes_tres_formatos/Plantilla_informe_tecnico.docx
Plantilla de informe ejecutivo (Caso 2)	Plantillas_informes_tres_formatos/Plantilla_informe_ejecutivo.docx
Plantilla de artículo científico (Caso 3)	Plantillas_informes_tres_formatos/Plantilla_articulo_cientifico.docx
Libro de rúbricas	Rubricas_evaluacion.xlsx · Rubricas_evaluacion_desarrolladas.docx

Las plantillas están en Quarto: se escribe encima y el análisis y el texto quedan en el mismo fichero, lo que resuelve buena parte del requisito de reproducibilidad.

8. Bibliografía

Referencias en formato **APA 7.^a edición**. El material del curso cita más de sesenta fuentes primarias, todas recogidas en `references.bib` y listadas en la [página de referencias](#) del sitio. Aquí figura la selección esencial.

Bibliografía básica

- Dobson & Barnett (2018) — texto principal y autoridad de la guía.
- Agresti (2015)
- Faraway (2016) — el de referencia para la práctica en R.
- Hosmer et al. (2013) — específico de regresión logística.
- McCullagh & Nelder (1989) — referencia clásica del marco.

Bibliografía complementaria

- Fox (2016) — puente desde la regresión clásica al GLM.
- Harrell (2015) — estrategias de modelización y validación.
- Hilbe (2014) — el texto del Caso 2.
- Agresti (2013) — respuestas categóricas en profundidad.
- Venables & Ripley (2002) — los paquetes `MASS`/`nnet`.
- James et al. (2021) — aprendizaje estadístico, selección y regularización.
- Therneau & Grambsch (2000) — supervivencia y extensiones del modelo de Cox.

Fuentes primarias que vertebran el curso

Tema	Referencia
El marco GLM	Nelder & Wedderburn (1972)
Cox y riesgos proporcionales	Cox (1972) · Cox (1975)
Supervivencia como GLM	Holford (1980) · Laird & Olivier (1981) · Aitkin & Clayton (1980) · Prentice & Gloeckler (1978)
Diagnóstico de proporcionalidad	Schoenfeld (1982) · Grambsch & Therneau (1994)
Fragilidad	Vaupel et al. (1979)
Exceso de ceros	Lambert (1992) · Mullahy (1986)
Familia Tweedie	Tweedie (1984) · Jørgensen (1987) · Jørgensen (1997) · Dunn & Smyth (2005)
Retransformación	Duan (1983)

Tema	Referencia
Componentes de varianza en la frontera Regularización	Self & Liang (1987) · Stram & Lee (1994) Hoerl & Kennard (1970) · Tibshirani (1996) · Friedman et al. (2010)
Selección de modelos	Akaike (1974) · Schwarz (1978) · Burnham & Anderson (2002) · Stone (1974)

Software

R Core Team (2024) y los paquetes de la pila de la sección 3. Con cita formal: `lme4` (Bates et al., 2015), `glmnet` (Friedman et al., 2010), `survival` (Therneau, 2024), `DHARMa` (Hartig, 2024), `marginalEffects` (Arel-Bundock et al., 2024), `pROC` (Robin et al., 2011). Complementarios sin cita formal: `tidyverse`, `broom`, `emmeans`, `ggeffects`, `performance`, `MASS`, `nnet`, `pscl`, `glmmTMB`, `survminer`, `flexsurv`, `rsample`.

Referencias citadas en este documento

- Agresti, A. (2013). *Categorical Data Analysis* (3.^a ed.). Wiley.
- Agresti, A. (2015). *Foundations of Linear and Generalized Linear Models*. Wiley.
- Aitkin, M., & Clayton, D. (1980). The Fitting of Exponential, Weibull and Extreme Value Distributions to Complex Censored Survival Data Using GLIM. *Journal of the Royal Statistical Society. Series C (Applied Statistics)*, 29(2), 156-163. <https://doi.org/10.2307/2986139>
- Akaike, H. (1974). A New Look at the Statistical Model Identification. *IEEE Transactions on Automatic Control*, 19(6), 716-723. <https://doi.org/10.1109/TAC.1974.1100705>
- Allison, P. D. (1982). Discrete-Time Methods for the Analysis of Event Histories. *Sociological Methodology*, 13, 61-98. <https://doi.org/10.2307/270718>
- Arel-Bundock, V., Greifer, N., & Heiss, A. (2024). How to Interpret Statistical Models Using `marginalEffects` for R and Python. *Journal of Statistical Software*, 111(9), 1-32. <https://doi.org/10.18637/jss.v111.i09>
- Bates, D., Mächler, M., Bolker, B., & Walker, S. (2015). Fitting Linear Mixed-Effects Models Using `lme4`. *Journal of Statistical Software*, 67(1), 1-48. <https://doi.org/10.18637/jss.v067.i01>
- Burnham, K. P., & Anderson, D. R. (2002). *Model Selection and Multimodel Inference: A Practical Information-Theoretic Approach* (2.^a ed.). Springer. <https://doi.org/10.1007/b97636>
- Cox, D. R. (1972). Regression models and life-tables. *Journal of the Royal Statistical Society: Series B (Methodological)*, 34(2), 187-202. <https://doi.org/10.1111/j.2517-6161.1972.tb00899.x>
- Cox, D. R. (1975). Partial Likelihood. *Biometrika*, 62(2), 269-276. <https://doi.org/10.1093/biomet/62.2.269>

- Dobson, A. J., & Barnett, A. G. (2018). *An Introduction to Generalized Linear Models* (4.^a ed.). Chapman; Hall/CRC. <https://doi.org/10.1201/9781315182780>
- Duan, N. (1983). Smearing Estimate: A Nonparametric Retransformation Method. *Journal of the American Statistical Association*, 78(383), 605-610. <https://doi.org/10.1080/01621459.1983.10478017>
- Dunn, P. K., & Smyth, G. K. (2005). Series evaluation of Tweedie exponential dispersion model densities. *Statistics and Computing*, 15(4), 267-280. <https://doi.org/10.1007/s11222-005-4070-y>
- Faraway, J. J. (2016). *Extending the Linear Model with R: Generalized Linear, Mixed Effects and Nonparametric Regression Models* (2.^a ed.). Chapman; Hall/CRC.
- Fox, J. (2016). *Applied Regression Analysis and Generalized Linear Models* (3.^a ed.). SAGE.
- Friedman, J. H., Hastie, T., & Tibshirani, R. (2010). Regularization Paths for Generalized Linear Models via Coordinate Descent. *Journal of Statistical Software*, 33(1), 1-22. <https://doi.org/10.18637/jss.v033.i01>
- Grambsch, P. M., & Therneau, T. M. (1994). Proportional hazards tests and diagnostics based on weighted residuals. *Biometrika*, 81(3), 515-526. <https://doi.org/10.1093/biomet/81.3.515>
- Harrell, F. E. (2015). *Regression Modeling Strategies: With Applications to Linear Models, Logistic and Ordinal Regression, and Survival Analysis* (2.^a ed.). Springer. <https://doi.org/10.1007/978-3-319-19425-7>
- Hartig, F. (2024). *DHARMA: Residual Diagnostics for Hierarchical (Multi-Level / Mixed) Regression Models*. <https://CRAN.R-project.org/package=DHARMA>
- Hilbe, J. M. (2014). *Modeling count data*. Cambridge University Press.
- Hoerl, A. E., & Kennard, R. W. (1970). Ridge Regression: Biased Estimation for Nonorthogonal Problems. *Technometrics*, 12(1), 55-67. <https://doi.org/10.1080/00401706.1970.10488634>
- Holford, T. R. (1980). The analysis of rates and of survivorship using log-linear models. *Biometrics*, 36(2), 299-305. <https://doi.org/10.2307/2529982>
- Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied Logistic Regression* (3.^a ed.). Wiley. <https://doi.org/10.1002/9781118548387>
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning with Applications in R* (2.^a ed.). Springer. <https://doi.org/10.1007/978-1-0716-1418-1>
- Jørgensen, B. (1987). Exponential dispersion models (with discussion). *Journal of the Royal Statistical Society: Series B (Methodological)*, 49, 127-162.
- Jørgensen, B. (1997). *The Theory of Dispersion Models*. Chapman; Hall.
- Laird, N., & Olivier, D. (1981). Covariance analysis of censored survival data using log-linear analysis techniques. *Journal of the American Statistical Association*, 76(374), 231-240. <https://doi.org/10.1080/01621459.1981.10477634>
- Lambert, D. (1992). Zero-Inflated Poisson Regression, with an Application to Defects in Manufacturing. *Technometrics*, 34(1), 1-14. <https://doi.org/10.2307/1269547>
- McCullagh, P., & Nelder, J. A. (1989). *Generalized Linear Models* (2.^a ed.). Chapman; Hall/CRC.

- Mullahy, J. (1986). Specification and Testing of Some Modified Count Data Models. *Journal of Econometrics*, 33(3), 341-365. [https://doi.org/10.1016/0304-4076\(86\)90002-3](https://doi.org/10.1016/0304-4076(86)90002-3)
- Nelder, J. A., & Wedderburn, R. W. M. (1972). Generalized Linear Models. *Journal of the Royal Statistical Society. Series A (General)*, 135(3), 370-384. <https://doi.org/10.2307/2344614>
- Prentice, R. L., & Gloeckler, L. A. (1978). Regression Analysis of Grouped Survival Data with Application to Breast Cancer Data. *Biometrics*, 34(1), 57-67. <https://doi.org/10.2307/2529588>
- R Core Team. (2024). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing. <https://www.r-project.org/>
- Robin, X., Turck, N., Hainard, A., Tiberti, N., Lisacek, F., Sanchez, J.-C., & Müller, M. (2011). pROC: An Open-Source Package for R and S+ to Analyze and Compare ROC Curves. *BMC Bioinformatics*, 12, 77. <https://doi.org/10.1186/1471-2105-12-77>
- Schoenfeld, D. (1982). Partial residuals for the proportional hazards regression model. *Biometrika*, 69(1), 239-241. <https://doi.org/10.1093/biomet/69.1.239>
- Schwarz, G. (1978). Estimating the Dimension of a Model. *The Annals of Statistics*, 6(2), 461-464. <https://doi.org/10.1214/aos/1176344136>
- Self, S. G., & Liang, K.-Y. (1987). Asymptotic Properties of Maximum Likelihood Estimators and Likelihood Ratio Tests under Nonstandard Conditions. *Journal of the American Statistical Association*, 82(398), 605-610. <https://doi.org/10.1080/01621459.1987.10478472>
- Stone, M. (1974). Cross-Validatory Choice and Assessment of Statistical Predictions. *Journal of the Royal Statistical Society: Series B (Methodological)*, 36(2), 111-147. <https://doi.org/10.1111/j.2517-6161.1974.tb00994.x>
- Stram, D. O., & Lee, J. W. (1994). Variance Components Testing in the Longitudinal Mixed Effects Model. *Biometrics*, 50(4), 1171-1177. <https://doi.org/10.2307/2533455>
- Therneau, T. M. (2024). *survival: A Package for Survival Analysis in R*. <https://CRAN.R-project.org/package=survival>
- Therneau, T. M., & Grambsch, P. M. (2000). *Modeling Survival Data: Extending the Cox Model*. Springer. <https://doi.org/10.1007/978-1-4757-3294-8>
- Tibshirani, R. (1996). Regression Shrinkage and Selection via the Lasso. *Journal of the Royal Statistical Society: Series B (Methodological)*, 58(1), 267-288. <https://doi.org/10.1111/j.2517-6161.1996.tb02080.x>
- Tweedie, M. C. K. (1984). An index which distinguishes between some important exponential families. *Statistics: Applications and New Directions. Proceedings of the Indian Statistical Institute Golden Jubilee International Conference*, 579-604.
- Vaupel, J. W., Manton, K. G., & Stallard, E. (1979). The impact of heterogeneity in individual frailty on the dynamics of mortality. *Demography*, 16(3), 439-454. <https://doi.org/10.2307/2061224>
- Venables, W. N., & Ripley, B. D. (2002). *Modern Applied Statistics with S* (4.^a ed.). Springer.